FNO 求解粘性 Burgers 方程的报告

本文依据 Li 等人的 Fourier Neural Operator 论文，说明所提供程序中一维周期粘性 Burgers 方程的实现。模型用初始场直接预测 t=1 的终态；本次完整复算对固定测试样本的终态相对 L^2 误差为 0.05837%，200 条测试初值的平均相对 L^2 误差为 0.09421%。这些指标均以程序生成的有限差分解为参考。

1. 训练数据与初始函数

求解方程及初边值条件为：

$$\partial_t u + \partial_x(u^2/2) = \nu \partial_{xx} u, \qquad \nu = 0.1, \quad 0 < t \le 1$$

$$u(x,0) = u_0(x), \qquad u(x+1,t) = u(x,t), \qquad x \in [0,1)$$

这里的粘性系数和终止时刻始终固定，变化的是初始函数。与论文第 5.1 节相同，学习对象是从初始函数到终态函数的解算子，而不是逐步推进的时间离散格式：

$$G^\dagger : u_0 \longmapsto u(\cdot,1), \qquad \hat{u}(\cdot,1) = s f_\theta(u_0)$$

其中 $G^\dagger$ 表示方程的初值到终态映射；f_θ 为网络给出的归一化预测，θ 表示待训练参数，s 为训练标签的全局标准差。物理量预测需将网络输出乘回 s。

1.1 初始函数如何产生

$$u_0^{(i)}(x) = \sum_{k=1}^{127} [a_{ik}\sin(2\pi k x) + b_{ik}\cos(2\pi k x)]$$

$$a_{ik} = \sigma_k \xi_{ik}, \quad b_{ik} = \sigma_k \zeta_{ik}, \quad \sigma_k = \frac{25\sqrt{2}}{(2\pi k)^2 + 25}, \quad \xi_{ik}, \zeta_{ik} \sim \mathcal{N}(0,1)$$

程序独立抽取标准正态随机数，生成 1200 条初值，前 1000 条用于训练，后 200 条用于测试。k=1,…,127 对应 127 个非零空间频率；系数标准差按上式随波数衰减。随机种子固定为 0。

初值不含常数项，因此在该均匀周期网格上空间均值为零（浮点误差除外）。每个训练样本是一整条 256 点曲线与其终态曲线的配对，不能把 1000×256 个网格值视为同样数量的独立初始条件。

项目	代码中的设置
训练集	1000 对初始场与终态场；全部参与梯度训练。
验证集	未设置。训练 500 轮后使用最后的模型。
测试集与图示算例	200 条同分布随机初值；四格图固定展示其中第一条。
空间范围	x∈[0,1)，256 点，不重复存储 x=1。

该谱衰减对应论文附录 A.3.1 的协方差 $625(-\Delta+25I)^{-2}$；代码在零空间均值子空间上截取前 127 个非零波数，常数项置零。它直接满足周期性，并使高频初始分量较弱；当前样本数与截断范围不代表已验证的最优设置。

1.2 参考标签的数值生成

对 1000 条初始曲线同时进行数值积分，从 t=0 推进到 t=1。每一步根据左右相邻点计算变化量；最左点的左邻点取最右点，最右点的右邻点取最左点，从而实施周期边界。用 u_j^q 表示第 j 个空间点在第 q 个时间步的数值解，更新式为：

$$u_j^{q+1} = u_j^q + \Delta t\left[-\frac{(u_{j+1}^q)^2 - (u_{j-1}^q)^2}{4\Delta x} + \nu\frac{u_{j+1}^q - 2u_j^q + u_{j-1}^q}{\Delta x^2}\right]$$

$$\Delta x = 1/256, \qquad \Delta t = 0.00005, \qquad q = 0, \ldots, 19999$$

非线性项是通量 $u^2/2$ 的中心差分，粘性项是二阶中心差分，时间推进采用显式 Euler。对光滑解，其形式截断误差为空间二阶、时间一阶。整个标签生成过程执行 20000 步，FNO 训练只使用终态，不保存中间时刻作为监督标签。

该实现便于用简短程序批量构造输入输出配对；训练标签由 Burgers 方程生成，物理信息通过标签进入监督学习。它不是论文附录 A.3.1 使用的 Fourier 分裂步数据生成器。256 点参考解含有数值离散误差，不能称为解析解或精确真值。

1.3 标签缩放及其理由

$$s = \left[\frac{1}{1000\cdot 256 - 1}\sum_{i=1}^{1000}\sum_{j=0}^{255}\left(u_{j,\mathrm{ref}}^{(i)} - \overline{u}_{\mathrm{ref}}\right)^2\right]^{1/2}, \qquad y_j^{(i)} = u_{j,\mathrm{ref}}^{(i)}/s$$

将全部 1000×256 个终态值合并计算一个样本标准差 s。上式中 i 为样本序号，j 为空间点序号，y 为缩放后的标签。只将标签除以 s，不减去均值；输入初始场保持原尺度，测试参考解不参与 s 的计算。

本次终态标准差为 0.00968339，初始场均方根为 0.58944708。缩放将输出目标提升到约为 1 的尺度，减少终态幅值较小给优化带来的尺度问题。它对所有样本使用同一个常数；逐样本相对误差的平衡由第 4 节的损失分母实现。

2. 输入与输出

对第 i 条初始曲线，网络接收的是按空间顺序排列的 256 个初值：

$$\boldsymbol{u}_0^{(i)} = \left(u_0^{(i)}(x_0), \ldots, u_0^{(i)}(x_{255})\right), \qquad x_j = j/256$$

位置	数据规模	实际含义
全部训练输入	1000 条曲线	每条曲线给出 256 个空间点上的初始值。
单个小批次	20 条曲线	每次用 20 条初始曲线共同计算损失并更新参数。
送入网络	每个点 1 个数	每点只有一个初始场值，作为该点的输入特征。
网络输出	每条曲线 256 个数	归一化终态 $f_\theta(u_0)$，尚未乘回尺度。
物理量预测	每条曲线 256 个数	乘回 s 后，对应 t=1 的整条空间曲线。

时间 t、粘性 ν 和绝对位置 x 均未作为输入。空间点的位置由固定周期网格及其顺序给出。因此本模型对应 ν=0.1、T=1 的固定终态任务；当前训练并不提供任意时刻预测或不同粘性的泛化证据。

3. 神经网络结构

网络先把每点的一个初始值转成 64 个特征，再经过四个 Fourier 块，最后将这些特征转成一个终态预测值。这里“通道”就是每个空间点上保存的一种特征；64 通道表示每点有 64 个特征数。

组成	具体设置	每条初值对应的结果
输入提升 P	逐点线性变换，1 个数变为 64 个特征，含偏置。	256 点，每点 64 个特征。
Fourier 块 ×4	每块含谱分支与局部分支；两者相加后使用 ReLU 激活。	256 点，每点 64 个特征。
谱分支	Fourier 变换 → 前 16 个频率的特征混合 → 逆变换。	256 点，每点 64 个特征。
局部分支	同一空间点的 64 个特征作线性组合，生成新的 64 个特征。	256 点，每点 64 个特征。
输出投影 Q	每点的 64 个特征先变为 128 个，经 ReLU 激活后再变为 1 个数。	256 点，每点 1 个终态预测值。

上述逐点线性变换由核大小为 1 的一维卷积实现，各空间点共用同一组参数。它只组合同一点的不同特征，跨空间位置的信息交换由谱分支完成。

3.1 Fourier 块的逐项计算

$$v_{\ell+1}(x) = \mathrm{ReLU}\left[\mathcal{F}^{-1}(R_\ell \mathcal{F} v_\ell)(x) + W_\ell v_\ell(x) + b_\ell\right]$$

ℓ 表示网络层号，v_ℓ 表示这一层的特征，$\mathcal{F}$ 和 $\mathcal{F}^{-1}$ 分别表示 Fourier 变换及其逆变换。R_ℓ 为谱分支的权重，W_ℓ 和 b_ℓ 为局部分支的权重与偏置。层号与方程的时间步无关。

对每一种特征在 256 个空间点上的值作 Fourier 变换，得到 $k=0,\cdots,128$ 共 129 个频率系数；实信号的负频率可由这些系数确定，无需重复保存。对每个保留频率，使用一张 64×64 的复权重矩阵组合 64 种输入特征：

$$\widehat{w}_o(k) = \sum_{c=1}^{64} R_{\ell,c,o}(k)\widehat{v}_c(k), \qquad k = 0, \ldots, 15$$

其中 c 为输入特征编号，o 为输出特征编号，k 为频率编号。公式左侧是组合后的输出系数，右侧是 64 个输入系数的加权和。谱分支保留 $k=0,\cdots,15$，包含零频率；其余系数置零，再逆变换回 256 个空间点，与局部分支相加。四个块全部使用 ReLU，第四块也不例外。

3.2 参数量及其他设置

四层谱权重共有 4×64×64×16=262144 个复数；其余权重和偏置共 25217 个实数。每个复数包含实部和虚部两个实数，因此按存储的实数分量计算，参数总量为 549505。

谱权重由复高斯随机数除以 64 初始化。模型没有批归一化、随机丢弃神经元、POD 降阶或均值守恒修正。局部分支的系数需要训练，并非直接把上一层结果原样相加。

3.3 为什么采用 Fourier 结构

论文第 3、4 节将神经算子层写成局部映射与积分算子的组合。若积分核只依赖位置差 x-y，积分变为卷积；在 Fourier 空间中，卷积可用逐频率矩阵乘法实现：

$$(\mathcal{K}_\ell v)(x) = \int_0^1 \kappa_\ell(x-y)v(y)\,dy = \mathcal{F}^{-1}[(\mathcal{F}\kappa_\ell)(\mathcal{F}v)](x)$$

κ_ℓ 是第 ℓ 层的卷积核，描述各位置之间如何相互影响；左侧符号表示这个卷积运算。积分式将整个空间域的信息汇集到位置 x，右侧是同一运算的 Fourier 表达。

本代码直接学习每个保留频率上的通道混合矩阵 R_ℓ，不先在物理空间拟合积分核。Fourier 基函数覆盖整个周期域，一个谱层就能建立全局空间联系；与周期边界及均匀网格相配合，FFT 可有效计算这个全局分支。

选择	能够说明的理由及边界
Fourier 全局分支	解算子依赖整条初始曲线。谱分支在全域交换信息，与从初始场预测终态场的任务相符。
保留 16 个频率	限制谱权重规模，以低频成分构成主要全局表示。随机初值的高频系数较弱，粘性扩散也抑制高频；但初值包含更多频率，16 并非解的精确频率上限。
局部 1×1 分支	保留各位置的通道信息，并与全局谱信息组合。高频未被该分支统一截断，因此整个网络输出不被限制为仅含前 16 个频率。
ReLU 非线性	Burgers 的初值到终态映射是非线性的；逐点激活使多个线性谱层能够组成非线性算子。ReLU 计算直接，但本次没有与其他激活函数的消融对照。
64 通道及四个块	通道提升提供多维隐表示，多层复合增加表达能力。四层组织与论文基本框架一致；宽度 64 的精度、效率取舍没有单独消融对照。
不输入绝对 x	周期均匀网格上的谱卷积、逐点卷积和逐点激活均兼容整数网格循环平移，适合空间齐次的方程。该性质不等价于连续域误差保证。

ReLU 的定义为 max(0,z)。它提供逐点非线性；与局部分支共同作用后，谱分支截断并不意味着最终预测只是一次低通滤波。

“为什么选它们”需要区分结构依据与最优性证据：论文提供了 Fourier 神经算子的理论组织方式和基准实验；本代码给出了具体超参数，但未包含模式数、宽度、深度或激活函数的消融实验。因此可以解释这些选择的功能，不能把它们写成已验证的最优配置。

4. 损失函数

每次训练取 B=20 条初始曲线，每条有 256 个空间点。用 y 表示归一化标签，用 ŷ 表示网络预测的归一化终态。训练时先对每条曲线计算相对 L^2 误差，再对当前批次取平均：

$$\mathcal{L}_{\mathrm{FNO}} = \frac{1}{B}\sum_{i=1}^{B}\frac{\left\|f_\theta(u_0^{(i)}) - \boldsymbol{y}^{(i)}\right\|_2}{\max\left(\left\|\boldsymbol{y}^{(i)}\right\|_2, 10^{-12}\right)}, \qquad B = 20$$

其中向量范数对 256 个空间点求平方和后开方。分母中的下限只用于避免除零；对本次非零标签，分母使用每条参考曲线自己的范数。忽略这一保护下限时，全局尺度 s 在比值中抵消，该损失等价于原物理量上的逐样本相对 L^2 误差平均。

选择相对 L^2 的作用是按每条曲线自身的幅值衡量偏差，避免幅值较大的样本仅因绝对误差较大而主导训练，并使数据优化目标与主要测试指标一致。它不是误差平方的平均，也不保证对所有初值都获得相同精度。

该损失是纯数据监督项。程序没有 Burgers 残差、时间导数残差、初值或边界惩罚、空间导数监督项。周期结构体现在数据生成和谱运算中。优化器另设置权重衰减 0.0001；损失表达式中没有单独追加正则化项。

程序同时计算归一化 MSE，但它只用于每 50 轮的日志和四格图，不参与反向传播：

$$\mathrm{MSE}_{\log} = \frac{1}{B\cdot 256}\sum_{i=1}^{B}\sum_{j=0}^{255}\left(\hat{y}_j^{(i)} - y_j^{(i)}\right)^2$$

4.1 优化设置与训练记录

项目	实际设置及含义
优化器	Adam；初始学习率 0.001，权重衰减系数 0.0001。
训练批量	每轮随机打乱 1000 个样本，分成每组 20 个样本，共 50 次更新；500 轮共 25000 次更新。
学习率	每完成 100 轮减半。第 1-100、101-200、201-300、301-400、401-500 轮分别为 0.001、0.0005、0.00025、0.000125、0.0000625。
最后一次退火	第 500 轮结束后变为 0.00003125；此后没有新的参数更新。
选模与记录	无验证集或早停，使用第 500 轮模型；每 50 轮打印最后小批次的相对 L^2 损失和 MSE，图中记录 MSE。
复算环境	Python 3.13.15，PyTorch 2.13.0+cu132；RTX 5080 Laptop GPU 训练，CPU 4 线程准备数据；随机种子 0。

Adam 用于梯度训练，学习率逐步减半可在后期减小更新步幅。这里可以说明策略的作用，但代码未提供优化器或调度器对照。程序记录的最后小批次损失既不是整轮平均损失，也不是验证误差；不同轮次最后一个随机小批次的样本也可能不同。

5. 数值实验

本节考察 Fourier 神经算子对一维周期粘性 Burgers 方程终态解的预测能力。模型学习初始场到 t=1 终态场的映射，并将预测结果与有限差分参考解比较。以下数值和图形来自当前代码在 GPU 上完成 500 轮训练后的同一次复算。

实验采用 1000 条随机周期初值及其终态作为训练数据，另有 200 条同分布随机初值用于测试，空间分辨率为 256 点。网络由四个 Fourier 块构成，宽度为 64，每层谱分支保留 16 个频率。使用 Adam 训练 500 轮，批量为 20，初始学习率为 0.001，每 100 轮减半，权重衰减为 0.0001；完整设置见第 1-4 节。

考虑前文给出的周期初值问题，粘性系数固定为 $\nu=0.1$，空间区域为 $x\in[0,1)$，终止时刻为 $t=1$。学习目标与物理量预测分别为：

$$G^{\dagger}:u_0\longmapsto u(\cdot,1),\qquad \hat{u}(\cdot,1)=sf_{\theta}(u_0)$$

图示测试初值固定取测试集第一条曲线，即 1200 条随机初值中的第 1001 条。它不参与梯度训练或标签尺度计算。训练和测试使用同一初值分布及同一个差分求解器；各时刻、各方法的图示初值保持一致。

评价指标。 记预测场为 $\hat{u}$，有限差分参考场为 u_{ref}，采用相对 L^2 误差、最大绝对误差和均方根误差：

$$E_{\mathrm{rel}}=\frac{\|\hat{u}-u_{\mathrm{ref}}\|_2}{\|u_{\mathrm{ref}}\|_2}\times 100\%,\qquad E_{\max}=\max_j|\hat{u}_j-u_{j,\mathrm{ref}}|$$

$$\mathrm{RMSE}=\sqrt{\frac{1}{256}\sum_{j=0}^{255}(\hat{u}_j-u_{j,\mathrm{ref}})^2}$$

后两项与场值单位相同，不是百分数。测试集平均相对 L^2 是先计算每条曲线的相对误差，再对 200 个结果取算术平均。

表 1 固定测试初值在 t=1 时的预测误差（空间分辨率为 256 点）

方法	相对 L^2 误差	最大绝对误差	均方根误差
FNO	0.05837%	1.03697×10^{-5}	4.63027×10^{-6}

200 条独立测试初值的平均相对 L^2 误差为 0.09421%。图示参考终态的最大绝对幅值为 1.12177×10^{-2}；训练结束后，对全部 1000 条归一化标签另行评价所得 MSE 为 8.46087×10^{-7}。

代码将图示相对误差保留两位百分数，表中更详细数值由本次保存的预测和参考数组计算。MSE 日志与反向传播所用的相对 L^2 损失含义不同。

表 2 训练过程中记录的最后一个小批次的归一化均方误差

训练轮次	50	100	150	200	250
MSE	1.52×10^{-4}	3.03×10^{-4}	1.37×10^{-4}	4.11×10^{-5}	8.77×10^{-6}
训练轮次	300	350	400	450	500
MSE	4.51×10^{-6}	4.99×10^{-6}	1.64×10^{-6}	1.07×10^{-6}	7.77×10^{-7}

每 50 轮记录一次，各数值为该轮最后一个小批次的 MSE，并非整轮平均损失或验证误差。

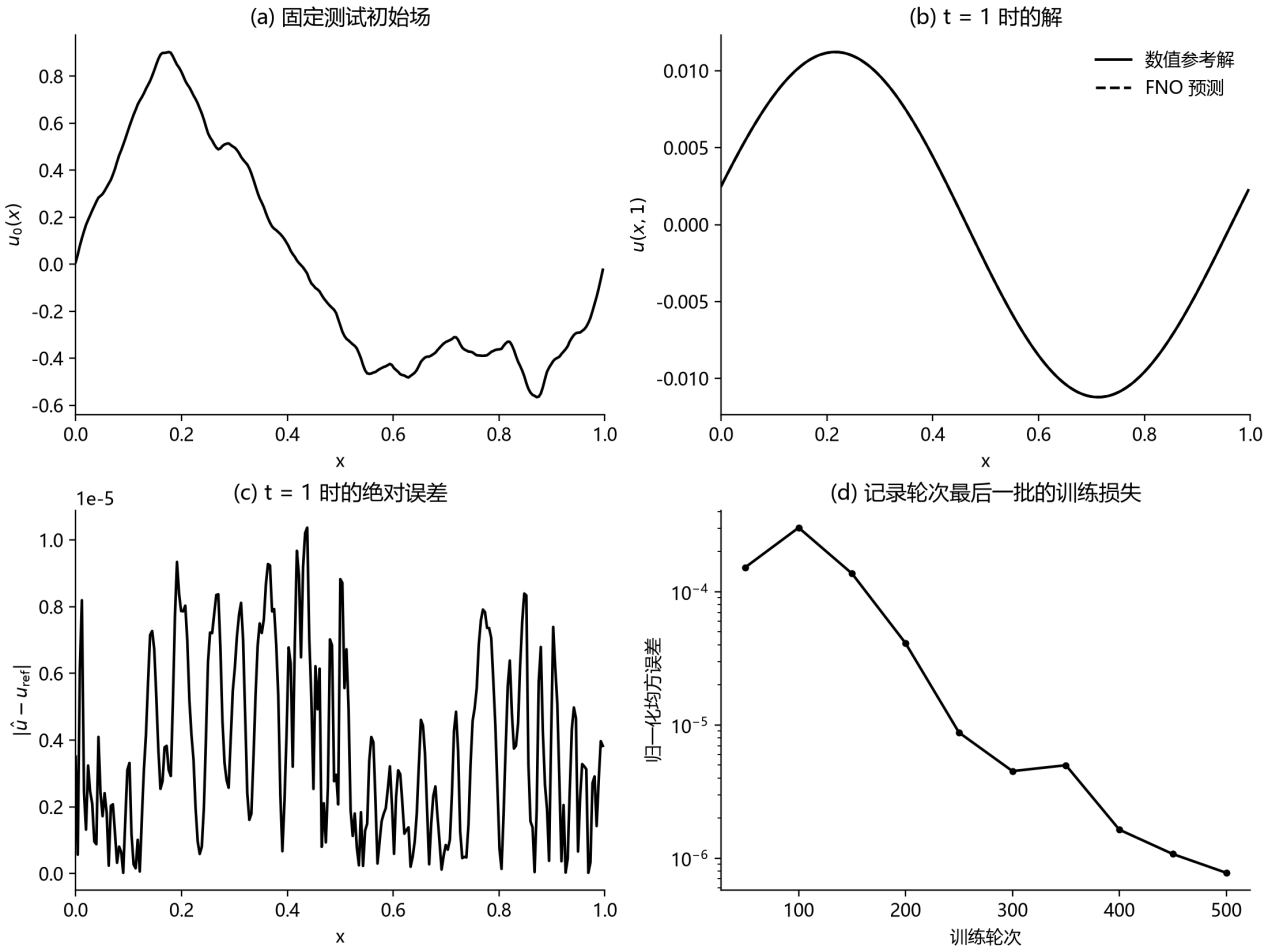


图 1 当前代码的固定测试算例及训练日志。（a）测试集第一条初始场；（b）t=1 的有限差分参考解与 FNO 预测；（c）同一终态的逐点绝对误差；（d）表 2 中每 50 轮记录的最后小批次 MSE，纵轴为对数。

图中使用原有 256 点并以直线连接，不额外添加 x=1 的重复端点，不平滑误差。参考解用黑实线，预测用黑虚线；（a）的初值并非网络对 t=0 的预测。（d）只有十个记录点，连接线不代表中间轮次已经记录。

预测结果。 如图 1(b) 和表 1 所示，固定样本的终态相对误差为 0.05837%，200 条测试曲线的平均值为 0.09421%。前者描述图中算例，后者补充了同分布随机初值上的评价；训练集 MSE 则描述训练拟合，三者统计对象不同。

训练过程与误差尺度。 图示参考终态最大幅值仅约为 0.01122，因此需要同时给出相对误差和绝对误差，避免只凭两条重合曲线判断精度。表 2 的日志总体下降，局部回升可受批次变化影响，不能仅凭十个点判断完整收敛过程。

结果讨论。 本次包含 200 条独立测试初值，但没有多随机种子统计、参考解网格收敛或与传统求解器的统一效率对照。结果反映当前初值分布下相对于离散参考解的误差，不能直接推导连续精确解误差、分布外精度或超分辨率能力。

结论。 当前程序实现固定粘性 0.1、固定终止时刻 1 的 FNO 终态映射。训练数据为随机周期高斯初值及显式有限差分终态，网络由四个谱分支与局部分支相加的 ReLU 块构成，优化目标为逐样本相对 L^2 误差平均。一次完整复算在图示初值上的相对误差为 0.05837%。

这一结果说明该实现能够拟合所展示的离散终态，并在独立同分布测试集上取得相应误差；其适用范围仍受初值分布、单一终止时刻监督和数值标签精度限制。保留 Fourier 算子结构，不等于复现了原论文的全部实验设置与性能结论。

6. FNO-PRNN求解粘性Burgers方程

本节在第 5 节的周期 Burgers 算例上，将 FNO 与物理增强神经网络（PRNN）结合。FNO 根据初始场和查询时间提取空间特征，POD 用少量系数表示解，训练时同时拟合终态数据并约束降阶方程残差。以下按训练数据、输入输出、网络结构、损失函数和数值实验依次说明；实验数值与四联图使用当前代码的完整复算结果。

6.1 训练数据与初始函数

求解方程和初边值条件仍为：

$$\partial_t u + \partial_x(u^2/2) = \nu \partial_{xx} u, \quad \nu = 0.1, \quad x \in [0,1), \quad 0 < t \le 1$$

$$u(x,0) = u_0(x), \qquad u(x+1,t) = u(x,t)$$

粘性系数与空间区域固定，变化的是初始函数。空间取 256 个点 $x_j = j/256$（$j=0,\cdots,255$），不重复保存 $x=1$；图示测试初值仍取同一测试集的第一条曲线。

6.1.1 初始函数如何产生

$$u_0^{(m)}(x) = \sum_{k=1}^{127} [a_{mk}\sin(2\pi k x) + b_{mk}\cos(2\pi k x)]$$

$$a_{mk} = \sigma_k \xi_{mk}, \quad b_{mk} = \sigma_k \zeta_{mk}, \quad \sigma_k = \frac{25\sqrt{2}}{(2\pi k)^2 + 25}, \quad \xi_{mk}, \zeta_{mk} \sim \mathcal{N}(0,1)$$

$m=1,\cdots,1000$ 表示训练初值编号，另留 200 条作测试。正态随机数相互独立，随机种子为 0；系数标准差随波数增大而减小。初值没有常数项，在周期均匀网格上具有零空间均值，浮点误差除外。

Fourier 随机初值直接满足周期性，并使分布以较低频成分为主。这一设置与当前 FNO 一致，便于在同一问题上加入降阶与物理约束；没有证据表明当前样本数或截断频率是最优选择。

6.1.2 参考标签与中间快照

$$u_j^{q+1} = u_j^q + \Delta t\left[-\frac{(u_{j+1}^q)^2 - (u_{j-1}^q)^2}{4\Delta x} + \nu\frac{u_{j+1}^q - 2u_j^q + u_{j-1}^q}{\Delta x^2}\right]$$

q 表示时间步，左右下标按周期循环。空间步长为 1/256，时间步长为 0.00005，共进行 20000 步。非线性通量使用中心差分，扩散项使用二阶中心差分，时间采用显式 Euler；这与 FNO 的标签求解器一致，所生成的是离散参考解。

表 3 训练数据、POD 快照和评价数据的用途

数据	数量与使用方式
训练初值及终态	1000 对 256 点场；终态经 POD 投影后作为数据损失的标签。
POD 快照	每 1000 步保存一次，加上初值，共 21 个时刻：$0, 0.05, \cdots, 1$；$1000\times21=21000$ 个场。
物理配点	每批 20 个训练初值分别配一个均匀随机时刻；不需要该配点处的参考标签。
验证与测试	无验证集，使用最后一轮模型；200 条测试初值不参与训练或 POD 基构造。

中间快照只用于建立降阶空间，数据损失只拟合 t=1 的终态系数。因此不能描述为完全没有利用中间解，也不能将 21000 个快照视为同样数量的独立初始条件。

6.2 输入与输出

对一个样本，模型接收整条初始曲线及查询时间，而不是单个位置的场值：

$$(\boldsymbol{u}_0, t) \longmapsto (\hat{a}_1(t), \ldots, \hat{a}_{12}(t)) \longmapsto \hat{u}(x_j, t)$$

时间 t 在所有空间点取相同数值，与该点的初始值并列，形成两个输入特征。单个样本包含 256 个初值和 1 个时间；复制时间是为了形成统一的两通道输入，不代表增加了 256 个独立时间变量。

表 4 从输入到物理量预测的各级结果

位置	每个初值对应的内容	实际含义
原始输入	256 个初值＋1 个查询时间	初始场保持原尺度，时间在 0 到 1 内。
FNO 输入	256 点，每点 2 个数	每点的初始值与相同的时间 t。
FNO 中间特征	256 点，每点 64 个特征	通过四个 Fourier 块交换全域信息。
FNO 输出头	256 个数	尚未投影的修正场 g_θ，不是最终物理解。
降阶网络输出	12 个实系数	经投影、扩散项和时间因子组合后的预测系数。
物理量预测	256 个场值	将预测系数与固定 POD 基函数线性组合。

当前程序的模型调用返回 12 个预测系数，之后再重建 256 点空间场。这些系数按原物理尺度表示，重建后无需乘回终态标准差 s；数据损失按每条参考系数向量的范数归一化。代码仍计算 s，但该变量不参与 FP 的训练损失或预测重建。

粘性 v 和绝对坐标 x 没有作为额外输入。空间位置由 256 点周期网格及其顺序确定。时间输入允许在不同 t 查询网络；本次既评价 t=1 的 200 条测试初值，也检查图示初值的五个时刻，不能据此断言任意初值和任意时刻都具有相同精度。

6.3 神经网络结构

整个计算由固定的 POD 表示、可训练的 FNO 主干、以及系数组合与场重建三部分组成。POD 基、扩散特征值和二次对流系数由训练快照及离散方程预先计算，不是神经网络参数。

6.3.1 POD 降阶表示

$$\langle f, g\rangle_h = \tfrac{1}{256}\sum_{j=0}^{255} f(x_j)g(x_j), \qquad \langle \phi_i, \phi_k\rangle_h = \delta_{ik}$$

$$a_i = \langle u, \phi_i\rangle_h, \qquad P_{12}u = \sum_{i=1}^{12} a_i\phi_i, \qquad \hat{u}(x,t) = \sum_{i=1}^{12} \hat{a}_i(t)\phi_i(x)$$

内积表示 256 个网格点上乘积的平均，δ_{ik} 在 i=k 时为 1，其余为 0。Φ_i 是第 i 个固定空间基函数，a_i 是解在该基上的系数，P_{12} 表示保留 12 个基函数的投影。原来描述一条场需要 256 个数，现在用 12 个系数描述主要空间变化。

先对每个快照去掉空间均值，记所得 256 点列向量为 w。用全部训练快照组成协方差，再对整数格周期平移求平均：

$$C = \frac{1}{21000}\sum_{m=1}^{21000} w_m w_m^T, \qquad \overline{C} = \frac{1}{256}\sum_{s=0}^{255} S_s C S_s^T$$

S_s 表示循环平移 s 个网格点，右上角 T 表示转置。对平均协方差取最大特征值对应的 12 个特征向量，经正交化与尺度调整，使其在离散内积下正交归一。周期平移平均利用方程的空间平移对称性，不加入测试样本，也不需要额外求解新初值。

本次用最终基投影后保留训练快照能量的 99.898125%。当前初值含有 127 个非零波数，12 维子空间不能完整表示全部初始频率。较高的能量保留率只说明这些训练快照总体容易表示，不保证每条新初值的预测误差，尤其不保证初值能够无误差重建。

6.3.2 FNO 主干的逐项计算

表 5 可训练网络的结构和作用

组成	具体设置	输出内容
输入提升	核大小为 1 的一维卷积，含偏置；2→64。	256 点，每点 64 个特征。
Fourier 块 ×4	谱分支与局部分支相加，再使用 ReLU。	空间点数和特征数不变。
谱分支	FFT；波数 0-15 的复权重混合；高频置零；逆 FFT。	全域交换后的 64 个特征。
局部分支	核大小为 1 的卷积，含偏置；64→64。	同一位置的特征线性组合。
输出头	逐点 64→128，经 ReLU 后 128→1。	256 点修正场 g_θ。

$$v_{\ell+1}(x) = \mathrm{ReLU}\left[\mathcal{F}^{-1}(R_\ell \mathcal{F} v_\ell)(x) + W_\ell v_\ell(x) + b_\ell\right]$$

$$\widehat{w}_o(k) = \sum_{c=1}^{64} R_{\ell,c,o}(k)\,\widehat{v}_c(k), \qquad k = 0, \ldots, 15$$

ℓ 是网络块编号，与物理时间步无关；c、o 分别是输入与输出特征编号。对 256 点实场的 FFT 给出波数 0-128 共 129 个系数，每个保留波数使用一张 64×64 复权重矩阵混合通道。谱分支之外的局部分支不进行相同的频率截断，四个块全部使用 ReLU。

四层谱权重共 262144 个复数，其余权重和偏置共 25281 个实数，按复数的实部、虚部分别计数，总计 549569 个实参数。16 个保留 Fourier 频率与 12 个 POD 实模态属于不同层次：前者控制谱分支，后者控制最终解的表示空间。

6.3.3 预测系数、初值约束与场重建

先将 FNO 修正场投影到 POD 基，得到修正系数；同样将给定初值投影得到初始系数：

$$c_{\theta,i}(u_0,t)=\langle g_\theta(u_0,t),\phi_i\rangle_h,\qquad a_{0,i}=\langle u_0,\phi_i\rangle_h$$

将 POD 子空间中的离散扩散矩阵作正交对角化，记对角元素为 λ_i。相应旋转只改变基的方向，不改变所保留的空间或正交性。最终预测系数采用：

$$\hat{a}_i(u_0,t)=a_{0,i}e^{\lambda_i t}+(1-e^{-\beta t})e^{-\beta t}c_{\theta,i}(u_0,t)$$

$$\beta=\frac{4\nu\sin^2(\pi/256)}{\Delta x^2},\qquad \hat{u}(x,t)=\sum_{i=1}^{12}\hat{a}_i(u_0,t)\phi_i(x)$$

第一项是该降阶空间中线性扩散的指数衰减。第二项是 FNO 学习的非线性修正，时间因子在 t=0 为零，且在晚期随扩散尺度衰减。β 取离散扩散算子第一个非零波数的衰减率；它与 ν、网格共同确定，不参与训练。

由此，t=0 的预测系数等于初始投影系数，重建场为 $P_{12}u_0$；这是对投影初值的结构约束。它不是完整 Burgers 方程的解析解，也不是对任意输入初值的逐点严格复制。本次训练初值的总体相对投影误差为 5.23931%，固定测试初值的 t=0 误差见表 8。

6.3.4 为什么采用这些结构

表 6 结构选择的依据及其边界

选择	作用与理由
FNO＋时间通道	利用初始场的全局空间结构，并区分不同查询时刻；保留原网络的周期谱运算。
POD 的 12 维表示	用较少系数表达主要空间变化，使物理约束写成降阶方程；模态截断仍可能遗漏动力学。
谱分支＋局部分支	分别提供全局空间联系和逐点特征组合；ReLU 提供逐点非线性。
扩散项＋时间因子	显式表达已知的线性衰减，并使修正项在初始时刻消失，减轻网络同时学习这些结构的负担。
固定基及方程系数	它们由训练快照和差分算子确定，优化集中于 FNO 参数；没有用测试解修正输出。

宽度 64、四个块和前 16 个频率与当前 FNO 一致，POD 秩取 12。上述理由解释结构的功能，本次实验未证明这些配置最优，也未以消融实验分离各部分的精度贡献。PRNN 的含义是降阶系数的“数据＋物理”联合训练，不是另接一个循环神经网络。

6.4 损失函数

训练目标由终态数据损失与降阶物理残差损失相加构成。前者利用差分求解器给出的标签，后者在随机时刻要求预测系数近似满足降阶动力学。两者都可对 FNO 参数反向传播。

6.4.1 终态系数数据损失及缩放

每批取 B=20 个初值，用终态参考解投影得到 12 个标签系数。当前数据损失对每条系数向量计算相对 L^2 误差，再对样本求平均：

$$a_{i,\mathrm{ref}}^{(b)}(1) = \langle u_{\mathrm{ref}}^{(b)}(\cdot,1), \phi_i \rangle_h$$

$$\mathcal{L}_{\mathrm{data}} = \frac{1}{B}\sum_{b=1}^{B} \frac{\|\hat{\boldsymbol{a}}(u_0^{(b)},1) - \boldsymbol{a}_{\mathrm{ref}}^{(b)}(1)\|_2}{\max(\|\boldsymbol{a}_{\mathrm{ref}}^{(b)}(1)\|_2, 10^{-12})}$$

分母按每条投影标签自身的幅值归一化，不再使用统一终态标准差 s 的平方。输入场不缩放，系数保持物理量尺度；保护下限 10^{-12} 用于避免除零。该项选择与 FNO 相同的逐样本相对误差原则，但比较对象是 12 维投影系数。

因为基函数按空间平均内积归一，忽略保护下限时，系数相对误差等于相对于投影参考场的重建相对误差：

$$\frac{\|\hat{\boldsymbol{a}} - \boldsymbol{a}_{\mathrm{ref}}\|_2}{\|\boldsymbol{a}_{\mathrm{ref}}\|_2} = \frac{\|\hat{u} - P_{12}u_{\mathrm{ref}}\|_h}{\|P_{12}u_{\mathrm{ref}}\|_h}$$

因此该项直接监督终态拟合，并按样本自身尺度衡量偏差。它不等于对完整参考场的相对误差，未保留模态的表示误差不能通过优化这些系数消除。小的数据损失不保证完整场误差同样小。

物理损失继续使用全部训练初值的均方根 s_0 作为尺度之一；它只由训练集计算，测试参考解不参与尺度估计：

$$s_0 = \sqrt{\frac{1}{1000\cdot 256}\sum_{b=1}^{1000}\sum_{j=0}^{255}\left[u_0^{(b)}(x_j)\right]^2}$$

本次 s_0=0.58944708。终态标准差 s=0.00968339 在代码中仍被计算，但 FP 损失已不使用它；后文完整场归一化 MSE 仅将它作为补充评价尺度。

6.4.2 降阶物理方程与残差

$$(D_x f)_j = \frac{f_{j+1} - f_{j-1}}{2\Delta x}, \qquad (D_{xx} f)_j = \frac{f_{j+1} - 2f_j + f_{j-1}}{\Delta x^2}$$

$$L_{ij} = \langle \nu D_{xx}\phi_j, \phi_i \rangle_h, \qquad Q_{ijk} = \left\langle -\tfrac{1}{2} D_x(\phi_j\phi_k), \phi_i \right\rangle_h$$

D_x、D_{xx} 分别是一阶和二阶周期中心差分；L 是扩散矩阵，Q 是对流二次项的固定系数。对扩散矩阵对角化并同时旋转基后，Galerkin 方程写为：

$$\frac{da_i}{dt} = \lambda_i a_i + \sum_{j=1}^{12}\sum_{k=1}^{12} Q_{ijk} a_j a_k, \qquad i = 1, \ldots, 12$$

这一步把空间变化的物理约束投影到 12 个基函数方向上。Q 来自守恒通量 $-D_x(u^2)/2$，与标签生成时使用的空间差分形式相同；没有用网络学习或用测试结果拟合 Q。

将网络系数代入降阶方程，把左右两边之差定义为物理残差：

$$r_i(u_0,t)=\partial_t\hat{a}_i-\lambda_i\hat{a}_i-\sum_{j=1}^{12}\sum_{k=1}^{12}Q_{ijk}\hat{a}_j\hat{a}_k$$

$$\mathcal{L}_{\text{phys}}=\frac{1}{B}\sum_{b=1}^{B}\sum_{i=1}^{12}\left[\frac{r_i(u_0^{(b)},t_b)}{\beta s_0 e^{-\beta t_b}}\right]^2,\qquad t_b\sim\mathcal{U}(0,1)$$

时间导数对给定初值保持不变，通过自动微分求出。每个批次为当前的 20 个初值分别抽取一个均匀随机时刻，重新计算残差，不要求对应时刻的参考解标签。对 12 个残差分量求平方和，再对样本取平均。

βs_0 给出残差的尺度，$e^{-\beta t}$ 对应选定的扩散衰减尺度。这样处理使晚期幅值很小时的残差仍受到约束，避免只由早期大幅值主导。它改变了不同时刻在物理损失中的权重，是本次人为选定的归一化方式，而不是对真实误差大小的精确估计。

$$\mathcal{L}_{\text{total}}=\mathcal{L}_{\text{data}}+\mathcal{L}_{\text{phys}}$$

两项权重均取 1。数据项是逐样本相对 L^2 损失，物理项是归一化残差平方和；数据项提供终态投影信息，物理项约束中间演化。本次没有验证权重 1 最优，两项的数值大小也不能直接解释为各自对最终测试误差的贡献。

没有额外的初值或边界罚项：初始投影由输出结构保证，周期性由周期差分、谱运算和基函数表示。Adam 另使用 0.0001 的权重衰减。物理损失约束半离散降阶方程，标签还含显式 Euler 时间离散误差，故残差小并不等价于对标签或连续精确解的误差小。

6.4.3 优化设置与损失记录

表 7 训练流程、采样和记录方式

项目	实际设置及含义
优化器	Adam，初始学习率 0.001，权重衰减 0.0001；仅优化 FNO 权重与偏置。
更新次数	1000 个训练初值每轮随机打乱，分为 50 个批次；500 轮共 25000 次更新。
学习率	每 100 轮减半；五个阶段分别为 0.001、0.0005、0.00025、0.000125、0.0000625。
随机性	数据与网络参数种子为 0，时间采样使用独立种子 1；CPU 生成随机数，再将所需数据移到 GPU。
物理采样	共抽取 500000 个初值-时间对；初值重复使用，时间随批次重新采样。
选模与记录	无验证集或早停，使用第 500 轮模型；保存各轮 50 个小批次损失的平均。

第 500 轮结束后学习率降到 0.00003125，但不再更新参数。逐步减小步幅有利于后期调整，未进行优化器对照。记录值包含一轮内参数不断变化的影响，既不是固定最终模型的全训练集损失，也不是验证误差。

6.5 数值实验

评价设置沿用第 5 节，图示初值取同一随机测试集第一条曲线，在原始 256 点上计算相对 L^2、最大绝对误差和均方根误差。图 2 与下表使用当前代码的预测、参考解和训练日志。

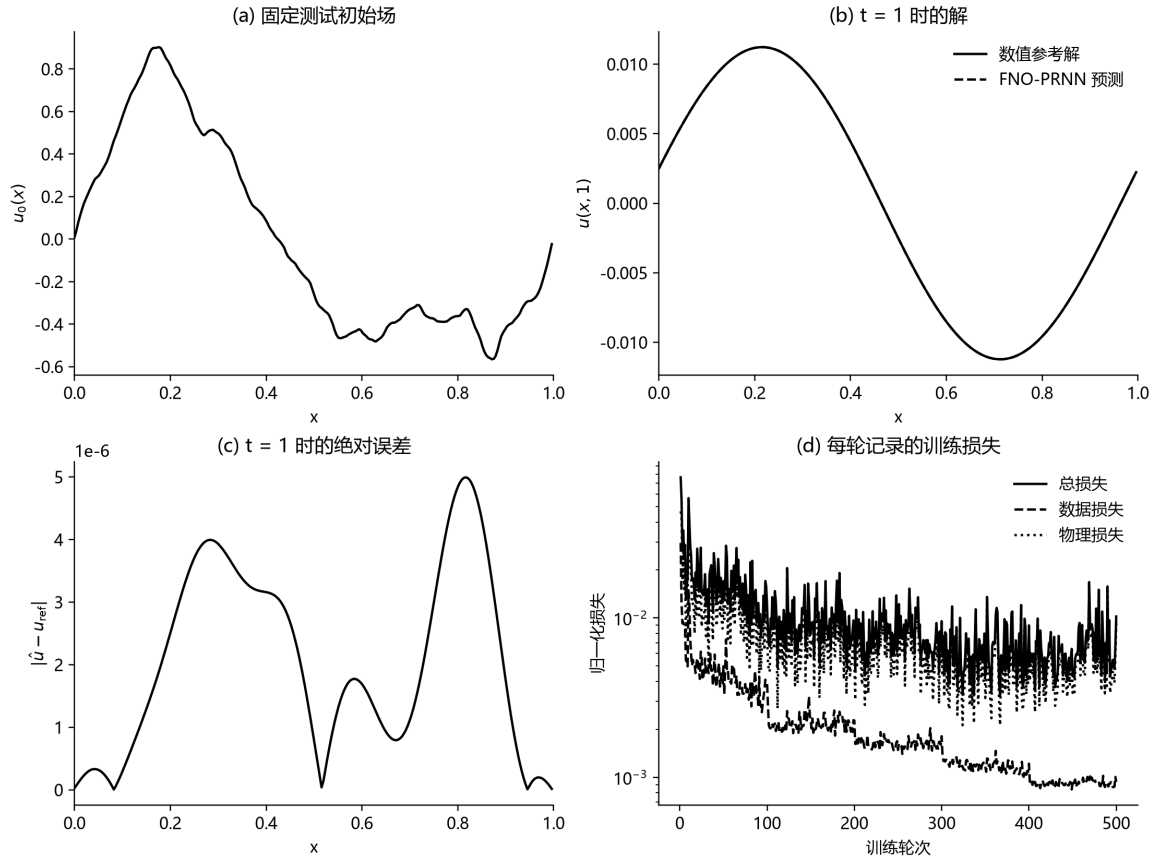


图 2 FNO-PRNN 的固定测试算例与训练过程。（a）初始场；（b）t=1 的参考解与预测解；（c）同一终态的逐点绝对误差；（d）每轮记录的总损失、数据损失和物理损失，纵轴为对数。

表 8 固定测试初值在不同查询时刻的预测误差

时刻 t	相对 L^2 误差	最大绝对误差	均方根误差
0.00	7.38683%	8.11588×10^{-2}	3.31192×10^{-2}
0.25	0.66446%	1.61503×10^{-3}	1.02763×10^{-3}
0.50	1.07324%	1.11979×10^{-3}	6.13803×10^{-4}
0.75	1.17454%	4.36432×10^{-4}	2.50027×10^{-4}
1.00	0.03180%	4.99375×10^{-6}	2.52269×10^{-6}

表中五个时刻均查询同一个 T=1 模型，未重新训练或对时间序列插值。t=0 的误差来自初值的 POD 投影和浮点运算，不能作为对未知解的预测成绩；其余时刻参考解由原差分求解器积分得到。

四联图使用原代码绘制：曲线以 256 点直线连接，不添加重复端点，不平滑误差；损失图包含全部 500 个轮次，采用第 6.4.3 节说明的逐轮小批次平均口径。

训练过程。 表 9 列出每 50 轮的损失记录。各项总体下降，训练中仍可能出现波动，不能仅凭下降趋势证明模型已达到最优解。

表 9 每 50 轮列出的训练损失（该轮小批次平均）

训练轮次	总损失	数据损失	物理损失
50	1.70695×10^{-2}	4.98310×10^{-3}	1.20864×10^{-2}
100	1.19434×10^{-2}	3.93930×10^{-3}	8.00408×10^{-3}
150	7.87983×10^{-3}	2.29159×10^{-3}	5.58823×10^{-3}
200	7.64674×10^{-3}	2.27376×10^{-3}	5.37298×10^{-3}
250	7.62661×10^{-3}	1.48616×10^{-3}	6.14046×10^{-3}
300	9.55537×10^{-3}	1.81250×10^{-3}	7.74287×10^{-3}
350	4.31917×10^{-3}	1.17338×10^{-3}	3.14579×10^{-3}
400	8.98985×10^{-3}	1.22028×10^{-3}	7.76957×10^{-3}
450	4.31399×10^{-3}	9.22626×10^{-4}	3.39137×10^{-3}
500	1.02243×10^{-2}	9.38671×10^{-4}	9.28565×10^{-3}

训练结束后用固定模型重新评价全部 1000 条终态，以 s 归一化的完整场 MSE 为 1.07591×10^{-6}。它与表 9 的数据损失统计对象及定义不同：前者使用最终参数，对完整参考场计算平方误差；后者记录更新过程中相对于投影系数标签的相对 L^2 损失。

预测结果。 固定测试初值在 t=1 的相对 L^2 误差为 0.03180%，最大绝对误差为 4.99375×10^{-6}，均方根误差为 2.52269×10^{-6}；200 条测试初值的平均相对 L^2 误差为 0.11062%。0.25、0.5、0.75 三个时刻的结果补充了同一模型的中间演化检查。

固定样本的相对 L^2 误差以 FP 较小，200 条测试初值的平均相对 L^2 误差以 FNO 较小。两种方法的训练目标和快照使用方式不同；本报告没有多随机种子重复或结构消融，不能将误差差异单独归因于某一部分。

核查与适用范围。 本次核查训练初值、测试初值及同一时刻参考标签的一致性，并检查训练、预测与物理残差中的数值有限性。固定测试初值与所有训练样本均不相同，最近训练样本的离散向量距离约为 1.96858。

随机物理配点反复使用训练初值，不构成额外的独立测试集。200 条保留初值才用于测试。模态截断、数据与物理约束的权衡、有限训练轮数以及参考标签离散误差都会影响结果；没有连续精确解验证、网格收敛或分布外测试，不能推出普遍精度保证。

结论。 本算例保留粘性 Burgers 方程及与 FNO 相同的随机初值分布。FNO 将初始场和时间映射为修正场，POD 投影与扩散结构将其组合成降阶系数，再重建空间解；训练目标为终态系数相对误差与降阶物理残差之和。当前实验的精度判断应同时依据固定样本和 200 条测试样本的误差。

7. FNO与FNO-PRNN的优缺点比较

本章比较前文两种具体实现。它们求解同一个周期粘性 Burgers 方程，粘性系数为 0.1，空间取 256 点，使用相同的 1000 条随机初值及有限差分终态，并在相同的 200 条保留初值上测试。图示初值均取测试集第一条。以下将结构特点与已有实验结果分开列出。

表 10 两种方法的结构与训练方式

比较项目	纯 FNO	FNO-PRNN
训练信息	使用 1000 对初始场与终态场；网络只拟合终态标签。	使用相同的 1000 对数据，另保存 21000 个训练快照构造 POD 基；随机时刻的物理残差不需要对应解标签。
输入与输出	输入整条 256 点初始曲线，输出归一化终态，乘回尺度后得到 t=1 的 256 点场值。	输入初始曲线和查询时间，输出 12 个降阶系数，再重建 256 点场值；在 $0 \leqslant t \leqslant 1$ 内可以查询不同时间。
网络与表示	四个 Fourier 块、64 通道、谱分支保留 16 个频率；直接输出场值，无固定 POD 子空间限制。	使用相同宽度和深度的 Fourier 主干，增加时间通道、POD 投影和扩散衰减结构；最终解限制在 12 维固定空间中。
损失与物理约束	终态场值的逐样本相对 L^2 误差平均。方程通过数值标签提供信息，训练中不计算方程残差。	终态投影系数的相对 L^2 数据损失与归一化降阶残差平方损失相加，权重均为 1；残差约束半离散降阶方程。
初值与周期结构	谱运算适应周期网格；本模型只预测 t=1，没有显式初值约束。	周期差分和固定基表示周期结构；t=0 的重建场等于初值的 POD 投影，对当前多频初值存在截断误差。
实现与计算步骤	训练只需终态前向计算和误差反向传播；按实数分量计有 549505 个参数。	还需构造降阶基与方程系数、计算时间导数和物理残差；有 549569 个实参数。12 维输出并未使 FNO 主干明显缩小。

两者均使用 Adam 训练 500 轮，批量为 20，初始学习率为 0.001，每 100 轮减半，权重衰减为 0.0001，均无验证集或早停。相同轮数不代表相同计算成本：FNO-PRNN 每次更新的计算内容更多。

本次 GPU 完整训练阶段的实测耗时分别约为 FNO 162.4 秒、FNO-PRNN 496.2 秒，计时包含 500 轮的前向、反向、更新与日志，不含数据准备及训练后评价。这是一次顺序运行的实际耗时，包含首次计算准备和设备状态影响，不作为稳定加速比或与传统求解器的速度结论。

表 11 同一固定测试初值在 t=1 的预测误差

评价指标	纯 FNO	FNO-PRNN
相对 L^2 误差	0.05837%	0.03180%
最大绝对误差	1.03697×10^{-5}	4.99375×10^{-6}
均方根误差	4.63027×10^{-6}	2.52269×10^{-6}

表 11 汇总表 1 和表 8 的本次数值，均相对于同一个 256 点参考终态计算。200 条测试初值的平均相对误差分别为 0.09421% 和 0.11062%。固定样本的相对 L^2 误差以 FP 较小，200 条测试初值的平均相对 L^2 误差以 FNO 较小。该比较反映当前完整实现与训练设置，不能单独说明物理约束或 POD 对精度的影响。

表 12 主要优点、缺点与本算例中的取舍

比较项目	纯 FNO	FNO-PRNN
主要优点	输入输出直接，训练目标单一，程序较简洁；不需要保存中间快照或构造降阶方程；输出不受固定 12 维基限制。	同一模型可查询不同时间；降阶系数给出明确的空间表示；初始投影、已知扩散衰减和方程残差都参与约束预测。
主要缺点	当前模型仅学习 t=1 的映射，无法直接给出中间演化；没有显式残差约束动力学，精度依赖终态标签及其覆盖范围。	步骤和调节因素更多，需选取降阶维数及物理损失尺度；截断限制可表示的解，当前复杂初值不能被完整保留。
当前任务中的取舍	若只评价图示终态相对误差，本次 FNO-PRNN 较低；若评价 200 条测试初值的平均相对误差，本次 纯 FNO 较低。	若需要查询不同时间并显式约束降阶动力学，该实现具备这些功能；采用时仍需核查各时刻的误差及初值投影误差。

时间预测的证据。 同一个 T=1 的 FNO-PRNN 模型在图示初值的 t=0.25、0.5、0.75 时刻，相对 L^2 误差分别为 0.66446%、1.07324%、1.17454%。这些结果补充中间时刻检查；t=0 结果是投影重建，不能作为未知解的预测成绩。

比较边界。 两种方法使用的训练信息和目标并不完全相同，FNO-PRNN 额外利用中间快照。其系数数据损失与物理总损失、逐轮平均与 FNO 的最后小批次 MSE 不能直接比较。200 条测试初值只支持当前分布下的评价，尚无多种子统计或结构消融来分离各部分影响。

结论。 纯 FNO 的优势是实现简洁且输出不受固定降阶空间限制；FNO-PRNN 的优势是能查询时间，并把降阶表示与物理约束纳入求解。当前 t=1 实验中，图示样本相对误差以 FNO-PRNN 较低，测试集平均相对误差以 纯 FNO 较低；更多建模功能本身不能作为精度更高的证据。

8. 不同终止时刻的补充数值实验

本节在前七部分的基础上，补充 T=0、0.25、0.5、0.75 的实验，并列入 T=1 的结果作为对照。FNO-PRNN 以下简称 FP。重点考察改变终止时刻后，两种实现对同一固定测试初值及 200 条保留测试初值的预测误差与训练表现；方程、网络结构与损失函数的已有推导不再重复。

8.1 实验设置与时间参数的含义

共同条件。 方程、周期边界及初值分布沿用第 1 节与第 6.1 节：粘性系数为 0.1，空间区域为 [0,1)，采用 256 个网格点和 0.00005 的积分步长。训练初值为同一批 1000 条随机周期曲线，测试初值为另外同一批 200 条曲线；图示固定取测试集第一条。

每个脚本从头初始化并训练 500 轮，批量为 20；Adam 的初始学习率为 0.001，每 100 轮减半，权重衰减为 0.0001。数据与网络参数的随机种子为 0，FP 的时间采样种子为 1。没有验证集，采用最后一轮模型；同一方法的网络宽度、频率数、POD 秩及损失权重均保持相同设置。

独立训练的终点任务。 T 是该份代码的数据积分终点和监督时刻。每种方法分别训练五个模型，共十次训练，而非让原 T=1 模型直接查询五个时刻。因此，本节的 FP 中间终点结果与第 6 节表 8 的多时刻查询结果属于不同实验。

表 13 不同终止时刻对应的数据规模与标签尺度

终止时刻 T	积分步数	每条初值的快照数	FP 快照总数	终态标准差 s(T)
0	0	1	1000	0.58944821
0.25	5000	6	6000	0.19198099
0.5	10000	11	11000	0.06998504
0.75	15000	16	16000	0.02599472
1	20000	21	21000	0.00968339

两种方法在每个 T 下都使用 1000 对初值与该时刻参考场。FP 每隔 0.05 保存一次快照，并包含初值；这些快照用于重新构造该区间的 POD 基。快照总数不是独立初值的数量。随着 T 改变，终态标签、标签标准差和 FP 的降阶基也随之重新计算。

输入、输出与损失。 FNO 仍输入 256 点初始场，输出归一化的 T 时刻场值并乘回 s(T)，采用逐样本相对 L^2 损失。FP 仍输入初始场与时间，输出 12 个系数并重建空间场；相对系数数据项在 t=T 计算，物理配点时间范围为 [0,T]，两项权重均为 1。其余分别沿用第 2-4 节和第 6.2-6.4 节。

同一方法的五份脚本仅 T 的显式设置不同。T 同时改变所学习的终点映射、FP 快照区间及物理采样区间，这是时间参数变化的派生结果。两种方法之间还存在表示空间、损失和快照用途的结构差异，不能表述为十份代码除 T 外全部相同。

8.2 误差指标与数值结果

沿用第 5 节的相对 L^2 误差、最大绝对误差和均方根误差，统一在原始 256 个空间点上计算；另列出 200 条测试初值的平均相对 L^2 误差。所有指标由十份脚本完整训练后保存的原尺度预测与参考数组计算；同一 T 下，两种方法的参考场一致。参考场仍为有限差分离散解。

表 14 各终止时刻的预测误差（每行对应独立训练的模型）

时刻 T	方法	固定样本相对 L^2	最大绝对误差	均方根误差	测试集平均相对 L^2
0	FNO	0.13248%	1.0591×10^{-3}	5.9398×10^{-4}	0.12997%
0	FP	7.38683%	8.1159×10^{-2}	3.3119×10^{-2}	6.84787%
0.25	FNO	0.04719%	2.2608×10^{-4}	7.2977×10^{-5}	0.09950%
0.25	FP	0.09967%	2.4956×10^{-4}	1.5414×10^{-4}	0.14085%
0.5	FNO	0.13624%	1.4215×10^{-4}	7.7915×10^{-5}	0.12885%
0.5	FP	0.10497%	1.2821×10^{-4}	6.0036×10^{-5}	0.13759%
0.75	FNO	0.03758%	2.8968×10^{-5}	7.9999×10^{-6}	0.11979%
0.75	FP	0.09943%	3.2870×10^{-5}	2.1165×10^{-5}	0.13460%
1	FNO	0.05837%	1.0370×10^{-5}	4.6303×10^{-6}	0.09421%
1	FP	0.03180%	4.9938×10^{-6}	2.5227×10^{-6}	0.11062%

初始时刻。 T=0 时，FNO 的固定样本相对 L^2 误差为 0.13248%，FP 为 7.38683%。此时参考场就是已知初值；两者分别采用学习恒等映射和结构性初值投影，不能将这一差距理解为对未知演化解的预测优势。

正时间终点。 按 T=0.25、0.5、0.75、1 的顺序，固定样本相对误差较小的方法分别为 FNO、FP、FNO、FP；测试集平均相对误差较小的方法分别为 FNO、FNO、FNO、FNO。单一样本与测试集平均应分别判断，四个独立终点任务也不足以给出连续时间区间的精度保证。

T=1 行与前文第 5、6、7 节使用同一批完整训练结果，数值、图形和文字同步更新。不同硬件、PyTorch 版本或计算顺序可能造成浮点及训练轨迹差异；本表对应本次已保存的运行记录。

图形组织。 初始曲线在各脚本中相同，故不重复展示。图 3-6 将同一终点的两种预测和误差直接放在一起，损失则各占一个子图。曲线使用原始网格点连接；不同损失图的纵轴范围由各自数据决定，不通过曲线高度直接比较两种训练目标。

8.3 不同终止时刻的图形对比

8.3.1 T=0：初值重建

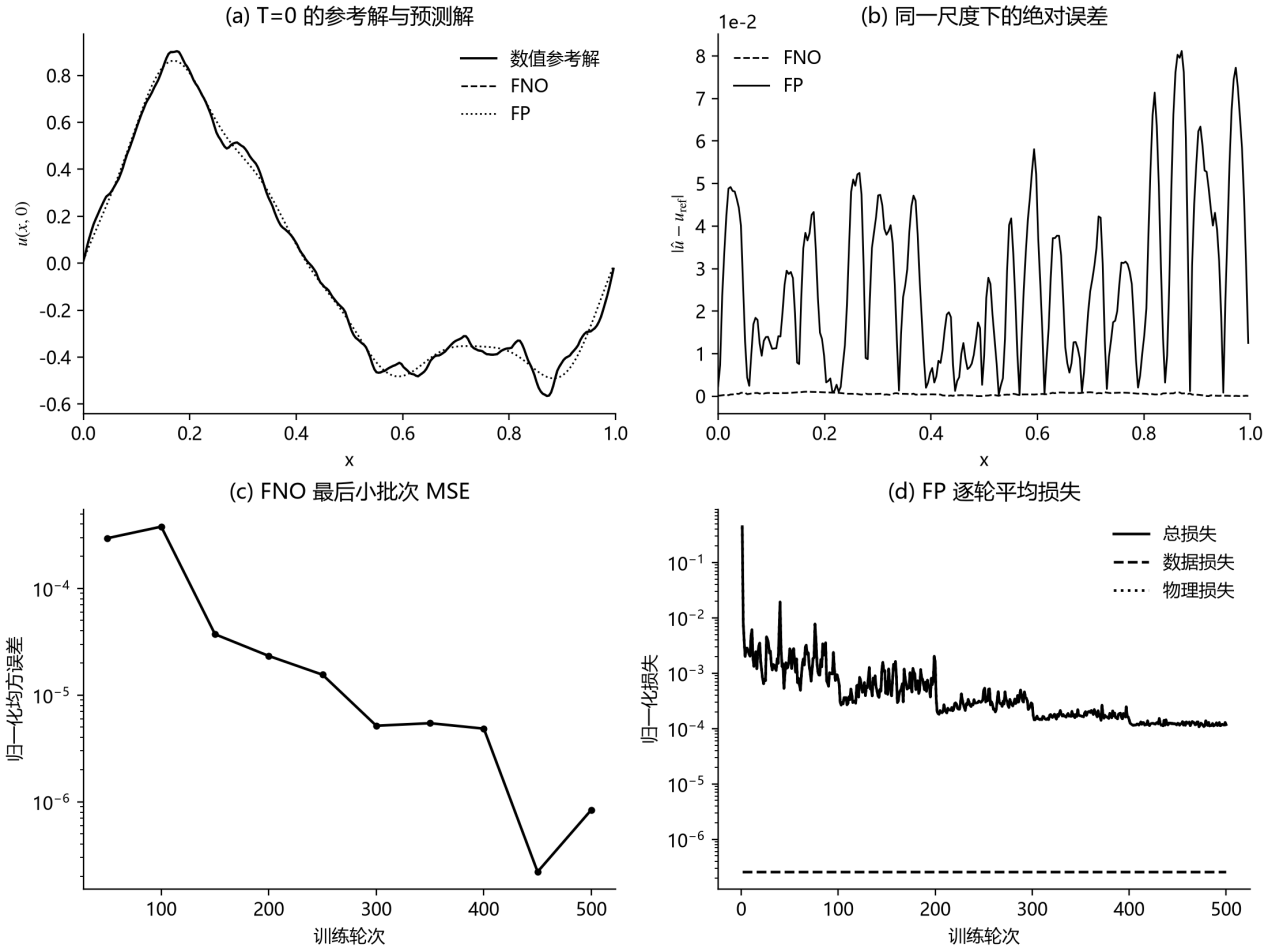


图 3 T=0 时两种方法的对比。（a）参考解与预测解；（b）同一纵轴尺度下的逐点绝对误差；（c）FNO 每 50 轮记录的最后小批次 MSE；（d）FP 每轮平均的总损失、数据损失和物理损失。后两图采用对数纵轴。

重建结果。 FNO 的最大绝对误差为 1.059×10^{-3}，FP 为 8.116×10^{-2}。固定样本的相对 L^2 误差以 FNO 较小，200 条测试初值的平均相对 L^2 误差以 FNO 较小。本次初值包含 127 个非零波数，FP 只保留 12 个基函数，初始重建误差已不能解释为单纯浮点误差。

FNO 此时以初值本身作为监督标签，需要通过参数训练近似实现“输入等于输出”。FP 的时间修正因子在零时刻消失，输出系数直接等于初始投影系数，因此网络训练不能消除该固定子空间之外的初始分量。这是输出表示的限制，不是预测未来造成的误差。

损失的含义。 FP 第 500 轮的数据损失为 2.580×10^{-7}，物理损失为 1.170×10^{-4}。数据项只比较投影系数，所以即使它很小，完整初值仍可存在截断误差。T=0 时所有物理配点都位于初始时刻，约束该处的瞬时降阶导数；本实验不能检验一段时间内的动力学预测。

8.3.2 T=0.25：较早终点的预测

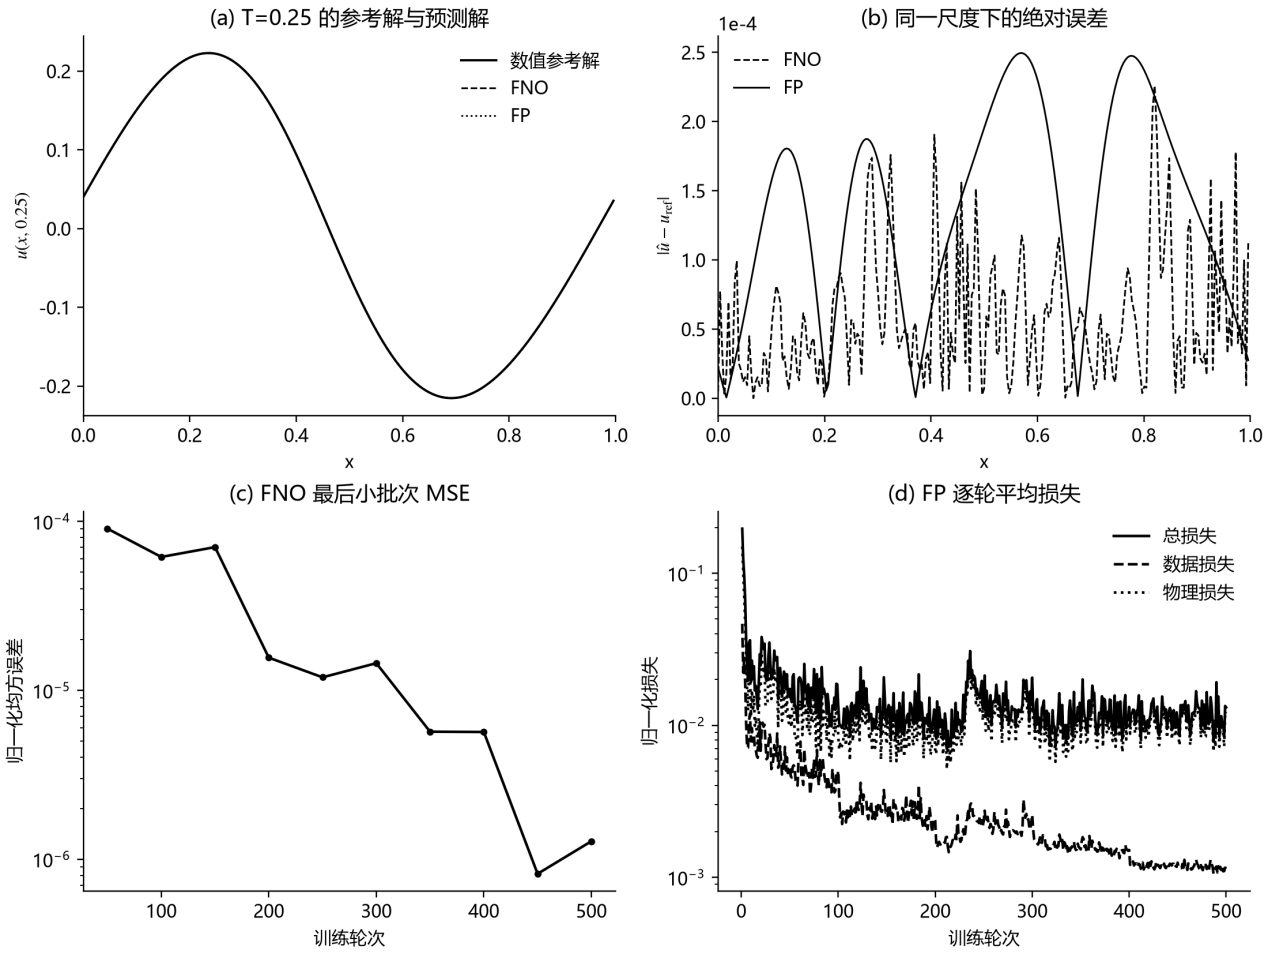


图 4 T=0.25 时两种方法的对比。（a）参考解与预测解；（b）同一纵轴尺度下的逐点绝对误差；（c）FNO 每 50 轮记录的最后小批次 MSE；（d）FP 每轮平均的总损失、数据损失和物理损失。后两图采用对数纵轴。

预测结果。 FNO 与 FP 的固定样本相对 L^2 误差分别为 0.04719% 和 0.09967%；最大绝对误差分别为 2.261×10^{-4} 和 2.496×10^{-4}。200 条测试初值的平均相对误差分别为 0.09950% 和 0.14085%。

该时刻图示参考场的最大绝对幅值约为 0.22294。解曲线的视觉重合程度和绝对误差需要结合场值尺度理解；表 14 同时列出相对误差，避免仅凭解曲线作判断。固定样本的相对 L^2 误差以 FNO 较小，200 条测试初值的平均相对 L^2 误差以 FNO 较小。

训练表现。 两种模型均完成 500 轮训练。FNO 第 500 轮最后小批次 MSE 为 1.277×10^{-6}；FP 该轮平均总损失为 1.311×10^{-2}，数据损失为 1.140×10^{-3}，物理损失为 1.197×10^{-2}。这些损失的定义和统计口径不同，不能直接据此给预测精度排名。

8.3.3 T=0.5：中间终点的预测

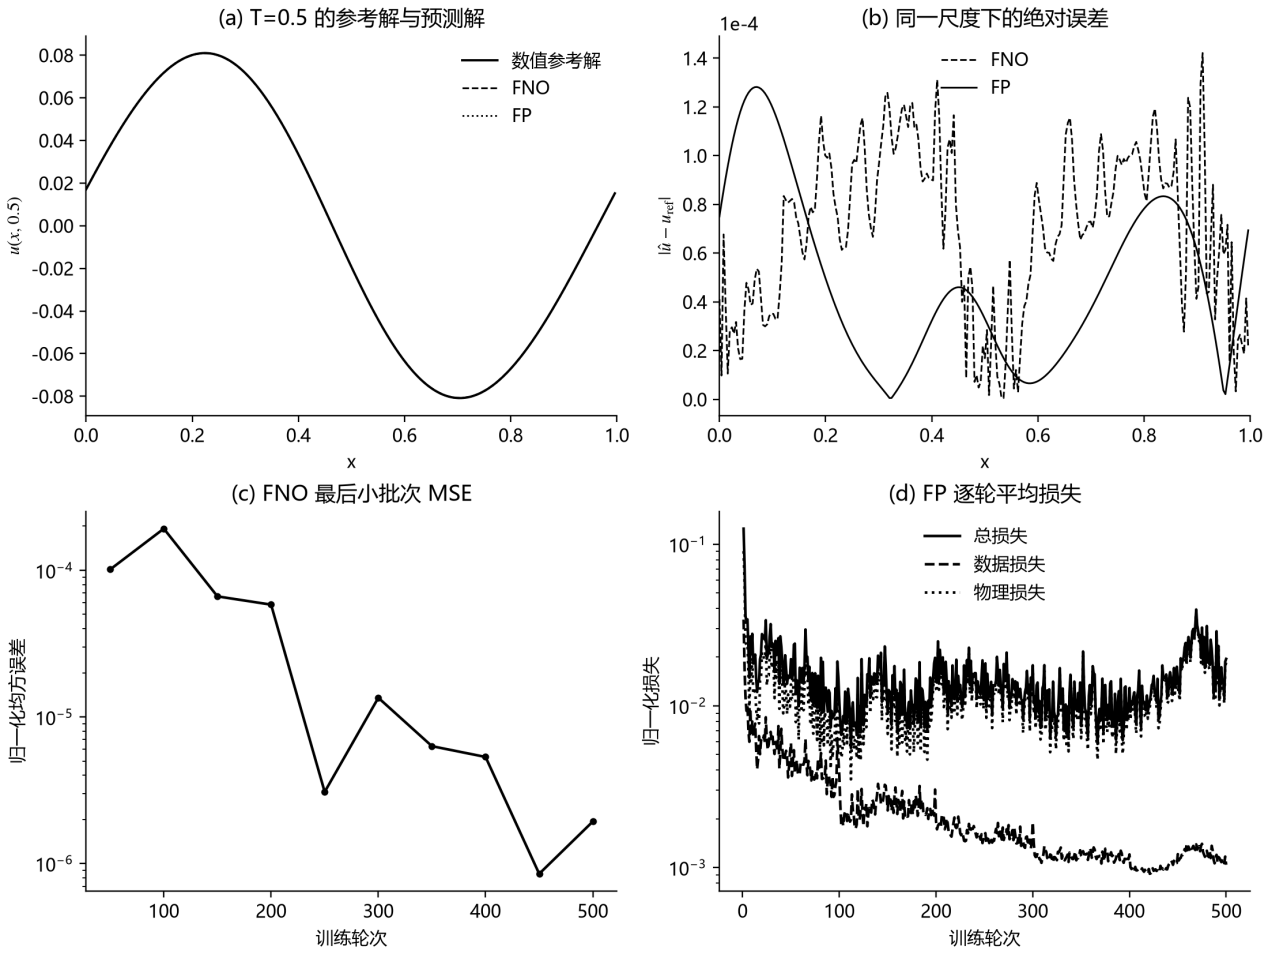


图 5 T=0.5 时两种方法的对比。（a）参考解与预测解；（b）同一纵轴尺度下的逐点绝对误差；（c）FNO 每 50 轮记录的最后小批次 MSE；（d）FP 每轮平均的总损失、数据损失和物理损失。后两图采用对数纵轴。

预测结果。 FNO 与 FP 的固定样本相对 L^2 误差分别为 0.13624% 和 0.10497%；最大绝对误差分别为 1.421×10^{-4} 和 1.282×10^{-4}。200 条测试初值的平均相对误差分别为 0.12885% 和 0.13759%。

该时刻图示参考场的最大绝对幅值约为 0.08099。解曲线的视觉重合程度和绝对误差需要结合场值尺度理解；表 14 同时列出相对误差，避免仅凭解曲线作判断。固定样本的相对 L^2 误差以 FP 较小，200 条测试初值的平均相对 L^2 误差以 FNO 较小。

训练表现。 两种模型均完成 500 轮训练。FNO 第 500 轮最后小批次 MSE 为 1.933×10^{-6}；FP 该轮平均总损失为 1.951×10^{-2}，数据损失为 1.040×10^{-3}，物理损失为 1.847×10^{-2}。这些损失的定义和统计口径不同，不能直接据此给预测精度排名。

8.3.4 T=0.75：较晚终点的预测

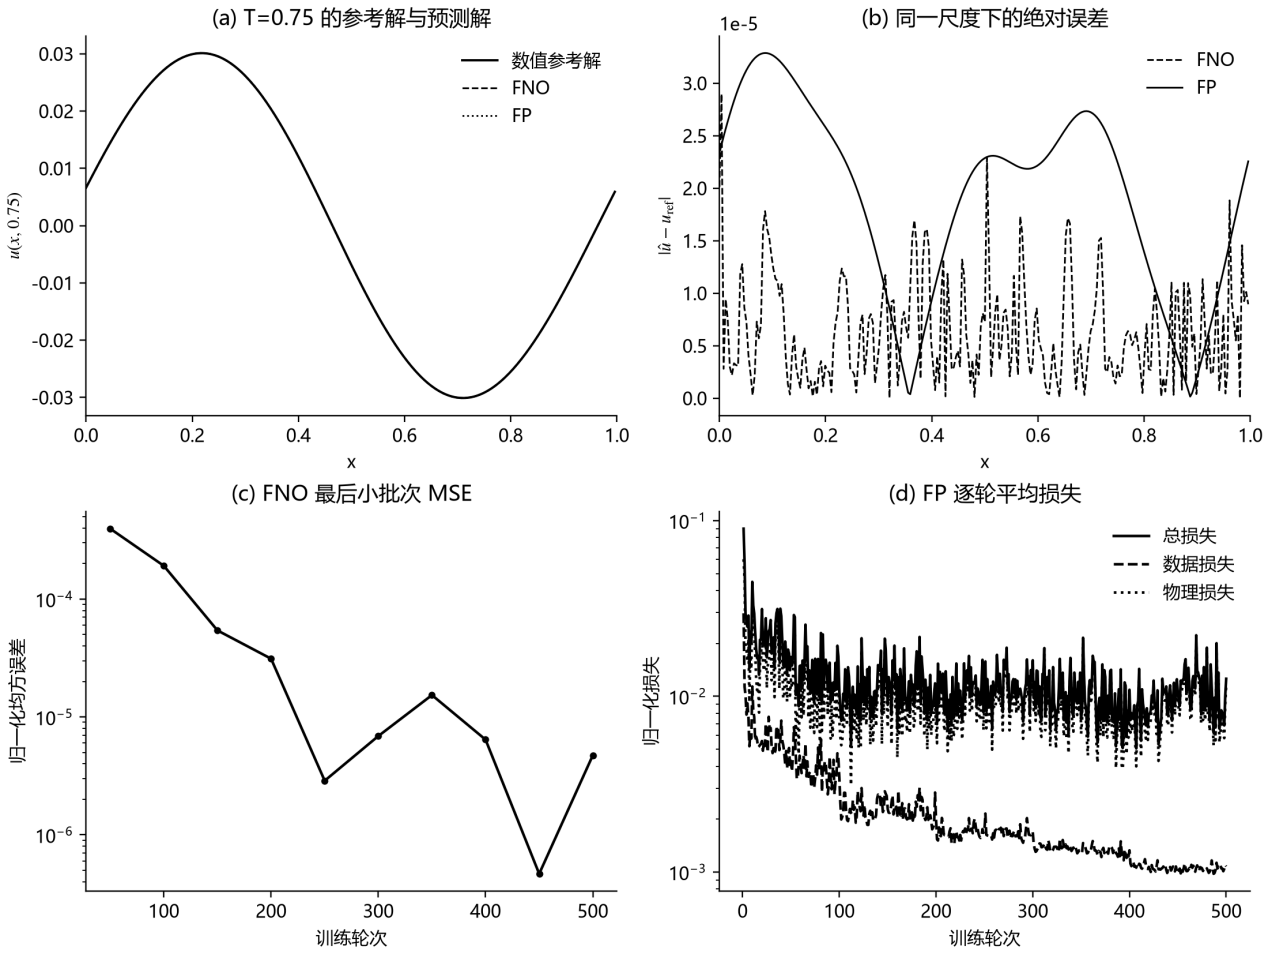


图 6 T=0.75 时两种方法的对比。（a）参考解与预测解；（b）同一纵轴尺度下的逐点绝对误差；（c）FNO 每 50 轮记录的最后小批次 MSE；（d）FP 每轮平均的总损失、数据损失和物理损失。后两图采用对数纵轴。

预测结果。 FNO 与 FP 的固定样本相对 L^2 误差分别为 0.03758% 和 0.09943%；最大绝对误差分别为 2.897×10^{-5} 和 3.287×10^{-5}。200 条测试初值的平均相对误差分别为 0.11979% 和 0.13460%。

该时刻图示参考场的最大绝对幅值约为 0.03011。解曲线的视觉重合程度和绝对误差需要结合场值尺度理解；表 14 同时列出相对误差，避免仅凭解曲线作判断。固定样本的相对 L^2 误差以 FNO 较小，200 条测试初值的平均相对 L^2 误差以 FNO 较小。

与原终点的联系。 T=1 时固定样本的 FNO 与 FP 相对误差分别为 0.05837% 和 0.03180%。本节各终点模型独立训练，标签尺度、FP 快照及物理采样区间随 T 改变；这些预测场不能直接拼接为同一模型的时间轨迹。

8.4 训练记录与综合比较

表 15 第 500 轮的损失记录

终止时刻 T	FNO MSE	FP 总损失	FP 数据损失	FP 物理损失
0	8.4218×10^{-7}	1.1729×10^{-4}	2.5795×10^{-7}	1.1703×10^{-4}
0.25	1.2769×10^{-6}	1.3114×10^{-2}	1.1405×10^{-3}	1.1974×10^{-2}
0.5	1.9329×10^{-6}	1.9514×10^{-2}	1.0405×10^{-3}	1.8473×10^{-2}
0.75	4.7256×10^{-6}	1.2593×10^{-2}	1.0772×10^{-3}	1.1516×10^{-2}
1	7.7686×10^{-7}	1.0224×10^{-2}	9.3867×10^{-4}	9.2857×10^{-3}

FNO 列为该轮最后一个小批次的 MSE，FP 各列为该轮 50 个小批次的平均；它们均不是验证误差。表 15 用于补充训练记录，预测精度以表 14 为准。FP 的物理损失约束降阶方程，数值较小不等于完整参考场误差必然更小。

表 16 补充实验对两种方法优缺点的说明

比较方面	FNO	FP
初值保持	T=0 时通过数据监督学习恒等映射，本次固定样本相对误差为 0.13248%。	初始投影由输出结构保证，但 12 维基不能完整保留当前多频初值；本次固定样本误差为 7.38683%。
正时间精度	直接拟合完整终态场，不受固定 POD 子空间限制；实际精度由表 14 的同一指标比较。	物理约束和降阶表示提供额外结构，但是否提高精度需分别检查固定样本和测试集平均误差。
物理信息	只监督对应终点的场值，没有显式约束中间动力学。	同时约束终点数据和 [0,T] 内的降阶残差，提供了额外的物理训练目标。
本节评价范围	每个终点单独训练；本节没有构造单一时间条件 FNO。	虽然模型含时间输入，本节仍逐终点重新训练；同一 T=1 模型的多时刻查询另见表 8。

结果边界。 以上针对同一固定测试初值及 200 条同分布测试初值、单个随机种子和同一离散参考求解器。没有权重或结构消融、多随机种子统计与分布外测试，不能将误差差距单独归因于物理损失，也不能推断一般情况下的效率与泛化能力。

结论。 补充实验将初值重建与正时间预测区分开来。正时间终点中，固定样本相对误差较小的方法为 T=0.25：FNO、T=0.5：FP、T=0.75：FNO、T=1：FP；测试集平均相对误差较小的方法为 T=0.25：FNO、T=0.5：FNO、T=0.75：FNO、T=1：FNO。FP 提供初始投影和降阶动力学约束，但“初值投影准确”与“完整初值准确”不同，更多物理结构也不自动保证更低的测试误差。

9. PRNN 求解粘性 Burgers 方程

本章补充独立 PRNN 的五个终点实验，沿用前文的方程、训练数据、测试初值和训练设置。每个终止时刻分别从头训练一个模型，取 T=0、0.25、0.5、0.75、1；所有结果来自对应 Python 程序完整训练 500 轮后的实际输出。

9.1 方法定义与保持不变的实验条件

本报告中 PRNN 的具体含义。 在既有 FNO-PRNN（简称 FP）实现中，保留 POD 降阶、初始投影约束、已知扩散衰减结构，以及“终态数据＋降阶物理残差”的联合损失；仅将 FNO 主干替换为普通全连接神经网络。仍输入完整的 256 点初始场与查询时间，不将输入改成仅含 12 个初始系数。

这里的 PRNN 指上述物理约束降阶网络，具体结构与训练目标以下文公式和代码为准。它没有 Fourier 神经算子层，也不是循环神经网络；它仍使用终态监督数据，不能称为无数据训练。

$$\partial_t u + \partial_x(u^2/2) = 0.1\partial_{xx}u, \qquad x \in [0,1), \quad 0 < t \le T$$

$$u(x,0) = u_0(x), \qquad u(x+1,t) = u(x,t)$$

表 17 PRNN 与现有实验保持一致的设置

项目	保持的设置
初值与数据划分	127 个非零 Fourier 波数的随机初值，系数分布同第 1 节；前 1000 条训练，后 200 条测试，随机种子 0。
测试函数	图示仍取同一测试集第一条随机曲线，即第 1001 条初值；未更换为另一条函数，也未加入训练集。
空间与时间离散	256 个周期网格点；Δx=1/256，Δt=0.00005；使用同一显式 Euler 与周期中心差分参考求解器。
POD 与方程系数	每隔 0.05 保存训练快照，包含初值；周期平移平均、12 维基和 Galerkin 系数的构造同 FP。
训练设置	500 轮，批量 20；Adam，初始学习率 0.001，权重衰减 0.0001；每 100 轮学习率减半。
损失与物理采样	相对系数数据项＋归一化残差平方项，权重均为 1；时间在 [0,T] 均匀采样，独立时间随机种子 1。
选模与运行	无验证集、早停或额外调参，使用第 500 轮模型；同一 CUDA 环境与 GPU，CPU 4 线程准备数据。

本次逐一核对了五个时刻的训练初值、测试初值、终态参考场、POD 基、扩散特征值及对流系数，它们与已保存的对应 FP 实验数组完全一致。FNO 的同一时刻参考场也一致。

9.2 输入输出与神经网络结构

将完整初始场的 256 个值按网格顺序排列，再接上一个查询时间，组成 257 维输入。时间只输入一次。网络生成 256 点修正场，再沿用 FP 的投影和系数组合得到 12 个预测系数，最后重建物理场。

$$z = (u_0(x_0), \ldots, u_0(x_{255}), t) \in \mathbb{R}^{257}$$

$$z \longmapsto g_\theta(u_0, t) \in \mathbb{R}^{256} \longmapsto \hat{a}(t) \in \mathbb{R}^{12} \longmapsto \hat{u}(t) \in \mathbb{R}^{256}$$

表 18 独立 PRNN 的可训练主干及固定输出结构

组成	具体设置	作用
输入提升	全连接线性层 257→64，含偏置。	将整条初值与时间变成 64 个隐特征。
四个隐藏层	每层 64→64，含偏置；每层后使用 ReLU。	通过四次非线性变换学习初值和时间对修正场的影响。
输出头	64→128，经 ReLU 后 128→256；含偏置。	输出 256 点修正场 g_θ。
POD 投影	$c_{\theta,i} = \langle g_\theta, \Phi_i \rangle_h$，i=1,…,12。	投影到与 FP 相同的固定降阶空间。
系数组合与重建	保留初始投影、扩散指数项及时间修正因子。	返回 12 个预测系数，并与固定基组合成 256 点预测场。

$$v_0 = A_0 z + b_0, \qquad v_{\ell+1} = \mathrm{ReLU}(A_{\ell+1} v_\ell + b_{\ell+1}), \quad \ell = 0, 1, 2, 3$$

$$g_\theta = A_6 \mathrm{ReLU}(A_5 v_4 + b_5) + b_6$$

A 和 b 分别为可训练的权重矩阵与偏置，ℓ 为隐藏层编号。这里 64 个特征属于整个输入向量，而 FP 的 64 个通道分别保存在每个空间点上；同样的宽度数值不意味着两个主干具有相同的表示方式或参数量。

参数量为 (257×64+64)+4(64×64+64)+(64×128+128)+(128×256+256)=74496，全部为实数。没有 FFT、复权重或保留频率设置；原来的模式数 16 对全连接主干不适用。POD 秩 12、四个宽度 64 的隐藏层、128 的输出头宽度和 ReLU 均保留。

选择理由。 全连接网络能够直接组合完整初值的各网格分量，提供不含谱层的对照；POD、初值约束与物理损失保持一致，便于考察主干替换后的结果。该网络绑定当前 256 点输入输出，未包含 FNO 的谱卷积结构和相同的空间平移性质，也不能直接据此主张跨网格能力。

9.3 初值约束、损失函数与训练方法

离散内积、基函数 Φ_i、扩散特征值 λ_i 与对流系数 Q_{ijk} 沿用第 6 节。将初始场和修正场分别投影为系数，预测仍为：

$$a_{0,i} = \langle u_0, \phi_i \rangle_h, \qquad c_{\theta,i} = \langle g_\theta, \phi_i \rangle_h$$

$$\hat{a}_i(u_0, t) = a_{0,i} e^{\lambda_i t} + (1 - e^{-\beta t}) e^{-\beta t} c_{\theta,i}(u_0, t)$$

$$\hat{u}(x, t) = \sum_{i=1}^{12} \hat{a}_i(t) \phi_i(x), \qquad \beta = \frac{4\nu \sin^2(\pi/256)}{\Delta x^2}$$

t=0 时修正项消失，预测场等于 $P_{12}u_0$，即初值在该 12 维空间中的投影。此约束只保证投影初值，不保证完整初值被逐点复制；换用全连接主干不改变这一表示限制。

每批 B=20 条初值。终态参考系数由同一参考场投影得到，数据损失为逐样本相对系数误差的平均：

$$\mathcal{L}_{\text{data}} = \frac{1}{B} \sum_{b=1}^{B} \frac{\|\hat{\boldsymbol{a}}(u_0^{(b)}, T) - \boldsymbol{a}_{\text{ref}}^{(b)}(T)\|_2}{\max(\|\boldsymbol{a}_{\text{ref}}^{(b)}(T)\|_2, 10^{-12})}$$

相对归一化按各标签自身幅值衡量偏差。比较对象是投影系数而非完整场；未保留模态的误差仍需在测试时通过完整场指标评价。终态标准差 s 继续计算，但不参与 PRNN 的损失或预测重建。

$$r_i(u_0, t) = \partial_t \hat{a}_i - \lambda_i \hat{a}_i - \sum_{j=1}^{12} \sum_{k=1}^{12} Q_{ijk} \hat{a}_j \hat{a}_k$$

$$\mathcal{L}_{\text{phys}} = \frac{1}{B} \sum_{b=1}^{B} \sum_{i=1}^{12} \left[\frac{r_i(u_0^{(b)}, t_b)}{\beta s_0 e^{-\beta t_b}} \right]^2, \quad t_b \sim \mathcal{U}(0, T)$$

$$\mathcal{L} = \mathcal{L}_{\text{data}} + \mathcal{L}_{\text{phys}}$$

s_0 是训练初值的全局均方根，本次为 0.58944708。时间导数采用自动微分，其他残差系数均固定；每个批次为各初值重采一个时刻。数据项提供终态监督，物理项约束区间内的降阶动力学，其尺度及两项权重均沿用 FP，未为新方法重新优化。

每轮随机打乱 1000 个训练样本，分成 50 批；500 轮共更新 25000 次，并抽取 500000 个初值-时间对。每轮保存三个损失的批次平均，四格图展示全部 500 轮，日志每 50 轮打印一次。

T=0 时所有物理采样点都在初始时刻，数据目标是已知初值的投影；此时训练只可能调整初始瞬时动力学，不能改变固定投影重建。损失、梯度和预测均已检查为有限数值。

9.4 五个终点的数值实验

评价口径与第 8 节一致。每个时刻单独初始化并训练，图示固定使用第 1001 条初值；相对 L^2、最大绝对误差和均方根误差均由原尺度的 256 点预测与同一有限差分参考解计算。测试集平均相对 L^2 先逐样本计算，再对 200 条曲线取平均。

表 19 独立 PRNN 在五个终止时刻的预测误差

T	固定样本相对 L^2	最大绝对误差	均方根误差	测试集平均相对 L^2
0	7.38683%	8.1159×10^{-2}	3.3119×10^{-2}	6.84787%
0.25	0.48120%	1.4809×10^{-3}	7.4420×10^{-4}	0.92581%
0.5	0.16357%	2.1395×10^{-4}	9.3549×10^{-5}	0.67861%
0.75	0.11965%	5.8020×10^{-5}	2.5470×10^{-5}	0.60033%
1	0.16307%	2.6112×10^{-5}	1.2935×10^{-5}	0.56055%

表 19 的五行来自五个不同模型；T 同时决定参考积分终点、快照区间和物理配点区间。它们不是同一个 T=1 模型的五次查询。对应的快照数和终态标准差仍与表 13 相同。

表 20 PRNN 第 500 轮的损失记录（该轮小批次平均）

T	总损失	数据损失	物理损失
0	4.1934×10^{-3}	2.5795×10^{-7}	4.1932×10^{-3}
0.25	3.1702×10^{-2}	3.9938×10^{-3}	2.7708×10^{-2}
0.5	2.4034×10^{-2}	2.8726×10^{-3}	2.1161×10^{-2}
0.75	1.9569×10^{-2}	2.4847×10^{-3}	1.7084×10^{-2}
1	1.8174×10^{-2}	2.3143×10^{-3}	1.5860×10^{-2}

总损失为后两项之和，显示时分别四舍五入可能产生末位差异。记录取训练更新过程中的逐批平均，并非最后模型的验证误差。物理损失衡量降阶方程残差，不能把它直接换算为完整场预测误差。

初值重建。 T=0 时固定样本相对误差为 7.38683%，200 条初值的平均误差为 6.84787%。这与 FP 使用相同投影空间的事实一致；误差并非只由浮点运算造成。

终态评价。 T=1 时，固定样本相对误差为 0.16307%，测试集平均相对误差为 0.56055%。训练结束后重新评价全部 1000 条终态，以 s 归一化的完整场 MSE 为 2.25086×10^{-5}；它与表 20 的投影系数相对损失不同。

以下五幅四格图由相应 PRNN 代码原有绘图段生成，采用黑白线型，分别显示初始场、终点解、逐点绝对误差以及三项训练损失。未对误差曲线平滑，也未换用另一个测试函数。

9.5 各时刻的四格图与结果说明

9.5.1 T=0 的 PRNN 求解结果

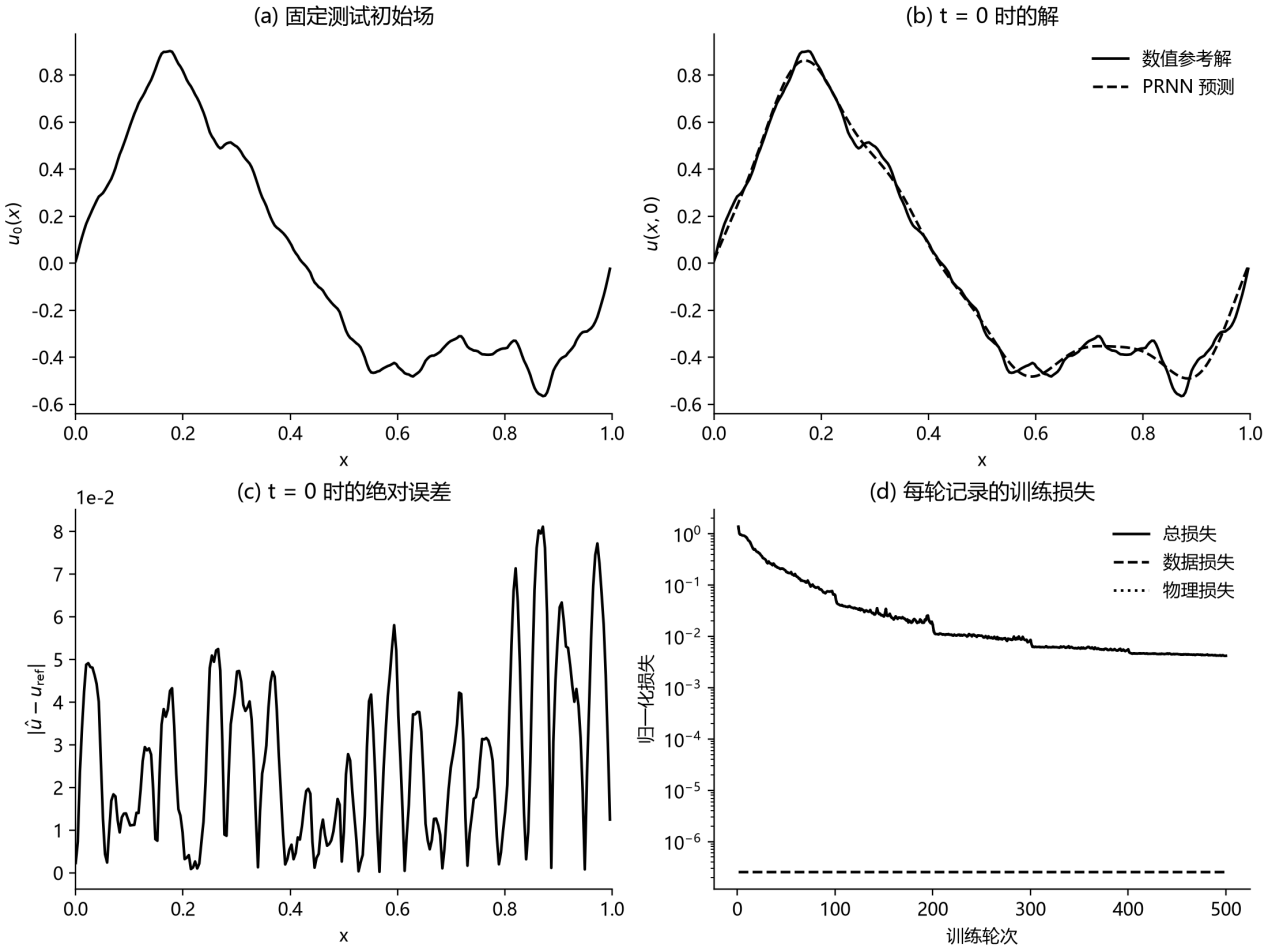


图 7 PRNN 在 T=0 时的四格图。（a）固定测试初始场；（b）该终点的参考解与预测解；（c）逐点绝对误差；（d）每轮平均的总损失、数据损失和物理损失，纵轴为对数。

预测结果。 固定样本相对 L^2 误差为 7.38683%，最大绝对误差为 8.1159×10^{-2}，均方根误差为 3.3119×10^{-2}；200 条测试初值的平均相对误差为 6.84787%。

参考场就是已知初始场，预测场为 $P_{12}u_0$。网络输出中的可训练修正项在 t=0 乘以零，故训练不能把固定降阶空间外的分量补回；初始曲线中的细节差距来自这一截断。

数据项比较相同投影下的 12 个系数，因此可接近零；物理项仍会约束初始瞬时导数。两者均不能使完整初值的重建误差自动消失。T=0 应视为表示能力检查，而非对未来未知解的预测。

9.5.2 T=0.25 的 PRNN 求解结果

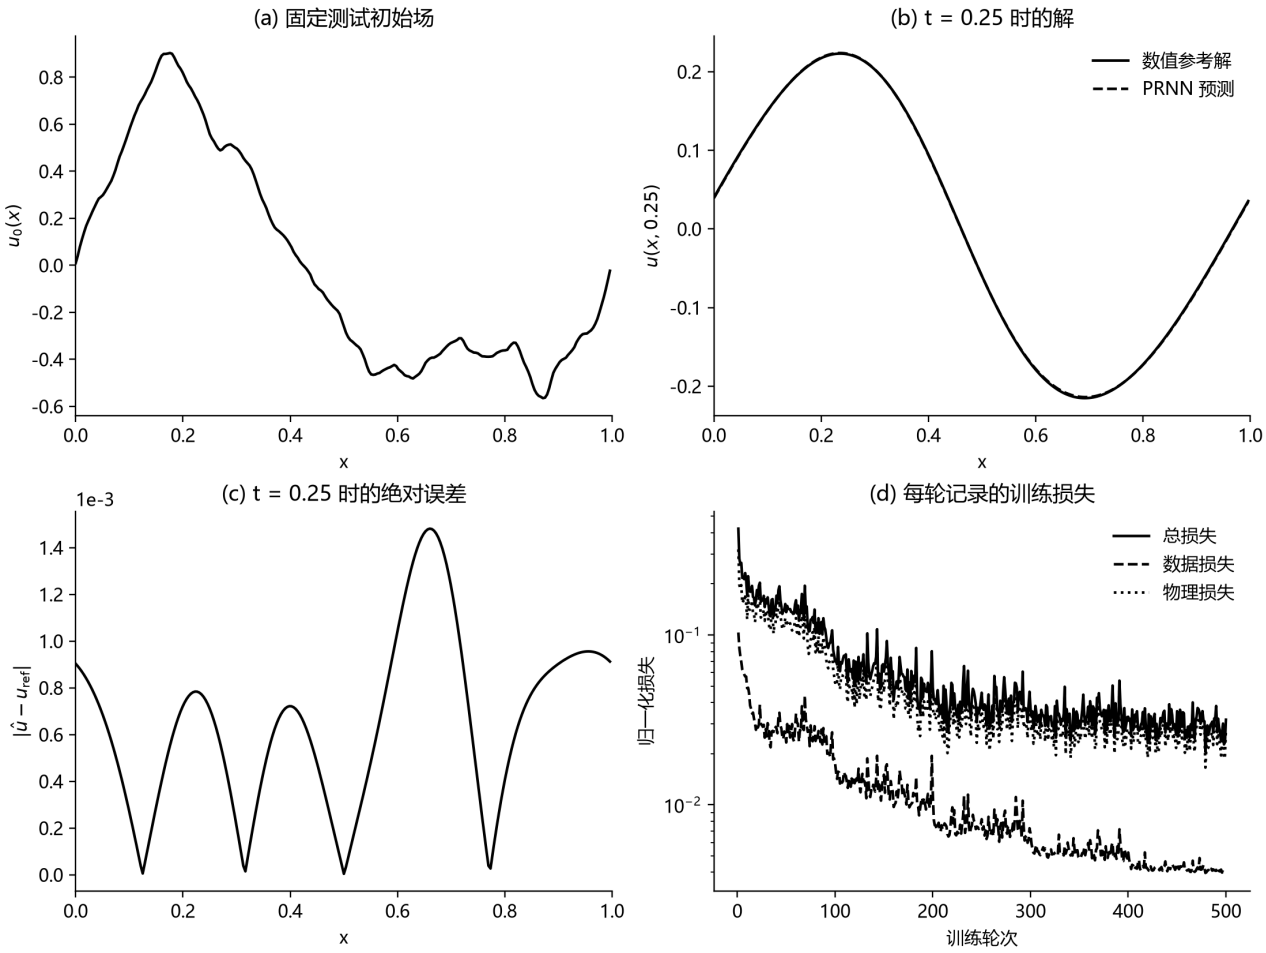


图 8 PRNN 在 T=0.25 时的四格图。（a）固定测试初始场；（b）该终点的参考解与预测解；（c）逐点绝对误差；（d）每轮平均的总损失、数据损失和物理损失，纵轴为对数。

预测结果。 固定样本相对 L^2 误差为 0.48120%，最大绝对误差为 1.4809×10^{-3}，均方根误差为 7.4420×10^{-4}；200 条测试初值的平均相对误差为 0.92581%。

图示参考场的最大绝对幅值为 2.2294×10^{-1}。解曲线的重合程度需结合场值尺度理解，表 19 同时给出相对与绝对指标；不能只看两条曲线是否重合。

训练记录。 两项权重和训练轮次未调整。第 500 轮平均总损失为 3.1702×10^{-2}，数据损失为 3.9938×10^{-3}，物理损失为 2.7708×10^{-2}。这些损失反映不同约束，预测精度仍以固定样本和独立测试集的误差为准。

9.5.3 T=0.5 的 PRNN 求解结果

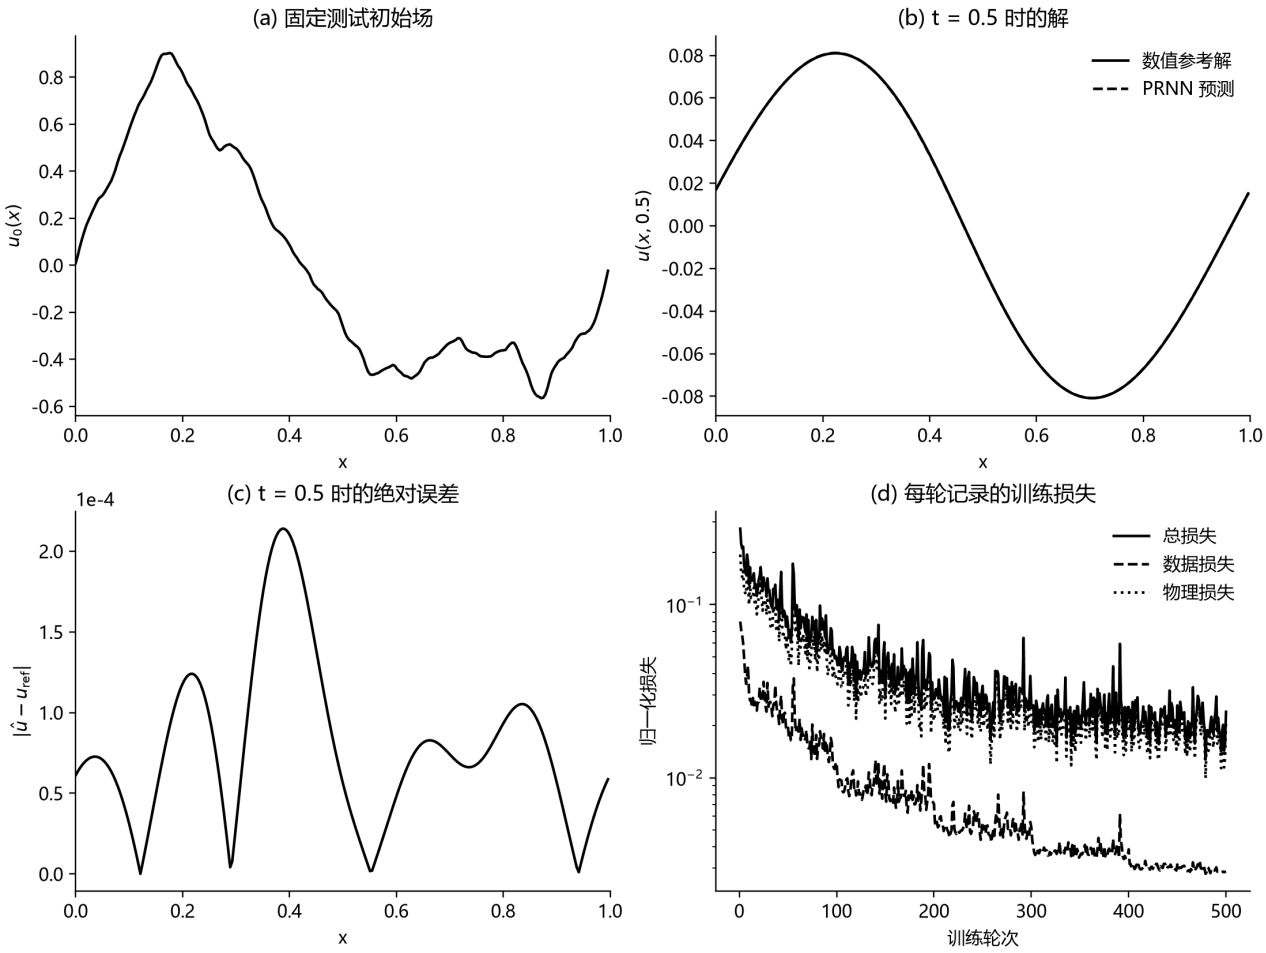


图 9 PRNN 在 T=0.5 时的四格图。（a）固定测试初始场；（b）该终点的参考解与预测解；（c）逐点绝对误差；（d）每轮平均的总损失、数据损失和物理损失，纵轴为对数。

预测结果。 固定样本相对 L^2 误差为 0.16357%，最大绝对误差为 2.1395×10^{-4}，均方根误差为 9.3549×10^{-5}；200 条测试初值的平均相对误差为 0.67861%。

图示参考场的最大绝对幅值为 8.0991×10^{-2}。解曲线的重合程度需结合场值尺度理解，表 19 同时给出相对与绝对指标；不能只看两条曲线是否重合。

训练记录。 两项权重和训练轮次未调整。第 500 轮平均总损失为 2.4034×10^{-2}，数据损失为 2.8726×10^{-3}，物理损失为 2.1161×10^{-2}。这些损失反映不同约束，预测精度仍以固定样本和独立测试集的误差为准。

9.5.4 T=0.75 的 PRNN 求解结果

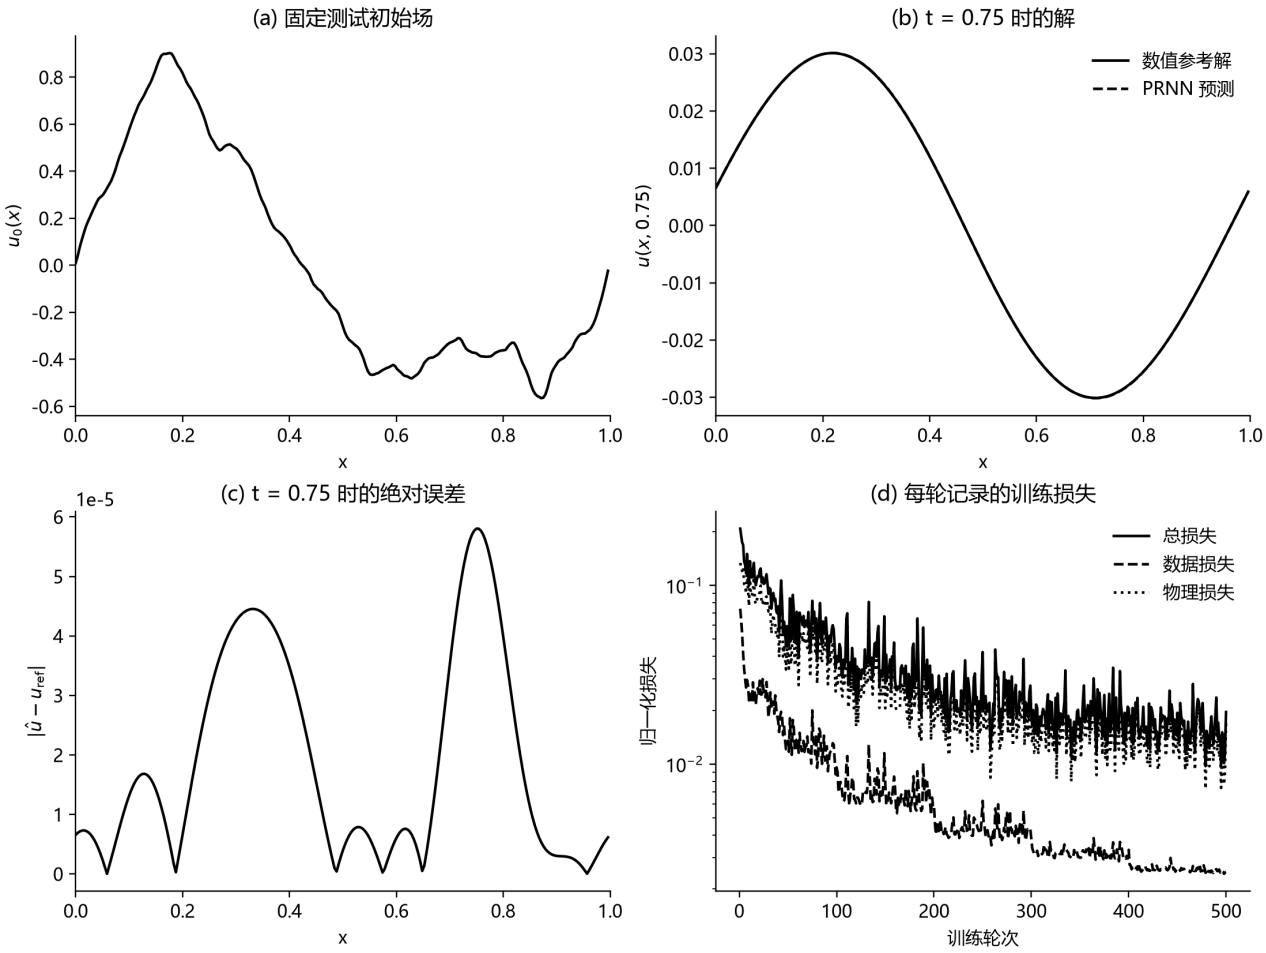


图 10 PRNN 在 T=0.75 时的四格图。（a）固定测试初始场；（b）该终点的参考解与预测解；（c）逐点绝对误差；（d）每轮平均的总损失、数据损失和物理损失，纵轴为对数。

预测结果。 固定样本相对 L^2 误差为 0.11965%，最大绝对误差为 5.8020×10^{-5}，均方根误差为 2.5470×10^{-5}；200 条测试初值的平均相对误差为 0.60033%。

图示参考场的最大绝对幅值为 3.0108×10^{-2}。解曲线的重合程度需结合场值尺度理解，表 19 同时给出相对与绝对指标；不能只看两条曲线是否重合。

训练记录。 两项权重和训练轮次未调整。第 500 轮平均总损失为 1.9569×10^{-2}，数据损失为 2.4847×10^{-3}，物理损失为 1.7084×10^{-2}。这些损失反映不同约束，预测精度仍以固定样本和独立测试集的误差为准。

9.5.5 T=1 的 PRNN 求解结果

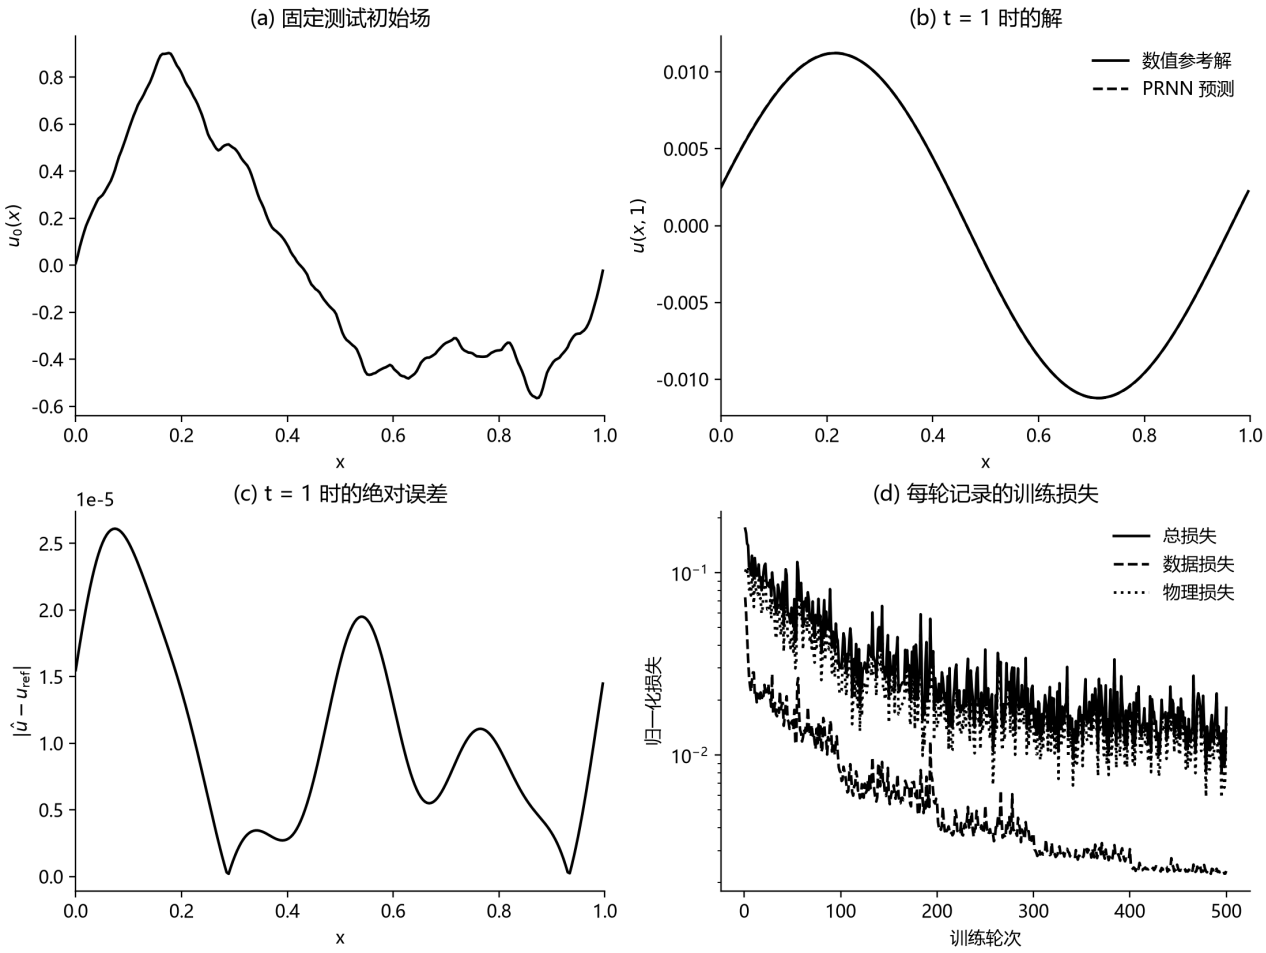


图 11 PRNN 在 T=1 时的四格图。（a）固定测试初始场；（b）该终点的参考解与预测解；（c）逐点绝对误差；（d）每轮平均的总损失、数据损失和物理损失，纵轴为对数。

预测结果。 固定样本相对 L^2 误差为 0.16307%，最大绝对误差为 2.6112×10^{-5}，均方根误差为 1.2935×10^{-5}；200 条测试初值的平均相对误差为 0.56055%。

图示参考场的最大绝对幅值为 1.1218×10^{-2}。解曲线的重合程度需结合场值尺度理解，表 19 同时给出相对与绝对指标；不能只看两条曲线是否重合。

训练记录。 两项权重和训练轮次未调整。第 500 轮平均总损失为 1.8174×10^{-2}，数据损失为 2.3143×10^{-3}，物理损失为 1.5860×10^{-2}。这些损失反映不同约束，预测精度仍以固定样本和独立测试集的误差为准。

9.6 同一模型的时间查询与小结

为区分“逐终点重新训练”和“同一模型查询不同时间”，再对已经训练完成的 T=1 PRNN 模型输入同一测试初值，分别查询五个时刻。以下查询不重新训练，不改权重，参考解与第 6 节表 8 完全相同。

表 21 同一 T=1 PRNN 模型的多时刻查询结果

查询时刻 t	固定样本相对 L^2	最大绝对误差	均方根误差
0	7.38683%	8.1159×10^{-2}	3.3119×10^{-2}
0.25	3.37659%	1.0067×10^{-2}	5.2221×10^{-3}
0.5	2.40896%	2.4912×10^{-3}	1.3777×10^{-3}
0.75	0.86353%	3.3865×10^{-4}	1.8382×10^{-4}
1	0.16307%	2.6112×10^{-5}	1.2935×10^{-5}

表 21 的 t=1 行与表 19 的 T=1 行对应同一个模型、同一个终点。其余时刻的预测来自 T=1 模型，不能与表 19 中针对较短区间重新训练的模型混为一谈。

t=0 的初值投影由输出结构保证；正时间处的预测还受到学习到的修正系数影响。时间作为输入使网络具备查询功能，但一个固定初值的五次查询不能证明整个时间区间内对所有初值均准确。

本章结论。 独立 PRNN 已在与 FP 相同的数据、POD 空间、物理方程、损失和训练计划下完成五组实验。主干使用全连接网络，输入完整初始场与时间，输出修正场后仍经相同的投影与扩散结构得到解。

该实现保留了初始投影和物理残差约束，同时减少了主干参数，但失去了 Fourier 谱层的空间处理方式。参数更少、损失下降或物理约束存在，都不能单独证明精度更高；实际差异由下一章在相同参考场和指标下比较。

10. FNO、FNO-PRNN 与 PRNN 的对比

本章保留第 7、8 节的二者对比，另外加入独立 PRNN。FNO 和 FP 采用前文已保存的十组完整实验结果，PRNN 使用本章新增的五组结果；三者均以同一初值、同一网格和同一时刻的有限差分参考解评价。

10.1 共同条件与方法差异

共同设置为 1000 条训练初值、200 条测试初值、固定图示初值、256 点、$\nu=0.1$、$\Delta t=0.00005$、500 轮、批量 20，以及相同的 Adam 学习率、衰减计划和权重衰减。每种方法五个终点各自独立训练；没有为了改变排名而调整数据、损失权重或训练轮数。

表 22 三种方法的结构与训练信息

比较项目	FNO	FP	PRNN
可训练主干	四个 Fourier 块，64 通道；每层谱分支保留 16 个频率。	同样的四块 FNO 主干，增加时间输入。	四个宽度 64 的全连接隐藏层，ReLU；不含谱层。
输入	完整 256 点初始场。	完整初始场及时间；时间复制到每点。	完整初始场及一个时间，共 257 个数。
输出与表示	直接输出 256 点场，乘回全局标准差。	修正场经投影，组合为 12 个系数，重建完整场。	与 FP 相同的投影、系数组合和场重建。
数据监督	终点完整场的逐样本相对 L^2 损失。	终点 12 维投影系数的相对 L^2 损失。	与 FP 相同。
物理约束	方程通过数值标签提供信息，无显式残差项。	加入归一化 Galerkin 残差平方损失。	与 FP 相同的残差、尺度和权重。
中间快照	训练只用终点标签。	中间快照用于构造 12 维固定 POD 空间。	快照、POD 基与方程系数和对应 FP 一致。
零时刻结构	T=0 模型学习恒等映射。	输出等于初值的 12 维投影。	与 FP 相同的初值投影约束。
实数分量参数量	549505	549569	74496

“仅换解法”的范围。 PRNN 相对 FP 保留了外部实验条件、降阶表示和损失，仅替换可训练主干。主干类型改变必然使参数量及参数初始化不同，Fourier 模式数也不再适用，因此不是等参数量的结构对照。FNO 与另两者的损失及快照用途本来就不同。

三者保持同一随机种子与每轮随机洗牌的训练方式；由于网络初始化消耗的随机数不同，不宣称三者逐批样本顺序完全一致。表中的差异用于解释完整实现之间的比较，不能据单次实验分离每个结构因素的独立贡献。

10.2 同一固定测试初值的误差对比

表 23 统一列出图示初值上的三个指标。各时刻的参考场相同；表中沿用已保存的 FNO 和 FP 结果，没有重新挑选测试初值。相对误差越小表示相对于该参考场的偏差越小，最大误差与均方根误差按原场值尺度计算。

表 23 三种方法在各终点的固定样本预测误差

T	方法	相对 L^2 误差	最大绝对误差	均方根误差
0	FNO	0.13248%	1.0591×10^{-3}	5.9398×10^{-4}
0	FP	7.38683%	8.1159×10^{-2}	3.3119×10^{-2}
0	PRNN	7.38683%	8.1159×10^{-2}	3.3119×10^{-2}
0.25	FNO	0.04719%	2.2608×10^{-4}	7.2977×10^{-5}
0.25	FP	0.09967%	2.4956×10^{-4}	1.5414×10^{-4}
0.25	PRNN	0.48120%	1.4809×10^{-3}	7.4420×10^{-4}
0.5	FNO	0.13624%	1.4215×10^{-4}	7.7915×10^{-5}
0.5	FP	0.10497%	1.2821×10^{-4}	6.0036×10^{-5}
0.5	PRNN	0.16357%	2.1395×10^{-4}	9.3549×10^{-5}
0.75	FNO	0.03758%	2.8968×10^{-5}	7.9999×10^{-6}
0.75	FP	0.09943%	3.2870×10^{-5}	2.1165×10^{-5}
0.75	PRNN	0.11965%	5.8020×10^{-5}	2.5470×10^{-5}
1	FNO	0.05837%	1.0370×10^{-5}	4.6303×10^{-6}
1	FP	0.03180%	4.9938×10^{-6}	2.5227×10^{-6}
1	PRNN	0.16307%	2.6112×10^{-5}	1.2935×10^{-5}

正时间终点。 按固定样本相对误差比较，各终点较低的方法为：T=0.25：FNO；T=0.5：FP；T=0.75：FNO；T=1：FP。这一结果只描述当前图示初值，不能代替测试集平均。

初始时刻。 FP 与 PRNN 的 T=0 输出使用同一 POD 投影，不受各自主干训练结果影响；它们的相同或近乎相同误差反映相同表示限制。FNO 则直接学习完整场的恒等映射，不能将该项当作预测未来解的排名。

10.3 测试集平均误差与计算规模

表 24 相同 200 条测试初值的平均相对 L^2 误差

终止时刻 T	FNO	FP	PRNN
0	0.12997%	6.84787%	6.84787%
0.25	0.09950%	0.14085%	0.92581%
0.5	0.12885%	0.13759%	0.67861%
0.75	0.11979%	0.13460%	0.60033%
1	0.09421%	0.11062%	0.56055%

对每条曲线先计算相对误差，再对 200 个结果求平均，各方法使用完全相同的测试初值。固定样本和平均指标可能给出不同排序；前者便于观察曲线细节，后者反映当前初值分布中一批保留样本的表现。

正时间终点按测试集平均相对误差比较，较低的方法分别为：T=0.25：FNO；T=0.5：FNO；T=0.75：FNO；T=1：FNO。这些结果对应单个随机种子，没有给出跨种子的置信区间。

表 25 T=1 的参数规模与一次完整训练计时

方法	实数分量参数量	训练轮次	训练阶段耗时 / 秒
FNO	549505	500	162.4
FP	549569	500	496.2
PRNN	74496	500	538.9

计时范围为完整 500 轮的前向、反向、优化器更新与日志，不含数据准备及训练后评价。FNO、FP 使用前文保存的运行计时，PRNN 为本次在同一 GPU 环境下的顺序运行；设备负载、首次计算准备等因素仍会影响时间。

PRNN 有 74496 个实参数，FP 按复权重的实部与虚部分别计数为 549569。参数规模约为 FP 的 13.56%。这反映当前全连接主干和谱主干的构造差异，不等于预测速度、峰值内存或总计算成本的同比例变化。

FP 与 PRNN 都要构造 POD 基、计算降阶方程系数和时间导数；FNO 不包含这些步骤。相同轮数不等于相同计算量。这里没有用重复计时建立稳定速度排名，也没有与传统差分求解器进行统一效率测试。

10.4 三种方法随终止时刻的误差变化

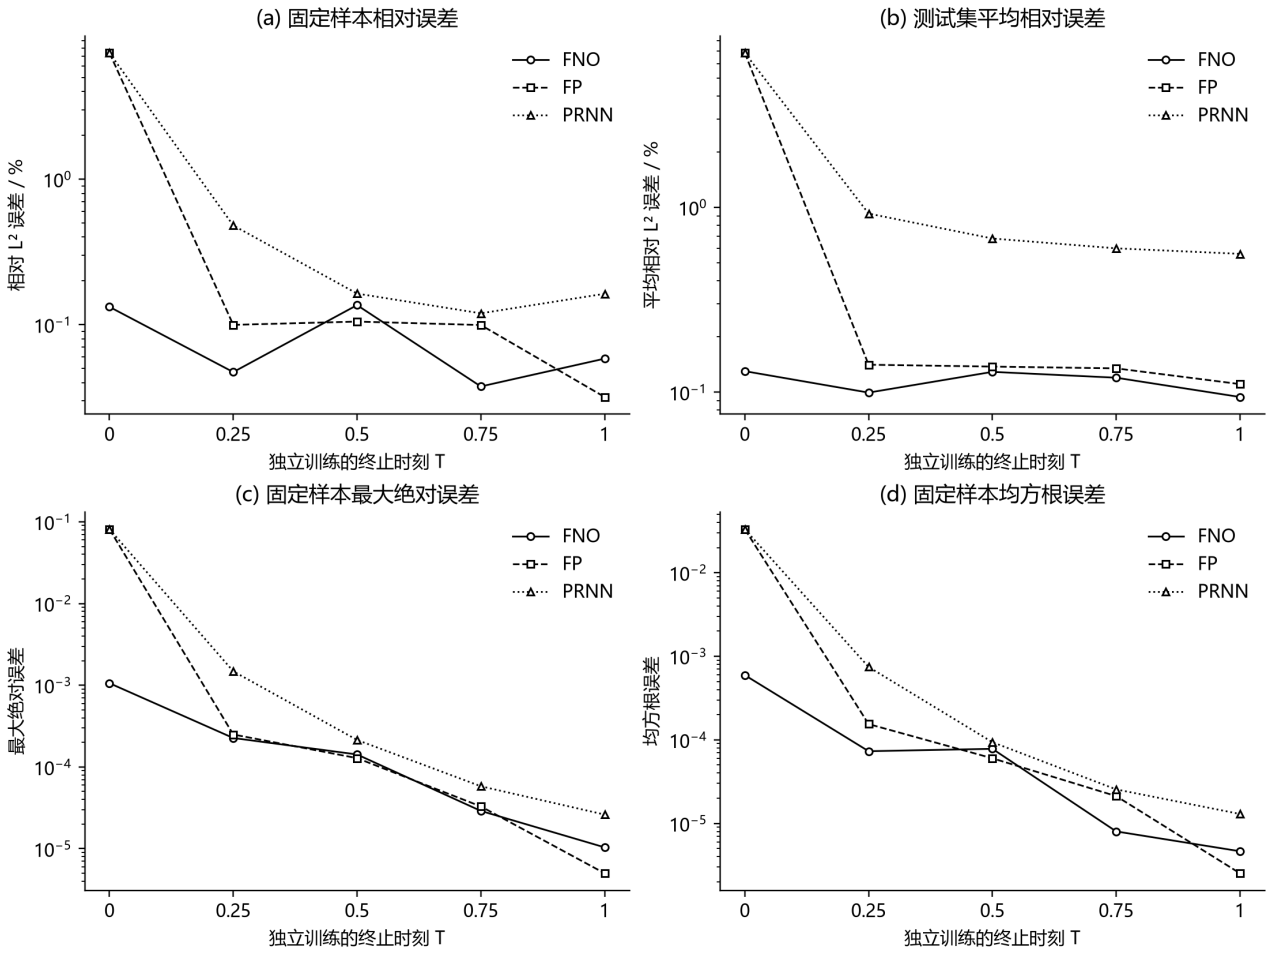


图 12 三种方法的终点误差对比。（a）固定样本相对 L^2 误差；（b）200 条测试初值的平均相对 L^2 误差；（c）固定样本最大绝对误差；（d）固定样本均方根误差。四图均采用对数纵轴，以黑白线型区分方法。

每个标记对应一次独立训练的模型，连接线仅帮助辨识离散实验点，不表示同一模型的连续时间轨迹，也不是时刻之间的插值精度。T=0 对应已知初值的重建，应与正时间解的预测分别解释。

随着时间变化，粘性扩散使参考解幅值整体减小，绝对误差与相对误差的变化不能混为一谈。单个固定初值的排序也未必与测试集平均一致，因此同时列出四类指标。

这些曲线反映当前数据、500 轮训练和固定主干配置下的实际结果。物理残差小并不保证完整场误差最小；POD 截断、主干表达、优化过程及离散参考误差都会影响比较。

10.5 三种方法的优缺点与适用范围

表 26 三种具体实现的主要优点与局限

比较方面	FNO	FP	PRNN
主要优点	直接拟合完整终点场；无固定 12 维空间限制；训练目标和流程较简洁。	FNO 主干处理全局周期结构；结合时间查询、初始投影和显式降阶物理约束。	保留与 FP 相同的降阶物理结构；全连接主干直接，当前参数量较少。
表示限制	当前代码不输入时间，每个终点需独立模型。	最终输出受固定 POD 空间限制，初值高频截断不能由主干消除。	同样受 POD 限制；全连接层绑定 256 点维数，缺少谱卷积结构。
训练信息	依赖终态标签，没有显式中间残差。	除终态标签外还用中间快照建基，并计算随机时间残差。	同 FP；不是仅依赖物理方程的无监督求解。
调节与成本	无需选择 POD 秩或物理损失尺度，但仍需选择谱宽度、频率数等。	需选择 POD 秩和损失尺度；时间导数与谱主干增加每次更新内容。	同样需要降阶与损失设置；较少参数不能直接证明误差更小。
本次证据范围	五个独立终点模型和相同 200 条测试初值。	同一测试集；另检查 T=1 模型对固定初值的五次时间查询。	与 FP 采用对应的终点测试与同模型时间查询。

时间查询的补充比较。 同一个 T=1 模型在固定初值上的中间查询，相对误差分别为：t=0.25，FP 为 0.66446%、PRNN 为 3.37659%；t=0.5，FP 为 1.07324%、PRNN 为 2.40896%；t=0.75，FP 为 1.17454%、PRNN 为 0.86353%。这与表 23 的逐终点独立训练不同，也说明方法排序可能随评价时刻和任务改变。

如何使用本次比较。 只需固定终点场时，可参考表 23、24 的精度与训练成本；若需要同一模型查询时间，并约束降阶动力学，FP 和 PRNN 都具备这一结构，但还要检查中间时刻误差及初值截断。

结论。 新增 PRNN 在保持 FP 的数据、损失、降阶空间和训练计划不变的条件下，将 FNO 主干换成全连接主干；本报告已明确这一实现定义。三种方法的优劣应分别按固定样本、测试集平均、时间查询需求和表示限制判断，不能由“包含物理约束”或“参数更少”预先决定。

本次属于单个随机种子下的完整实现对比，主干参数量并不相等，也未进行损失权重、POD 秩或网络规模消融。因此，表中差异不能进一步解释为 FNO 谱层、物理约束或降阶表示中某一因素的独立贡献。

附录 A 与 Li 论文实验设置的对应说明

本附录补充说明论文参数与当前程序的对应关系。报告采用了 Li 等人 FNO 论文中的部分实验设置，同时保留当前的数据生成方式，并扩展了 FP、PRNN 和多个终止时刻。因此，本报告应表述为“参考论文设置的实现与扩展”，不能表述为“全部实验设置均严格复现原论文”。

A.1 训练样本数、测试样本数与训练轮次

Li 论文第 5 节开头（PDF 第 6 页）明确说明：除非另有说明，使用 1000 个训练样本、200 个测试样本，训练 500 轮。当前程序的这三个数值与该设置一致；后文出现的 1000 条训练初值不是另行增加的训练量。

一个训练样本是一整条初始函数及其对应终态解的配对，不是一个空间网格值。500 轮表示重复遍历同一组 1000 条训练初值。按当前批量 20 计算，每轮有 50 次参数更新，500 轮共有 25000 次更新；累计使用训练样本 500000 次，不等于生成了 500000 条不同初值。200 条测试初值不参与梯度训练。

表 A1 已从论文明确核实且与当前设置一致的项目

项目	论文中的设置	当前采用范围
训练与测试样本	1000 个训练样本、200 个测试样本。	三种方法各终点均采用这一划分。
训练轮次	500 轮。	三种方法各终点均完整训练 500 轮。
优化器	Adam。	三种方法均采用 Adam。
学习率计划	初始值 0.001，每 100 轮减半。	三种方法采用相同初始值和衰减计划。
FNO 主干设置	四层 Fourier 层；一维问题采用 64 通道、16 个模式，ReLU 激活。	FNO 与 FP 的谱主干采用这些数值；PRNN 主干为全连接网络，不适用 Fourier 模式数。
方程与边界	一维粘性 Burgers 方程，单位区间、周期边界，粘性系数 0.1。	三种方法求解同一方程及边界条件。
Burgers 基本任务	由初始函数预测 t=1 的解。	本报告 T=1 实验采用这一终态任务；其他时刻为扩展。

表 A1 的训练与网络设置见论文第 5 节，任务定义见第 5.1 节，粘性系数见附录 A.3.1。参数值一致不等于使用了原论文的同一批数据，也不等于整个网络和数据处理过程完全相同。

A.2 独立初值数量与 POD 快照数量

FP 和 PRNN 每隔 0.05 保存训练轨迹快照，用于构造 POD 基。T=1 时包含初始时刻在内，每条轨迹有 21 个快照，因此共有 1000×21=21000 个快照场；它们来自同一组 1000 条训练初值，不是 21000 条独立初值。终态监督仍对应 1000 条轨迹。FNO 不使用这些中间快照建基，因此样本数量相同不代表三种方法使用的训练信息完全相同。

A.3 与论文存在的实际差异

表 A2 原论文与当前实现的主要差异

项目	Li 论文的说明	当前代码及其含义
参考解与网格	附录 A.3.1：在 8192 点网格上采用 Fourier 分裂步方法；扩散部分在 Fourier 空间精确推进，非线性部分采用很小步长的显式 Euler，再由高分辨率数据降采样。	直接在 256 点网格上使用周期中心差分和显式 Euler，时间步长 0.00005；没有先生成 8192 点参考解。标签的数值生成方法与误差来源不同。
初始函数分布	附录 A.3.1：周期高斯随机场，协方差为 $625(-\Delta+25I)^{-2}$；正文未明确说明常数模态的具体处理。	按相应谱衰减生成随机正弦、余弦系数，只取 127 个非零频率，常数项置零。它是有限截断并附加零空间均值条件，不能直接宣称与论文数据分布完全相同。
批归一化	第 5 节明确写明 Fourier 层使用 ReLU 和批归一化。	当前 FNO 和 FP 主干没有批归一化，因此整体网络实现并非逐项相同。
预测时刻	第 5.1 节的 Burgers 实验学习初值到 t=1 解的映射。	额外训练 T=0、0.25、0.5、0.75 的模型；这些是本报告的补充实验。
FP 与 PRNN	论文没有给出本报告采用的 FP、PRNN 构造及其联合损失。	POD 降阶、初始投影约束、扩散结构和物理残差均属于本报告的扩展。PRNN 是保留 FP 这些部分、将 FNO 主干替换为全连接网络的具体实现。

高斯随机场的概率均值为零，与每条样本在空间上的平均值都为零，是不同条件。本附录仅说明论文正文与当前代码可核实的处理，不据此推断论文原始生成程序是否也将常数模态置零。

A.4 损失函数、其他设置及结果解释

当前 FNO 优化逐样本相对 L^2 误差的均值，分母设置 10^{-12} 的下限。FP、PRNN 则使用“终态投影系数相对误差＋归一化 Galerkin 物理残差平方”的联合损失，两项权重均为 1。三者损失并不相同，具体定义见第 4、6、9 节；不能将 FP、PRNN 的目标函数归为 Li 论文的原始 FNO 损失。

当前批量 20、权重衰减 0.0001、随机种子 0，以及标签全局标准差缩放等，是代码中的具体设置。所核对的论文 PDF 未明确给出这些设置的相同数值和完整处理，也未逐项规定当前相对损失的实现细节。它们不能标注为已从论文逐项核实的原始配置。

现有误差衡量的是模型对本报告有限差分参考场的逼近程度。由于参考数据生成、网络细节和扩展方法存在差异，这些数值不能直接作为原论文的复现成绩，也不能仅凭数值更小判定优于论文结果。三种方法统一部分外部实验条件，与严格复现论文全部设置，是两个不同层面的要求。

核对来源：Li 等，Fourier Neural Operator for Parametric Partial Differential Equations，ICLR 2021；第 2 节（PDF 第 3 页）、第 5 节（第 6 页）、第 5.1 节（第 7 页）、附录 A.3.1（第 14 页）。当前实现依据 FNO复现 目录中的十五份实验代码。