# FNO 求解粘性 Burgers 方程的报告

本文依据 Li 等人的 Fourier Neural Operator 论文，说明所提供程序中一维周期粘性 Burgers 方程的实现。模型用初始场直接预测 t=1 的终态；本次原代码复算对指定初值的终态相对 $L^2$ 误差为 0.04628%。该指标以程序生成的有限差分解为参考，评价范围为一个固定算例。

## 1. 训练数据与初始函数

求解方程及初边值条件为：

$$\partial_t u + \partial_x(u^2/2) = \nu \partial_{xx} u, \qquad \nu = 0.1, \quad 0 < t \le 1$$

$$u(x,0) = u_0(x), \qquad u(x+1,t) = u(x,t), \qquad x \in [0,1)$$

这里的粘性系数和终止时刻始终固定，变化的是初始函数。与论文第 5.1 节相同，学习对象是从初始函数到终态函数的解算子，而不是逐步推进的时间离散格式：

$$G^\dagger : u_0 \longmapsto u(\cdot,1), \qquad \hat{u}(\cdot,1) = s f_\theta(u_0)$$

其中 G† 表示方程的初值到终态映射；$f_\theta$ 为网络给出的归一化预测，θ 表示待训练参数，s 为训练标签的全局标准差。û 表示物理量预测，需将网络输出乘回 s。

## 1.1 初始函数如何产生

$$u_0^{(i)}(x) = \sum_{k=1}^{3} [a_{ik}\sin(2\pi k x) + b_{ik}\cos(2\pi k x)]$$

$$a_{ik} = \frac{\xi_{ik}}{2k}, \quad b_{ik} = \frac{\zeta_{ik}}{2k}, \quad \xi_{ik}, \zeta_{ik} \sim \mathcal{N}(0,1)$$

程序从标准正态分布独立抽取 ξ 和 ζ，再按上式得到正弦与余弦系数。i=1,…,256 对应 256 条训练初值，k=1,2,3 对应三个非零空间频率。各系数的标准差依次为 1/2、1/4、1/6；高频初始分量在分布上较弱。随机种子固定为 0。

初值不含常数项，因此在该均匀周期网格上空间均值为零（浮点误差除外）。每个训练样本是一整条 64 点曲线与其终态曲线的配对，不能把 256×64 个网格值视为同样数量的独立初始条件。

| 项目 | 代码中的设置 |
|---|---|
| 训练集 | 256 对初始场与终态场；全部参与梯度训练。 |
| 验证集 | 未设置。训练 300 轮后使用最后的模型。 |
| 测试算例 | 固定初值 $u_0(x)=-\sin(2\pi x)$；不参与梯度训练。 |
| 空间范围 | x∈[0,1)，64 点，不重复存储 x=1。 |

选择三模态随机 Fourier 初值，可直接满足周期性，并以少量随机系数形成可重复的小规模训练问题。这是该构造的作用；代码未说明选择 256 个样本或三个频率的最优性，也未验证对更复杂初值分布的覆盖能力。

### 1.2 参考标签的数值生成

$$x_j = \frac{j}{64}\ (j = 0, \ldots, 63), \qquad \Delta t = 5 \times 10^{-4}, \qquad N_t = 2000$$

对 256 条初始曲线同时进行数值积分，从 t=0 推进到 t=1。每一步根据左右相邻点计算变化量；最左点的左邻点取最右点，最右点的右邻点取最左点，从而实施周期边界。用 $u_j^n$ 表示第 j 个空间点在第 n 个时间步的数值解，更新式为：

$$u_j^{n+1} = u_j^n - \frac{\Delta t}{4\Delta x}\left[(u_{j+1}^n)^2 - (u_{j-1}^n)^2\right] + \frac{\nu \Delta t}{\Delta x^2}\left(u_{j+1}^n - 2u_j^n + u_{j-1}^n\right)$$

非线性项是通量 $u^2/2$ 的中心差分，粘性项是二阶中心差分，时间推进采用显式 Euler。对光滑解，其形式截断误差为空间二阶、时间一阶。整个标签生成过程执行 2000 步，训练只使用终态，不保存中间时刻作为监督标签。

该实现便于用简短程序批量构造输入输出配对；训练标签由 Burgers 方程生成，物理信息通过标签进入监督学习。它不是论文附录 A.3.1 使用的 Fourier 分裂步数据生成器。64 点参考解含有数值离散误差，不能称为解析解或精确真值。

### 1.3 标签缩放及其理由

$$s = 0.0090725515, \qquad y_j^{(i)} = \frac{u_j^{(i)}(1)}{s}$$

将全部 256×64 个终态值合并计算一个样本标准差 s：先求这些值与其平均值之差的平方和，再除以 256×64-1，最后开平方。上式中 i 为样本序号，j 为空间点序号，y 为缩放后的标签。只将标签除以 s，不减去均值；输入初始场保持原尺度，测试参考解不参与 s 的计算。

本次终态标准差约为 0.00907，而初始正弦系数的标准差量级为 0.5。缩放将输出目标提升到约为 1 的尺度，减少终态幅值较小给优化带来的尺度问题。它对所有样本使用同一个常数，并不会逐样本平衡相对误差。

## 2. 输入与输出

对第 i 条初始曲线，网络接收的是按空间顺序排列的 64 个初值：

$$\boldsymbol{u}_0^{(i)} = \left(u_0^{(i)}(x_0),\ u_0^{(i)}(x_1),\ \ldots,\ u_0^{(i)}(x_{63})\right)$$

| 位置 | 数据规模 | 实际含义 |
|---|---|---|
| 全部训练输入 | 256 条曲线 | 每条曲线给出 64 个空间点上的初始值。 |
| 单个小批次 | 32 条曲线 | 每次用 32 条初始曲线共同计算损失并更新参数。 |
| 送入网络 | 每个点 1 个数 | 每点只有一个初始场值，作为该点的输入特征。 |
| 网络输出 | 每条曲线 64 个数 | 归一化终态 $f_\theta(u_0)$，尚未乘回尺度。 |
| 物理量预测 | 每条曲线 64 个数 | $\hat{u}=s\ f_\theta(u_0)$，对应 t=1 的整条空间曲线。 |

时间 t、粘性 ν 和绝对位置 x 均未作为输入。空间点的位置由固定周期网格及其顺序给出。因此本模型对应 ν=0.1、T=1 的固定终态任务；当前训练并不提供任意时刻预测或不同粘性的泛化证据。

## 3. 神经网络结构

网络先把每点的一个初始值转成 16 个特征，再经过四个 Fourier 块，最后将这些特征转成一个终态预测值。这里“通道”就是每个空间点上保存的一种特征；16 通道表示每点有 16 个特征数。

| 组成 | 具体设置 | 每条初值对应的结果 |
| --- | --- | --- |
| 输入提升 P | 逐点线性变换，1 个数变为 16 个特征，含偏置。 | 64 点，每点 16 个特征。 |
| Fourier 块 ×4 | 每块含谱分支与局部分支；两者相加后使用 GELU 激活。 | 64 点，每点 16 个特征。 |
| 谱分支 | Fourier 变换 → 前 12 个频率的特征混合 → 逆变换。 | 64 点，每点 16 个特征。 |
| 局部分支 | 同一空间点的 16 个特征作线性组合，生成新的 16 个特征。 | 64 点，每点 16 个特征。 |
| 输出投影 Q | 每点的 16 个特征先变为 32 个，经 GELU 激活后再变为 1 个数。 | 64 点，每点 1 个终态预测值。 |

上述逐点线性变换由核大小为 1 的一维卷积实现，各空间点共用同一组参数。它只组合同一点的不同特征，跨空间位置的信息交换由谱分支完成。

### 3.1 Fourier 块的逐项计算

$$v_{\ell+1} = \mathrm{GELU}\left[\mathcal{F}^{-1}(R_\ell \mathcal{F} v_\ell) + W_\ell v_\ell + b_\ell\right], \quad \ell = 0, 1, 2, 3$$

$\ell$ 表示网络层号，$v_\ell$ 表示这一层的特征，$\mathcal{F}$ 和 $\mathcal{F}^{-1}$ 分别表示 Fourier 变换及其逆变换。$R_\ell$ 为谱分支的权重，$W_\ell$ 和 $b_\ell$ 为局部分支的权重与偏置。层号与方程的时间步无关。

对每一种特征在 64 个空间点上的值作 Fourier 变换，得到 k=0,…,32 共 33 个频率系数；实信号的负频率可由这些系数确定，无需重复保存。对每个保留频率，使用一张 16×16 的复权重矩阵组合 16 种输入特征：

$$\hat{z}_{\ell,o}(k) = \sum_{c=1}^{16} R_{\ell,oc}(k)\, \hat{v}_{\ell,c}(k), \qquad k = 0, 1, \ldots, 11$$

其中 c 为输入特征编号，o 为输出特征编号，k 为频率编号。公式左侧是组合后的输出系数，右侧是 16 个输入系数的加权和。谱分支保留 k=0,…,11，包含零频率；其余系数置零，再逆变换回 64 个空间点，与局部分支相加。四个块全部使用 GELU，第四块也不例外。

### 3.2 参数量及其他设置

四层谱权重共有 4×16×16×12=12,288 个复数；其余权重和偏置共 1,697 个实数。每个复数包含实部和虚部两个实数，因此按存储的实数分量计算，参数总量为 26,273。

谱权重由复高斯随机数除以 16 初始化。模型没有批归一化、随机丢弃神经元、POD 降阶或均值守恒修正。局部分支的系数需要训练，并非直接把上一层结果原样相加。

## 3.3 为什么采用 Fourier 结构

论文第 3、4 节将神经算子层写成局部映射与积分算子的组合。若积分核只依赖位置差 x-y，积分变为卷积；在 Fourier 空间中，卷积可用逐频率矩阵乘法实现：

$$(\mathcal{K}_\ell v)(x) = \int_0^1 \kappa_\ell(x-y)v(y)\,dy = \mathcal{F}^{-1}[R_\ell \mathcal{F}v](x)$$

$\kappa_\ell$ 是第 $\ell$ 层的卷积核，描述各位置之间如何相互影响；$\mathcal{K}\ell$ 表示这个卷积运算。积分式将整个空间域的信息汇集到位置 x，右侧是同一运算的 Fourier 表达。

本代码直接学习每个保留频率上的通道混合矩阵 $R_\ell$，不先在物理空间拟合积分核。Fourier 基函数覆盖整个周期域，一个谱层就能建立全局空间联系；与周期边界及均匀网格相配合，FFT 可有效计算这个全局分支。

| 选择 | 能够说明的理由及边界 |
| --- | --- |
| Fourier 全局分支 | 解算子依赖整条初始曲线。谱分支在全域交换信息，与从初始场预测终态场的任务相符。 |
| 保留 12 个频率 | 限制谱权重规模，以低频成分构成主要全局表示。初值只有三个频率，粘性扩散也抑制高频；但非线性可产生新频率，12 并非由初值频数推得的精确上限。 |
| 局部 1×1 分支 | 保留各位置的通道信息，并与全局谱信息组合。高频未被该分支统一截断，因此整个网络输出不被限制为仅含前 12 个频率。 |
| GELU 非线性 | Burgers 的初值到终态映射是非线性的；逐点激活使多个线性谱层能够组成非线性算子。GELU 为平滑激活，但材料没有证明它比 ReLU 更优。 |
| 16 通道及四个块 | 通道提升提供多维隐表示，多层复合增加表达能力。四层组织与论文基本框架一致；宽度 16 的精度、效率取舍没有消融对照。 |
| 不输入绝对 x | 周期均匀网格上的谱卷积、逐点卷积和逐点激活均兼容整数网格循环平移，适合空间齐次的方程。该性质不等价于连续域误差保证。 |

GELU 的定义为 $z\Phi(z)$，$\Phi$ 为标准正态分布的累积分布函数。它提供平滑的逐点非线性；与局部分支共同作用后，谱分支截断并不意味着最终预测只是一次低通滤波。

“为什么选它们”需要区分结构依据与最优性证据：论文提供了 Fourier 神经算子的理论组织方式和基准实验；本代码给出了具体超参数，但未包含模式数、宽度、深度或激活函数的消融实验。因此可以解释这些选择的功能，不能把它们写成已验证的最优配置。

## 4. 损失函数

每次训练取 32 条初始曲线，每条有 64 个空间点。用 y 表示归一化标签，用 ŷ 表示网络预测的归一化终态；i 为当前批次内的样本序号，j 为空间点序号。训练时将各点的预测误差平方后取平均，得到均方误差（MSE）：

$$\mathcal{L}(\theta)=\frac{1}{32\times 64}\sum_{i=1}^{32}\sum_{j=0}^{63}\left(\hat{y}_j^{(i)}-y_j^{(i)}\right)^2$$

也就是说，一次参数更新同时考虑 32×64 个点的误差。由于预测值和标签都按同一个 s 缩放，损失也可用原物理量等价表示为：

$$\mathcal{L}(\theta)=\frac{1}{s^2}\frac{1}{32\times 64}\sum_{i=1}^{32}\sum_{j=0}^{63}\left(\hat{u}_j^{(i)}(1)-u_j^{(i)}(1)\right)^2$$

选择 MSE 的作用是直接监督整条终态曲线，对大幅偏差给予更大的平方惩罚，并提供便于反向传播的平滑目标。均匀网格下，各点等权与离散场值 $L^2$ 误差一致；乘上固定的 $1/s^2$ 改变优化尺度，但不改变未正则化经验 MSE 的最小化目标。

该损失是纯数据监督项。程序没有 Burgers 残差、时间导数残差、初值或边界惩罚、空间导数监督项，也没有显式正则化项。周期结构体现在数据生成和谱运算中，而不是额外的边界损失。论文提供的 FNO 思路不意味着代码自动使用物理约束。

全局缩放 MSE 与逐样本相对 $L^2$ 损失不同：它没有除以每条参考解各自的范数，故不会自动提高小幅样本的权重。单个测试算例的相对 $L^2$ 仅用于训练结束后的评价，不参与反向传播。

## 4.1 优化设置与训练记录

| 项目 | 实际设置及含义 |
| --- | --- |
| 优化器 | Adam；初始学习率 0.003，权重衰减系数为 0。 |
| 训练批量 | 每轮随机打乱 256 个样本，分成每组 32 个样本，共 8 次更新；300 轮共 2,400 次更新。 |
| 学习率 | 每完成 100 轮训练，学习率减半。第 1-100 轮为 0.003，第 101-200 轮为 0.0015，第 201-300 轮为 0.00075。 |
| 最后一次退火 | 第 300 轮结束后变为 0.000375；此后没有新的参数更新。 |
| 选模与记录 | 无验证集或早停，直接使用第 300 轮结束的模型；每 50 轮打印一次最后小批次损失。 |
| 复算环境 | Python 3.13.15，PyTorch 2.14.1+cpu；CPU 单线程；随机种子为 0。 |

Adam 用于梯度训练，学习率逐步减半可在后期减小更新步幅。这里可以说明策略的作用，但代码未提供优化器或调度器对照。程序记录的损失既不是整轮平均损失，也不是验证误差；不同轮次最后一个随机小批次的样本也可能不同。

## 5. 数值实验

本节考察 Fourier 神经算子对一维周期粘性 Burgers 方程终态解的预测能力。模型学习初始场到 t=1 终态场的映射，并将预测结果与有限差分参考解比较。以下数值和图形沿用前文所记录的同一次原代码复算结果。

实验采用 256 条随机三模态初值及其终态作为训练数据，空间分辨率为 64 点。网络由四个 Fourier 块构成，宽度为 16，每层谱分支保留 12 个频率。使用 Adam 训练 300 轮，批量为 32，初始学习率为 0.003，每 100 轮减半。随机种子为 0，计算在 CPU 单线程上完成；完整的数据、网络和优化设置见第 1-4 节。

考虑前文给出的周期初值问题，粘性系数固定为 $\nu=0.1$，空间区域为 $x\in[0,1)$，终止时刻为 $t=1$。学习目标与物理量预测分别为：

$$G^{\dagger}:u_0\longmapsto u(\cdot,1),\qquad \hat{u}(\cdot,1)=sf_{\theta}(u_0)$$

测试初值取 $u_0(x)=-\sin(2\pi x)$，参考终态由与训练标签相同的有限差分求解器计算。该初值属于同一有限 Fourier 形式，但不是随机测试集。本次核查其与所有训练初值的离散 $L^2$ 距离均非零，未与训练样本重复，且不参与梯度训练。

**评价指标。** 记 $\hat{u}$ 为网络预测，$u_{\mathrm{ref}}$ 为有限差分参考解，采用相对 $L^2$ 误差、最大绝对误差和均方根误差评价终态预测：

$$E_{\mathrm{rel}}=\frac{\|\hat{u}-u_{\mathrm{ref}}\|_2}{\|u_{\mathrm{ref}}\|_2}\times 100\%$$

$$E_{\max}=\max_j|\hat{u}_j-u_{\mathrm{ref},j}|,\qquad \mathrm{RMSE}=\sqrt{\frac{1}{64}\sum_{j=0}^{63}(\hat{u}_j-u_{\mathrm{ref},j})^2}$$

其中 $\|\cdot\|_2$ 表示各点数值平方和的平方根。$E_{\mathrm{rel}}$ 为相对误差，$E_{\max}$ 为最大绝对误差，RMSE 为均方根误差。指标均使用原始 64 个空间点；后两项与场值单位相同，不是百分数。

表 1 固定测试初值在 t=1 时的预测误差（空间分辨率为 64 点）

| 方法 | 相对 $L^2$ 误差 | 最大绝对误差 | 均方根误差 |
|---|---|---|---|
| FNO | 0.04628% | $1.37920\times10^{-5}$ | $5.85890\times10^{-6}$ |

表 1 给出了固定测试算例在 t=1 时的误差，图 1 展示相应的终态曲线和逐点误差。相对 $L^2$ 以同一初值的有限差分参考解为基准；最大绝对误差取 64 点中的最大值，RMSE 对 64 点取均方根。参考终态在这 64 点上的绝对值最大值为 $1.79021\times10^{-2}$；最终全训练集 MSE 为 $1.68537\times10^{-6}$，是训练结束后对全部 256 条归一化标签额外评价得到的。

原代码将相对误差保留两位百分数，因此显示 0.05%。以上更详细数值来自同一次运行保存的预测值和参考值。本次复算保持原始数据生成、模型、训练及随机数流程，统计结果并非历史训练记录。

表 2 训练过程中记录的最后一个小批次的归一化均方误差

| 训练轮次 | 50 | 100 | 150 | 200 | 250 | 300 |
|---|---|---|---|---|---|---|
| 训练损失 | 0.000064 | 0.000018 | 0.000004 | 0.000005 | 0.000004 | 0.000002 |

每 50 轮记录一次，各数值为该轮最后一个小批次的损失，并非整轮平均损失或验证误差。

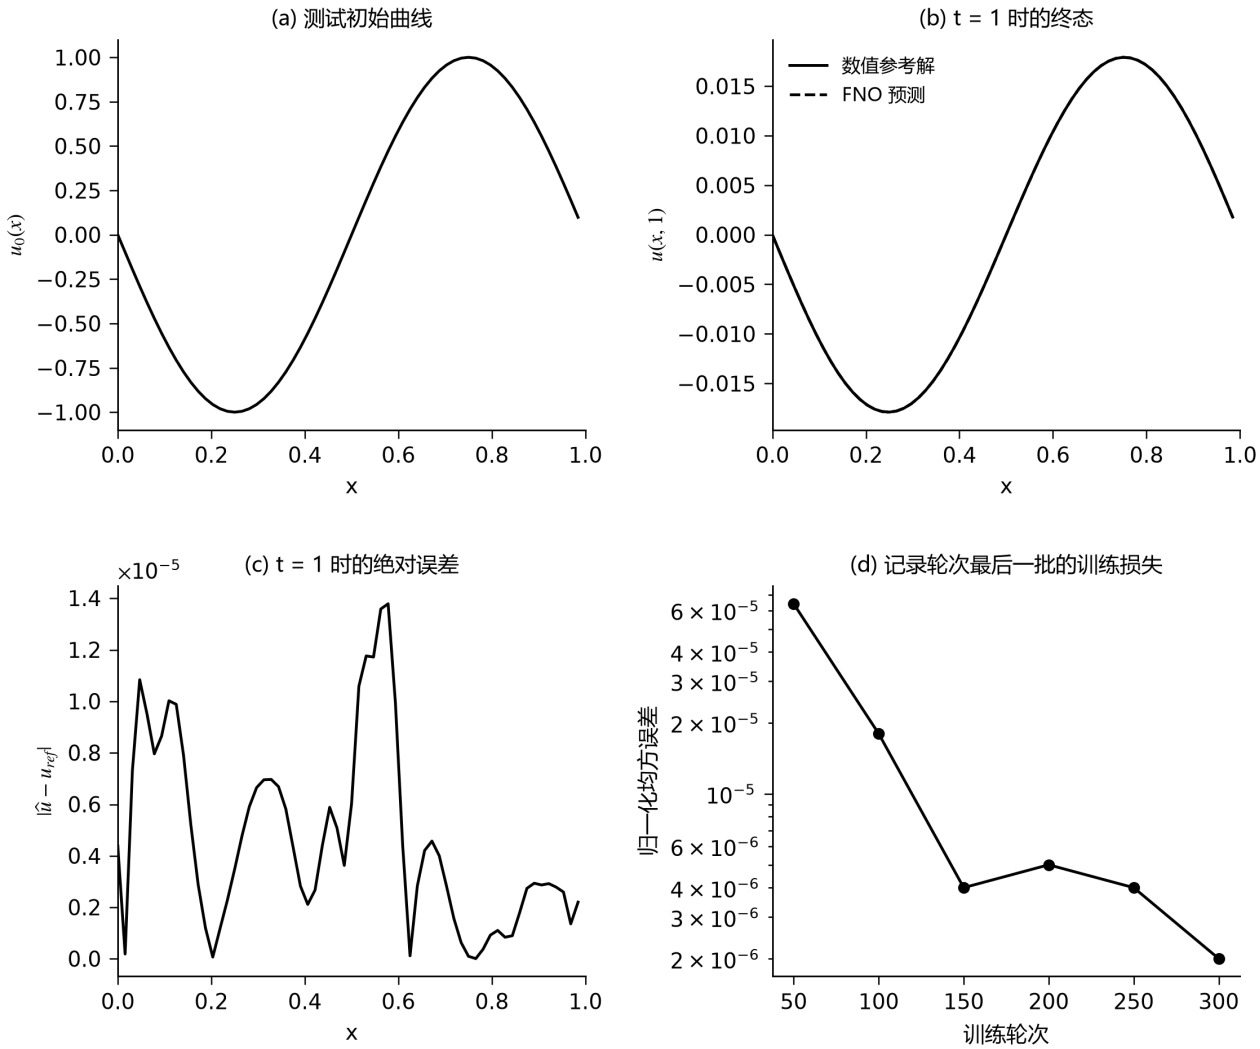



图 1 原代码指定算例及训练日志。（a）固定测试初始场；（b）t=1 的有限差分参考解与 FNO 预测；（c）同一终态的逐点绝对误差；（d）表 2 中原程序每 50 轮打印的最后小批次 MSE，纵轴为对数。所有点均来自本次复算。

图中使用原有 64 点并以直线连接，不额外添加 x=1 的重复端点，不平滑误差。参考解用黑实线，预测用黑虚线；（a）的初值并非网络对 t=0 的预测。（d）只有原日志的六个记录点，连接线不代表中间轮次已经记录。

**预测结果。** 如图 1(b) 和表 1 所示，在当前固定算例上，预测终态与有限差分参考场接近。误差较小支持“模型拟合了这个终态案例”的判断；256 条训练数据上的低 MSE 则说明训练拟合充分，两者统计对象不同。

**训练过程与误差尺度。** 参考终态的最大幅值只有约 0.0179，因此需要同时给出相对误差和绝对误差，避免只凭两条重合曲线判断精度。表 2 和图 1(d) 的损失日志总体下降，局部回升可受批次变化影响，不能仅凭六个点判断完整收敛过程。

**结果讨论。** 这里没有独立随机测试集、多随机种子统计、参考解网格收敛或运行速度对照。该结果不能推导出对任意初值的平均误差、对连续精确解的误差、超分辨率能力或优于其他求解器的结论。

**结论。** 压缩包实现了固定粘性 0.1、固定终止时刻 1 的 FNO 终态映射。训练数据为随机三模态周期初值及显式有限差分终态，网络由四个谱分支与局部分支相加的 GELU 块构成，优化目标为全局标签缩放后的 MSE。一次原代码复算在指定初值上的相对 $L^2$ 为 0.04628%。

这一结果说明该简化实现能够准确拟合所展示的离散终态案例；其适用范围仍受初值分布、单一终止时刻监督和数值标签精度限制。保留 Fourier 算子结构，不等于复现了原论文的全部实验设置与性能结论。

## 6. FNO-PRNN求解粘性Burgers方程

本节在第 5 节的周期 Burgers 算例上，将 FNO 与物理增强神经网络（PRNN）结合。FNO 根据初始场和查询时间提取空间特征，POD 用少量系数表示解，训练时同时拟合终态数据并约束降阶方程残差。以下按训练数据、输入输出、网络结构、损失函数和数值实验依次说明；实验数值与四联图沿用原有运行记录。

### 6.1 训练数据与初始函数

求解方程和初边值条件仍为：

$$\partial_t u + \partial_x(u^2/2) = \nu \partial_{xx} u, \quad \nu = 0.1, \quad x \in [0,1), \quad 0 \le t \le 1$$

$$u(x,0) = u_0(x), \qquad u(0,t) = u(1,t), \qquad u_x(0,t) = u_x(1,t)$$

粘性系数与空间区域固定，变化的是初始函数。空间取 64 个点 $x_j = j/64$（$j=0,\cdots,63$），不重复保存 $x=1$；固定测试初值仍为 $u_0(x) = -\sin(2\pi x)$。

#### 6.1.1 初始函数如何产生

$$u_0^{(m)}(x) = \sum_{k=1}^{3} [A_{mk}\sin(2\pi k x) + B_{mk}\cos(2\pi k x)]$$

$$A_{mk} = \frac{\xi_{mk}}{2k}, \quad B_{mk} = \frac{\zeta_{mk}}{2k}, \quad \xi_{mk}, \zeta_{mk} \sim \mathcal{N}(0,1)$$

$m=1,\cdots,256$ 表示训练初值编号，$k=1,2,3$ 表示三个非零波数。正态随机数相互独立，随机种子为 0，三个频率的系数标准差分别为 1/2、1/4、1/6。初值没有常数项，在周期均匀网格上具有零空间均值，浮点误差除外。

三模态正弦与余弦直接满足周期性，系数随频率减小，使初始分布以较低频成分为主。这一设置沿用原 FNO，便于在同一问题上加入降阶与物理约束；没有证据表明三个频率或 256 条样本是最优选择。

#### 6.1.2 参考标签与中间快照

$$u_j^{q+1} = u_j^q + \Delta t\left[-\frac{(u_{j+1}^q)^2 - (u_{j-1}^q)^2}{4\Delta x} + \nu\frac{u_{j+1}^q - 2u_j^q + u_{j-1}^q}{\Delta x^2}\right]$$

$q$ 表示时间步，左右下标按周期循环。空间步长为 1/64，时间步长为 0.0005，共进行 2000 步。非线性通量使用中心差分，扩散项使用二阶中心差分，时间采用显式 Euler；这与原 FNO 的标签求解器一致，所生成的是离散参考解。

表 3 训练数据、POD 快照和评价数据的用途

| 数据 | 数量与使用方式 |
|---|---|
| 训练初值及终态 | 256 对 64 点场；终态经 POD 投影后作为数据损失的标签。 |
| POD 快照 | 每 100 步保存一次，加上初值，共 21 个时刻：$0, 0.05, \cdots, 1$；$256\times21=5376$ 个场。 |
| 物理配点 | 每批 32 个训练初值分别配一个均匀随机时刻；不需要该配点处的参考标签。 |
| 验证与测试 | 无验证集，使用最后一轮模型；固定测试初值不参与训练或 POD 基构造。 |

中间快照只用于建立降阶空间，网络的数据损失只拟合 $t=1$ 的终态系数。因此，不能将本方法描述为完全没有利用中间解，也不能将 5376 个快照视为同样数量的独立初始条件。

## 6.2 输入与输出

对一个样本，模型接收整条初始曲线及查询时间，而不是单个位置的场值：

$$\mathbf{u}_0 = (u_0(x_0), \ldots, u_0(x_{63})), \qquad z(x_j) = (u_0(x_j), t)$$

时间 t 在所有空间点取相同数值，与该点的初始值并列，形成两个输入特征。单个样本包含 64 个初值和 1 个时间；复制时间是为了形成统一的两通道输入，不代表增加了 64 个独立时间变量。

$$(\mathbf{u}_0, t) \longmapsto \hat{\mathbf{a}}_\theta(\mathbf{u}_0, t) \in \mathbb{R}^{12} \longmapsto \hat{\mathbf{u}}_\theta(\mathbf{u}_0, t) \in \mathbb{R}^{64}$$

表 4 从输入到物理量预测的各级结果

| 位置 | 每个初值对应的内容 | 实际含义 |
|---|---|---|
| 原始输入 | 64 个初值＋1 个查询时间 | 初始场保持原尺度，时间在 0 到 1 内。 |
| FNO 输入 | 64 点，每点 2 个数 | 每点的初始值与相同的时间 t。 |
| FNO 中间特征 | 64 点，每点 16 个特征 | 通过四个 Fourier 块交换全域信息。 |
| FNO 输出头 | 64 个数 | 尚未投影的修正场 $g_\theta$，不是最终物理解。 |
| 降阶网络输出 | 12 个实系数 | 经投影、扩散项和时间因子组合后的预测系数。 |
| 物理量预测 | 64 个场值 | 将预测系数与固定 POD 基函数线性组合。 |

当前程序的模型调用返回 12 个预测系数，之后再重建 64 点空间场。这些系数按原物理尺度表示，重建后无需乘回终态标准差 s；s 只用于数据损失的缩放。此处与前文纯 FNO 的“输出归一化场，再乘回 s”不同。

粘性 v 和绝对坐标 x 没有作为额外输入。空间位置由 64 点周期网格及其顺序确定。时间输入允许在不同 t 查询网络，但本次只对同一个测试初值的五个时刻作了评价，不能据此断言任意初值和任意时刻都具有相同精度。

## 6.3 神经网络结构

整个计算由固定的 POD 表示、可训练的 FNO 主干、以及系数组合与场重建三部分组成。POD 基、扩散特征值和二次对流系数由训练快照及离散方程预先计算，不是神经网络参数。

### 6.3.1 POD 降阶表示

$$\langle f, g\rangle_h = \frac{1}{64}\sum_{j=0}^{63} f(x_j)g(x_j), \quad \langle \phi_i, \phi_k\rangle_h = \delta_{ik}$$

$$a_i = \langle u, \phi_i\rangle_h, \quad P_{12}u = \sum_{i=1}^{12} a_i\phi_i, \quad \hat{u}(x_j, t) = \sum_{i=1}^{12} \hat{a}_i(t)\phi_i(x_j)$$

内积表示 64 个网格点上乘积的平均，$\delta_{ik}$ 在 i=k 时为 1，其余为 0。$\Phi_i$ 是第 i 个固定空间基函数，$a_i$ 是解在该基上的系数，$P_{12}$ 表示保留 12 个基函数的投影。原来描述一条场需要 64 个数，现在用 12 个系数描述主要空间变化。

先对每个快照去掉空间均值，记所得 64 点列向量为 w。用全部训练快照组成协方差，再对整数格周期平移求平均：

$$C = \frac{1}{5376}\sum_{m=1}^{5376} \mathbf{w}_m \mathbf{w}_m^T, \qquad \overline{C} = \frac{1}{64}\sum_{s=0}^{63} S_s C S_s^T$$

$S_s$ 表示循环平移 s 个网格点，右上角 T 表示转置。对平均协方差取最大特征值对应的 12 个特征向量，经正交化与尺度调整，使其在离散内积下正交归一。周期平移平均利用方程的空间平移对称性，不加入测试样本，也不需要额外求解新初值。

本次保留训练快照能量的 99.99999373%，所得子空间对应第 1-6 个波数的正弦、余弦分量。原初值只有 6 个实模态，额外模态用于表示非线性生成的谐波。较高的能量保留率只说明这些训练快照容易表示，不保证新初值的预测误差。

### 6.3.2 FNO 主干的逐项计算

表 5 可训练网络的结构和作用

| 组成 | 具体设置 | 输出内容 |
|---|---|---|
| 输入提升 | 核大小为 1 的一维卷积，含偏置；2→16。 | 64 点，每点 16 个特征。 |
| Fourier 块 ×4 | 谱分支与局部分支相加，再使用 GELU。 | 空间点数和特征数不变。 |
| 谱分支 | FFT；波数 0-11 的复权重混合；高频置零；逆 FFT。 | 全域交换后的 16 个特征。 |
| 局部分支 | 核大小为 1 的卷积，含偏置；16→16。 | 同一位置的特征线性组合。 |
| 输出头 | 逐点 16→32，经 GELU 后 32→1。 | 64 点修正场 $g_\theta$。 |

$$v_{\ell+1}(x) = \mathrm{GELU}\big(\mathcal{F}^{-1}(R_\ell \mathcal{F} v_\ell)(x) + W_\ell v_\ell(x) + b_\ell\big)$$

$$\widehat{w}_o(k) = \sum_{c=1}^{16} R_{\ell,c,o}(k)\,\widehat{v}_c(k), \qquad k = 0, \ldots, 11$$

$\ell$ 是网络块编号，与物理时间步无关；c、o 分别是输入与输出特征编号。对 64 点实场的 FFT 给出波数 0-32 共 33 个系数，每个保留波数使用一张 16×16 复权重矩阵混合通道。谱分支之外的局部分支不进行相同的频率截断，四个块全部使用 GELU。

四层谱权重共 12,288 个复数，其余权重和偏置共 1,713 个实数，按复数的实部、虚部分别计数，总计 26,289 个实参数。12 个保留 Fourier 频率与 12 个 POD 实模态属于不同层次：前者控制谱分支，后者控制最终解的表示空间。

### 6.3.3 预测系数、初值约束与场重建

先将 FNO 修正场投影到 POD 基，得到修正系数；同样将给定初值投影得到初始系数：

$$c_{\theta,i}(\mathbf{u}_0,t)=\langle g_\theta(\mathbf{u}_0,t),\phi_i\rangle_h,\qquad a_i(0)=\langle u_0,\phi_i\rangle_h$$

将 POD 子空间中的离散扩散矩阵作正交对角化，记对角元素为 $\lambda_i$。相应旋转只改变基的方向，不改变所保留的空间或正交性。最终预测系数采用：

$$\hat{a}_i(t)=e^{\lambda_i t}a_i(0)+(1-e^{-\beta t})e^{-\beta t}c_{\theta,i}(\mathbf{u}_0,t)$$

$$\beta=\frac{4\nu\sin^2(\pi/64)}{\Delta x^2}\approx 3.94467211,\qquad \Delta x=\frac{1}{64}$$

第一项是该降阶空间中线性扩散的指数衰减。第二项是 FNO 学习的非线性修正，时间因子在 t=0 为零，且在晚期随扩散尺度衰减。β 取离散扩散算子第一个非零波数的衰减率；它与 ν、网格共同确定，不参与训练。

由此，t=0 的预测系数等于初始投影系数，重建场为 $P_{12}u_0$；这是对投影初值的结构约束。它不是完整 Burgers 方程的解析解，也不是对任意输入初值的逐点严格复制。本次训练初值的总体相对投影误差为 $2.06343\times10^{-7}$，固定测试初值的 t=0 误差见表 8。

### 6.3.4 为什么采用这些结构

表 6 结构选择的依据及其边界

| 选择 | 作用与理由 |
|---|---|
| FNO＋时间通道 | 利用初始场的全局空间结构，并区分不同查询时刻；保留原网络的周期谱运算。 |
| POD 的 12 维表示 | 用较少系数表达主要空间变化，使物理约束写成降阶方程；模态截断仍可能遗漏动力学。 |
| 谱分支＋局部分支 | 分别提供全局空间联系和逐点特征组合；GELU 提供平滑非线性。 |
| 扩散项＋时间因子 | 显式表达已知的线性衰减，并使修正项在初始时刻消失，减轻网络同时学习这些结构的负担。 |
| 固定基及方程系数 | 它们由训练快照和差分算子确定，优化集中于 FNO 参数；没有用测试解修正输出。 |

宽度 16、四个块和前 12 个频率沿用原 FNO，POD 秩取 12。上述理由解释结构的功能，本次实验未证明这些配置最优，也未以消融实验分离各部分的精度贡献。PRNN 的含义是降阶系数的“数据＋物理”联合训练，不是另接一个循环神经网络。

## 6.4 损失函数

训练目标由终态数据损失与降阶物理残差损失相加构成。前者利用差分求解器给出的标签，后者在随机时刻要求预测系数近似满足降阶动力学。两者都可对 FNO 参数反向传播。

### 6.4.1 终态系数数据损失及缩放

$$s = \mathrm{std}\,\{u_{\mathrm{ref}}^{(m)}(x_j, 1)\}, \qquad s_0 = \sqrt{\frac{1}{256\cdot 64}\sum_{m=1}^{256}\sum_{j=0}^{63}|u_0^{(m)}(x_j)|^2}$$

s 是全部 256×64 个终态值的样本标准差，分母使用 256×64-1；$s_0$ 是全部训练初值的均方根。本次分别为 0.00907255 和 0.59348762。两者都只由训练集计算，输入场不除以它们，测试参考解不参与尺度估计。

每批取 B=32 个初值，用终态参考解投影得到标签系数。数据损失对样本求平均、对 12 个系数的平方误差求和：

$$\mathcal{L}_{\mathrm{data}} = \frac{1}{Bs^2}\sum_{b=1}^{B}\sum_{i=1}^{12}\left[\hat{a}_i(\mathbf{u}_0^{(b)}, 1) - a_{i,\,\mathrm{ref}}^{(b)}(1)\right]^2$$

代码没有再除以 12。因为基函数按空间平均内积归一，系数误差平方和等于重建场的空间均方误差：

$$\mathcal{L}_{\mathrm{data}} = \frac{1}{B\cdot 64\cdot s^2}\sum_{b=1}^{B}\sum_{j=0}^{63}\left[\hat{u}^{(b)}(x_j, 1) - (P_{12}u_{\mathrm{ref}}^{(b)})(x_j, 1)\right]^2$$

因此该项保留了原 FNO 的全局标签缩放尺度，并直接监督终态拟合。平方损失对较大偏差给予较大惩罚，目标平滑，便于梯度优化。它相对于 POD 投影标签计算，不等于对完整参考场误差逐点求平均；未保留模态的表示误差不能通过优化这些系数消除。

### 6.4.2 降阶物理方程与残差

$$(D_x f)_j = \frac{f_{j+1} - f_{j-1}}{2\Delta x}, \qquad (D_{xx} f)_j = \frac{f_{j+1} - 2f_j + f_{j-1}}{\Delta x^2}$$

$$L_{ij} = \langle \nu D_{xx}\phi_j, \phi_i\rangle_h, \qquad Q_{ijk} = \left\langle -\tfrac{1}{2}D_x(\phi_j\phi_k), \phi_i\right\rangle_h$$

$D_x$、$D_{xx}$ 分别是一阶和二阶周期中心差分；L 是扩散矩阵，Q 是对流二次项的固定系数。对扩散矩阵对角化并同时旋转基后，Galerkin 方程写为：

$$\frac{da_i}{dt} = \lambda_i a_i + \sum_{j=1}^{12}\sum_{k=1}^{12} Q_{ijk}a_j a_k, \qquad i = 1, \ldots, 12$$

这一步把空间变化的物理约束投影到 12 个基函数方向上。Q 来自守恒通量 $-D_x(u^2)/2$，与标签生成时使用的空间差分形式相同；没有用网络学习或用测试结果拟合 Q。

将网络系数代入降阶方程，把左右两边之差定义为物理残差：

$$R_i(\mathbf{u}_0, t) = \frac{\partial \hat{a}_i}{\partial t} - \lambda_i \hat{a}_i - \sum_{j=1}^{12}\sum_{k=1}^{12} Q_{ijk}\hat{a}_j\hat{a}_k$$

$$\mathcal{L}_{\text{phys}} = \frac{1}{B}\sum_{b=1}^{B}\sum_{i=1}^{12}\left[\frac{R_i(\mathbf{u}_0^{(b)}, t_b)}{\beta s_0 e^{-\beta t_b}}\right]^2, \qquad t_b \sim U(0,1)$$

时间导数对给定初值保持不变，通过自动微分求出。每个批次为当前的 32 个初值分别抽取一个均匀随机时刻，重新计算残差，不要求对应时刻的参考解标签。对 12 个残差分量求平方和，再对样本取平均。

$\beta s_0$ 给出残差的尺度，$e^{-\beta t}$ 对应选定的扩散衰减尺度。这样处理使晚期幅值很小时的残差仍受到约束，避免只由早期大幅值主导。它改变了不同时刻在物理损失中的权重，是本次人为选定的归一化方式，而不是对真实误差大小的精确估计。

$$\mathcal{L} = \mathcal{L}_{\text{data}} + \mathcal{L}_{\text{phys}}$$

两项归一化后权重均取 1。数据项提供离散参考解的终态信息，物理项约束中间演化；本次没有验证权重 1 最优。损失没有除以每条参考解各自的范数，因此它不是逐样本相对 $L^2$ 损失，测试相对误差也不参与参数更新。

没有额外的初值、边界罚项或正则化项：初始投影由输出结构保证，周期性由周期差分、谱运算和基函数表示。物理损失约束的是半离散降阶方程；标签还含显式 Euler 时间离散误差，故物理残差小并不等价于对标签或连续精确解的误差小。

### 6.4.3 优化设置与损失记录

表 7 训练流程、采样和记录方式

| 项目 | 实际设置及含义 |
| --- | --- |
| 优化器 | Adam，初始学习率 0.003，无权重衰减；仅优化 FNO 权重与偏置。 |
| 更新次数 | 256 个训练初值每轮随机打乱，分为 8 个批次；300 轮共 2400 次更新。 |
| 学习率 | 第 1-100 轮为 0.003，第 101-200 轮为 0.0015，第 201-300 轮为 0.00075。 |
| 随机性 | 数据与网络参数种子为 0，时间采样使用独立种子 1；CPU 单线程。 |
| 物理采样 | 共抽取 76800 个初值-时间对；初值重复使用，时间随批次重新采样。 |
| 选模与记录 | 无验证集或早停，使用第 300 轮模型；保存各轮 8 个小批次损失的平均。 |

学习率每完成 100 轮减半；第 300 轮结束后降到 0.000375，但不再更新参数。逐步减小步幅有利于后期调整，未进行优化器对照。记录值包含一轮内参数不断变化的影响，既不是固定最终模型的全训练集损失，也不是验证误差。

## 6.5 数值实验

评价设置沿用第 5 节，使用固定测试初值 $u_0(x)=-\sin(2\pi x)$，在原始 64 点上计算相对 $L^2$、最大绝对误差和均方根误差。图 2 与下表保留原实验的预测、参考解和训练日志。

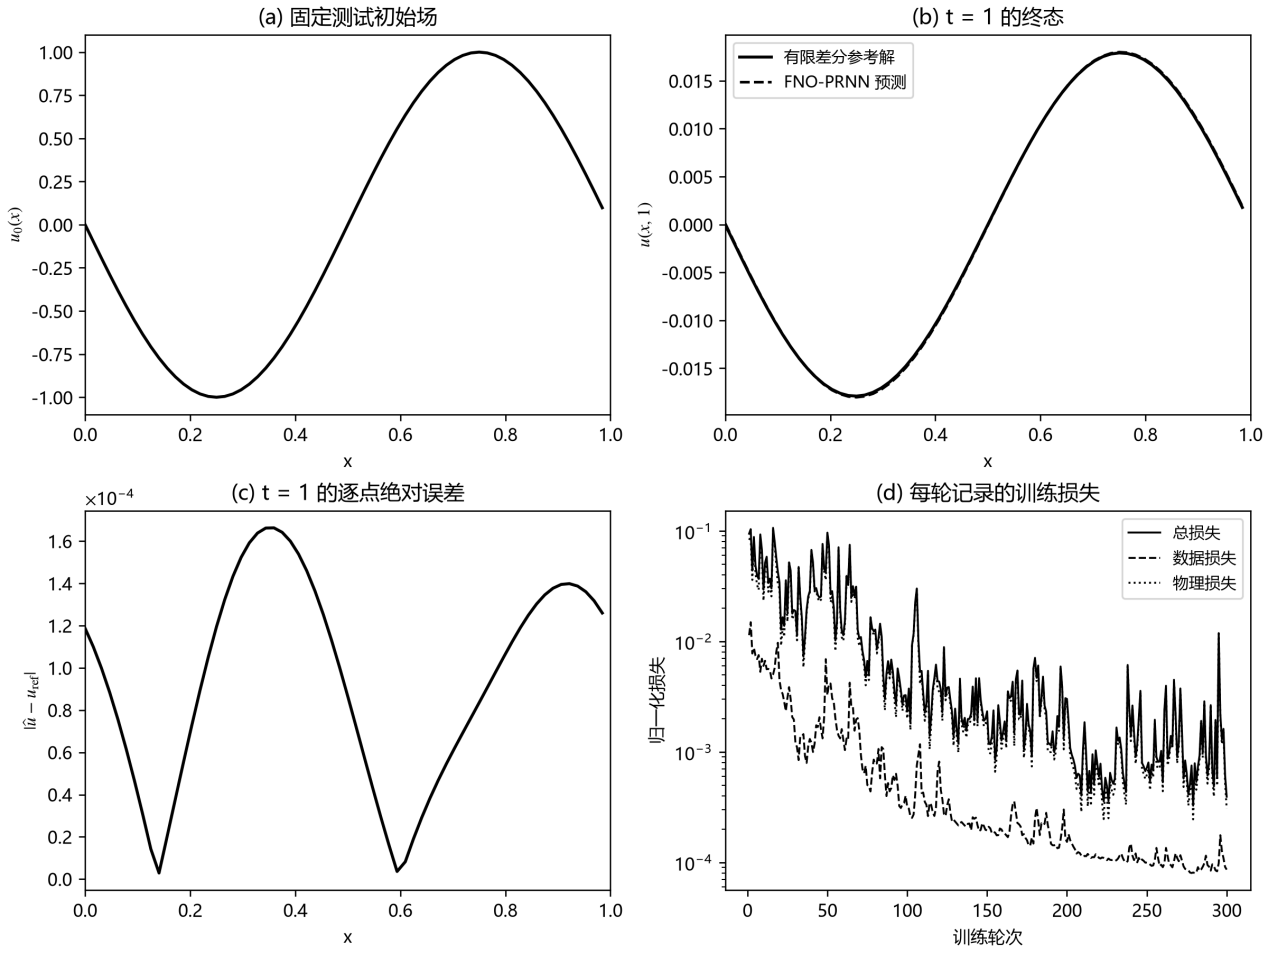



图 2 FNO-PRNN 的固定测试算例与训练过程。（a）初始场；（b）t=1 的参考解与预测解；（c）同一终态的逐点绝对误差；（d）每轮记录的总损失、数据损失和物理损失，纵轴为对数。

表 8 固定测试函数在不同查询时刻的预测误差

| 时刻 t | 相对 $L^2$ 误差 | 最大绝对误差 | 均方根误差 |
|---|---|---|---|
| 0.00 | 0.000014% | $2.38419\times10^{-7}$ | $1.00945\times10^{-7}$ |
| 0.25 | 0.26418% | $1.21528\times10^{-3}$ | $6.62859\times10^{-4}$ |
| 0.50 | 0.58485% | $9.30104\times10^{-4}$ | $5.35230\times10^{-4}$ |
| 0.75 | 0.45583% | $2.52560\times10^{-4}$ | $1.54930\times10^{-4}$ |
| 1.00 | 0.83050% | $1.66283\times10^{-4}$ | $1.05138\times10^{-4}$ |

t=0 的误差来自初值的 POD 投影和浮点运算，不是对未知解的预测成绩。其余时刻分别直接查询网络，参考解由原差分求解器积分到对应时刻；没有对预测时间序列插值。

四联图原样保留：曲线以原始 64 点直线连接，不添加重复端点，不平滑误差；损失图包含全部 300 个轮次。图中的训练损失采用第 6.4.3 节说明的逐轮小批次平均口径。

**训练过程。** 表 9 保留每 50 轮的损失记录。各项总体下降，物理损失在部分轮次有明显波动，不能仅凭下降趋势证明模型已达到最优解。

表 9 每 50 轮列出的训练损失（该轮小批次平均）

| 训练轮次 | 总损失 | 数据损失 | 物理损失 |
|---|---|---|---|
| 50 | $9.63816\times10^{-2}$ | $3.26480\times10^{-3}$ | $9.31168\times10^{-2}$ |
| 100 | $2.32112\times10^{-3}$ | $3.17072\times10^{-4}$ | $2.00405\times10^{-3}$ |
| 150 | $2.33100\times10^{-3}$ | $1.96090\times10^{-4}$ | $2.13491\times10^{-3}$ |
| 200 | $3.01615\times10^{-3}$ | $1.53512\times10^{-4}$ | $2.86264\times10^{-3}$ |
| 250 | $7.19900\times10^{-4}$ | $9.94974\times10^{-5}$ | $6.20403\times10^{-4}$ |
| 300 | $3.93335\times10^{-4}$ | $8.61690\times10^{-5}$ | $3.07166\times10^{-4}$ |

训练结束后用固定模型重新评价全部 256 条终态，归一化场值 MSE 为 $8.43868\times10^{-5}$。它与表 9 的数据损失统计对象不同：前者使用最终参数，并对完整参考场计算误差；后者记录更新过程中对投影系数标签的拟合误差。

**预测结果。** 固定测试初值在 t=1 的相对 $L^2$ 误差为 0.83050%，最大绝对误差为 $1.66283\times10^{-4}$，均方根误差为 $1.05138\times10^{-4}$。这说明当前模型能够近似重建该算例的终态。0.25、0.5、0.75 三个时刻的结果补充了中间演化的检查，但仍属于同一个测试初值。

终态误差高于第 5 节纯 FNO 所记录的 0.04628%，因此这次实验不支持“加入 PRNN 后提高了终态精度”的结论。两种方法的训练目标和快照使用方式不同；本报告保留的实验没有多随机种子重复或结构消融，不能将误差差异单独归因于某一部分。

**核查与适用范围。** 原有核查确认训练初值和终态标签与原 FNO 一致，并检查了 POD 正交性、降阶右端与差分算子投影的一致性、时间导数和物理损失的参数梯度。固定测试初值与所有训练样本均不相同，最近训练样本的离散向量距离约为 1.49047。

随机物理配点反复使用训练初值，不构成独立随机测试集。模态截断、数据与物理约束的权衡、有限训练轮数以及参考标签离散误差都会影响结果。没有连续精确解验证、网格收敛或速度对照，不能推出普遍泛化精度、超分辨率能力或计算加速结论。

**结论。** 本算例保留原粘性 Burgers 方程、三模态初值分布与固定测试函数。FNO 将初始场和时间映射为修正场，POD 投影与扩散结构将其组合成降阶系数，再重建空间解；训练目标为终态系数误差与降阶物理残差之和。现有结果支持对所展示算例的近似预测，当前 300 轮设置下的终态精度未超过原纯 FNO。

## 7. FNO与FNO-PRNN的优缺点比较

本章比较前文两种具体实现。它们求解同一个周期粘性 Burgers 方程，粘性系数为 0.1，空间取 64 点，使用相同的 256 条随机三模态初值及有限差分终态。固定测试初值均为 $u_0(x)=-\sin(2\pi x)$。以下将结构特点与已有实验结果分开列出。

表 10 两种方法的结构与训练方式

| 比较项目 | 纯 FNO | FNO-PRNN |
| --- | --- | --- |
| 训练信息 | 使用 256 对初始场与终态场；网络只拟合终态标签。 | 使用相同的 256 对数据，另保存 5376 个训练快照构造 POD 基；随机时刻的物理残差不需要对应的解标签。 |
| 输入与输出 | 输入整条 64 点初始曲线，输出归一化终态，乘回尺度后得到 t=1 的 64 点场值。 | 输入初始曲线和查询时间，输出 12 个降阶系数，再重建 64 点场值；在 $0\leqslant t\leqslant 1$ 内可以查询不同时间。 |
| 网络与表示 | 四个 Fourier 块、16 通道、谱分支保留 12 个频率；直接输出场值，无固定 POD 子空间限制。 | 沿用相同的 Fourier 主干，增加时间通道、POD 投影和扩散衰减结构；最终解限制在 12 个固定基函数张成的空间中。 |
| 损失与物理约束 | 只使用缩放后的终态场值 MSE。方程通过数值标签提供信息，训练中不计算方程残差。 | 终态系数数据损失与降阶物理残差损失相加，归一化后权重均为 1；残差约束的是半离散降阶方程。 |
| 初值与周期结构 | 谱运算适应周期网格；模型只预测终态，没有 t=0 输出，也没有显式初值约束。 | 周期差分和固定基用于表示周期结构；t=0 的重建场等于初值的 POD 投影，而非对任意初值逐点严格复制。 |
| 实现与计算步骤 | 训练只需终态前向计算和误差反向传播，程序组成较少；按实数分量计有 26273 个参数。 | 还需构造降阶基与方程系数、计算时间导数和物理残差；有 26289 个实参数。12 维输出并未使 FNO 主干明显缩小。 |

两者均使用 Adam 训练 300 轮，批量为 32，初始学习率为 0.003，每 100 轮减半，均无验证集或早停。相同轮数不代表相同计算成本：FNO-PRNN 每次更新的计算内容更多，现有材料没有两者在相同计时条件下的速度和内存对照。

表 11 同一固定测试初值在 t=1 的预测误差

| 评价指标 | 纯 FNO | FNO-PRNN |
|---|---|---|
| 相对 $L^2$ 误差 | 0.04628% | 0.83050% |
| 最大绝对误差 | $1.37920\times10^{-5}$ | $1.66283\times10^{-4}$ |
| 均方根误差 | $5.85890\times10^{-6}$ | $1.05138\times10^{-4}$ |

表 11 直接汇总表 1 和表 8 的原有数值，均相对于同一个 64 点有限差分参考终态计算。本次纯 FNO 的三项终态误差均较小；该比较反映当前完整实现与训练设置的结果，不能单独说明物理约束或 POD 对精度的影响。

表 12 主要优点、缺点与本算例中的取舍

| 比较项目 | 纯 FNO | FNO-PRNN |
|---|---|---|
| 主要优点 | 输入输出直接，训练目标单一，程序较简洁；不需要保存中间快照或构造降阶方程；本次固定算例的终态精度较高。 | 同一模型可查询不同时间；降阶系数给出明确的空间表示；初始投影、已知扩散衰减和方程残差都参与约束预测。 |
| 主要缺点 | 当前模型仅学习 t=1 的映射，无法直接给出中间演化；没有显式残差来约束动力学，预测精度依赖终态标签及其覆盖范围。 | 步骤和调节因素更多，需选取降阶维数及物理损失尺度；截断会限制可表示的解；加入物理约束后，本次终态误差仍高于纯 FNO。 |
| 当前任务中的取舍 | 若需求限于本算例的终态预测，现有实验支持采用更简洁、终态误差更小的纯 FNO 实现。 | 若需要不同时间的预测以及显式的降阶动力学约束，该实现具备这些功能；采用时仍需核查各时刻的误差。 |

**时间预测的证据。** FNO-PRNN 在同一测试初值的 t=0.25、0.5、0.75 时刻，相对 $L^2$ 误差分别为 0.26418%、0.58485%、0.45583%。这些结果补充了中间时刻检查；t=0 的误差主要来自投影和浮点运算，不能作为未知解的预测成绩。

**比较边界。** 两种方法使用的训练信息和目标并不完全相同，FNO-PRNN 额外利用了中间快照。其数据损失与总损失、逐轮平均与纯 FNO 的最后小批次日志也不能直接比较。现有实验不足以证明哪一种更节省样本、泛化更好或运行更快。

**结论。** 在本报告的固定终态任务中，纯 FNO 的优势是实现简洁且已记录误差更小；FNO-PRNN 的优势是能查询时间，并把降阶表示与物理约束纳入求解。后者提供了更多建模功能，但本次实验没有显示终态精度提升。

## 8. 不同终止时刻的补充数值实验

本节在前七部分的基础上，补充 T=0、0.25、0.5、0.75 的实验，并列入 T=1 的结果作为对照。FNO-PRNN 以下简称 FP。重点考察改变终止时刻后，两种实现对同一固定测试初值的预测误差及训练表现；方程、网络结构与损失函数的已有推导不再重复。

### 8.1 实验设置与时间参数的含义

**共同条件。** 方程、周期边界及初值分布沿用第 1 节与第 6.1 节：粘性系数为 0.1，空间区域为 [0,1)，采用 64 个网格点和 0.0005 的积分步长。训练初值仍为同一批 256 条随机三模态曲线，固定测试初值为 $u_0(x)=-\sin(2\pi x)$。

每个脚本从头初始化并训练 300 轮，批量为 32；Adam 的初始学习率为 0.003，每 100 轮减半。数据与网络参数的随机种子为 0，FP 的时间采样种子为 1。没有验证集，采用最后一轮模型；网络宽度、频率数、POD 秩和两项损失的权重均保持原设置。

**独立训练的终点任务。** T 是该份代码的数据积分终点和监督时刻。每种方法分别训练五个模型，共十次训练，而非让原 T=1 模型直接查询五个时刻。因此，本节的 FP 中间终点结果与第 6 节表 8 的多时刻查询结果属于不同实验。

表 13 不同终止时刻对应的数据规模与标签尺度

| 终止时刻 T | 积分步数 | 每条初值的快照数 | FP 快照总数 | 终态标准差 s(T) |
|---|---|---|---|---|
| 0 | 0 | 1 | 256 | 0.59350574 |
| 0.25 | 500 | 6 | 1536 | 0.17982730 |
| 0.5 | 1000 | 11 | 2816 | 0.06558114 |
| 0.75 | 1500 | 16 | 4096 | 0.02435795 |
| 1 | 2000 | 21 | 5376 | 0.00907255 |

两种方法在每个 T 下都使用 256 对初值与该时刻参考场。FP 每隔 0.05 保存一次快照，并包含初值；这些快照用于重新构造该区间的 POD 基。快照总数不是独立初值的数量。随着 T 改变，终态标签、标签标准差和 FP 的降阶基也随之重新计算。

**输入、输出与损失。** FNO 仍输入 64 点初始场，输出归一化的 T 时刻场值，并乘回 s(T)。FP 仍输入初始场与时间，输出 12 个系数并重建空间场；其数据项在 t=T 计算，物理配点的时间范围改为 [0,T]。除这些时间相关量外，计算方式分别沿用第 2-4 节和第 6.2-6.4 节。

改变 T 是本次脚本的显式设置变化，但它同时改变了所学习的终点映射、FP 的快照区间及物理采样区间。故不能把不同 T 的结果解释为同一个已训练模型的误差随时间演化。

## 8.2 误差指标与数值结果

沿用第 5 节的相对 $L^2$ 误差、最大绝对误差和均方根误差，统一在原始 64 个空间点上计算。所有指标由十份脚本运行后保存的原尺度预测与参考数组复算；同一 T 下，两种方法的参考场逐点一致。参考场仍为有限差分离散解。

表 14 各终止时刻的预测误差（每行对应独立训练的模型）

| 时刻 T | 方法 | 相对 $L^2$ 误差 | 最大绝对误差 | 均方根误差 |
|---|---|---|---|---|
| 0 | FNO | 0.12962% | $1.99729\times10^{-3}$ | $9.16559\times10^{-4}$ |
| 0 | FP | 0.000012% | $2.08616\times10^{-7}$ | $8.58097\times10^{-8}$ |
| 0.25 | FNO | 0.06850% | $3.67254\times10^{-4}$ | $1.71861\times10^{-4}$ |
| 0.25 | FP | 0.40415% | $1.80247\times10^{-3}$ | $1.01404\times10^{-3}$ |
| 0.5 | FNO | 0.04011% | $8.26838\times10^{-5}$ | $3.67070\times10^{-5}$ |
| 0.5 | FP | 0.78750% | $9.88275\times10^{-4}$ | $7.20686\times10^{-4}$ |
| 0.75 | FNO | 0.03952% | $3.28515\times10^{-5}$ | $1.34327\times10^{-5}$ |
| 0.75 | FP | 0.37502% | $2.53851\times10^{-4}$ | $1.27464\times10^{-4}$ |
| 1 | FNO | 0.04628% | $1.37920\times10^{-5}$ | $5.85890\times10^{-6}$ |
| 1 | FP | 0.83051% | $1.66285\times10^{-4}$ | $1.05139\times10^{-4}$ |

**初始时刻。** T=0 时，FNO 的相对 $L^2$ 误差为 0.12962%，FP 约为 0.000012%。此时参考场就是已知初值；两者分别采用学习恒等映射和结构性初值投影，不能将这一差距理解为对未知演化解的预测优势。

**正时间终点。** T=0.25、0.5、0.75、1 时，FNO 的相对误差、最大绝对误差和均方根误差均小于 FP。FP 的相对误差并不随 T 单调变化；四个独立终点任务也不足以给出整个连续时间区间的精度保证。

T=1 行采用当前四格图脚本保存的数值：FP 相对误差为 0.83051%，前文原记录为 0.83050%；两批预测场的最大差约为 $4.66\times10^{-9}$。本节按本批数组列值，前文的数值、图形与文字均保留。

**图形组织。** 初始曲线在各脚本中相同，故不重复展示。图 3-6 将同一终点的两种预测和误差直接放在一起，损失则各占一个子图。曲线使用原始网格点连接；不同损失图的纵轴范围由各自数据决定，不通过曲线高度直接比较两种训练目标。

## 8.3 不同终止时刻的图形对比

### 8.3.1 T=0：初值重建

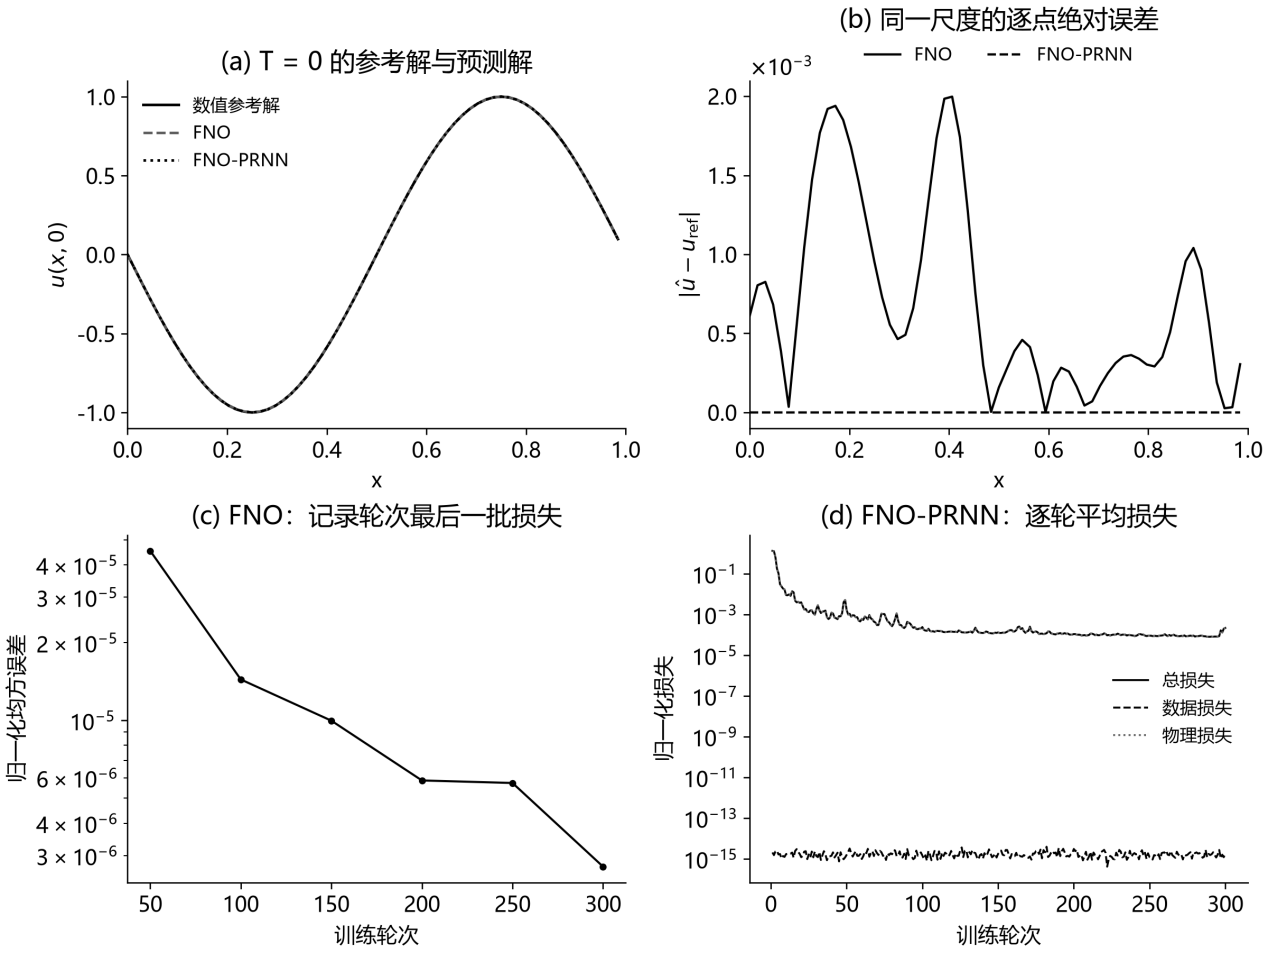



图 3 T=0 时两种方法的对比。（a）参考解与预测解；（b）同一纵轴尺度下的逐点绝对误差；（c）FNO 每 50 轮记录的最后小批次 MSE；（d）FP 每轮平均的总损失、数据损失和物理损失。后两图采用对数纵轴。

**重建结果。** 图 3(a) 中两种预测与初值接近，但图 3(b) 显示误差尺度明显不同。FNO 的最大绝对误差约为 $2.00\times10^{-3}$，FP 约为 $2.09\times10^{-7}$；由于使用同一纵轴尺度，FP 的误差曲线接近横轴。

FNO 此时以初值本身作为监督标签，需要通过参数训练近似实现“输入等于输出”。FP 的时间修正因子在零时刻消失，输出系数直接等于初始投影系数，因此重建误差主要来自 POD 投影与浮点计算。这是输出结构的作用，不是网络通过预测未来获得的精度。

**损失的含义。** FP 第 300 轮的数据损失约为 $1.73\times10^{-15}$，但物理损失仍约为 $2.14\times10^{-4}$。T=0 时，所有物理配点均位于初始时刻，约束的是该处的瞬时降阶导数；快照也只有初始场。因此，这个算例适合检查初值保持，不能检验一段时间内的动力学预测。

### 8.3.2 T=0.25：较早终点的预测

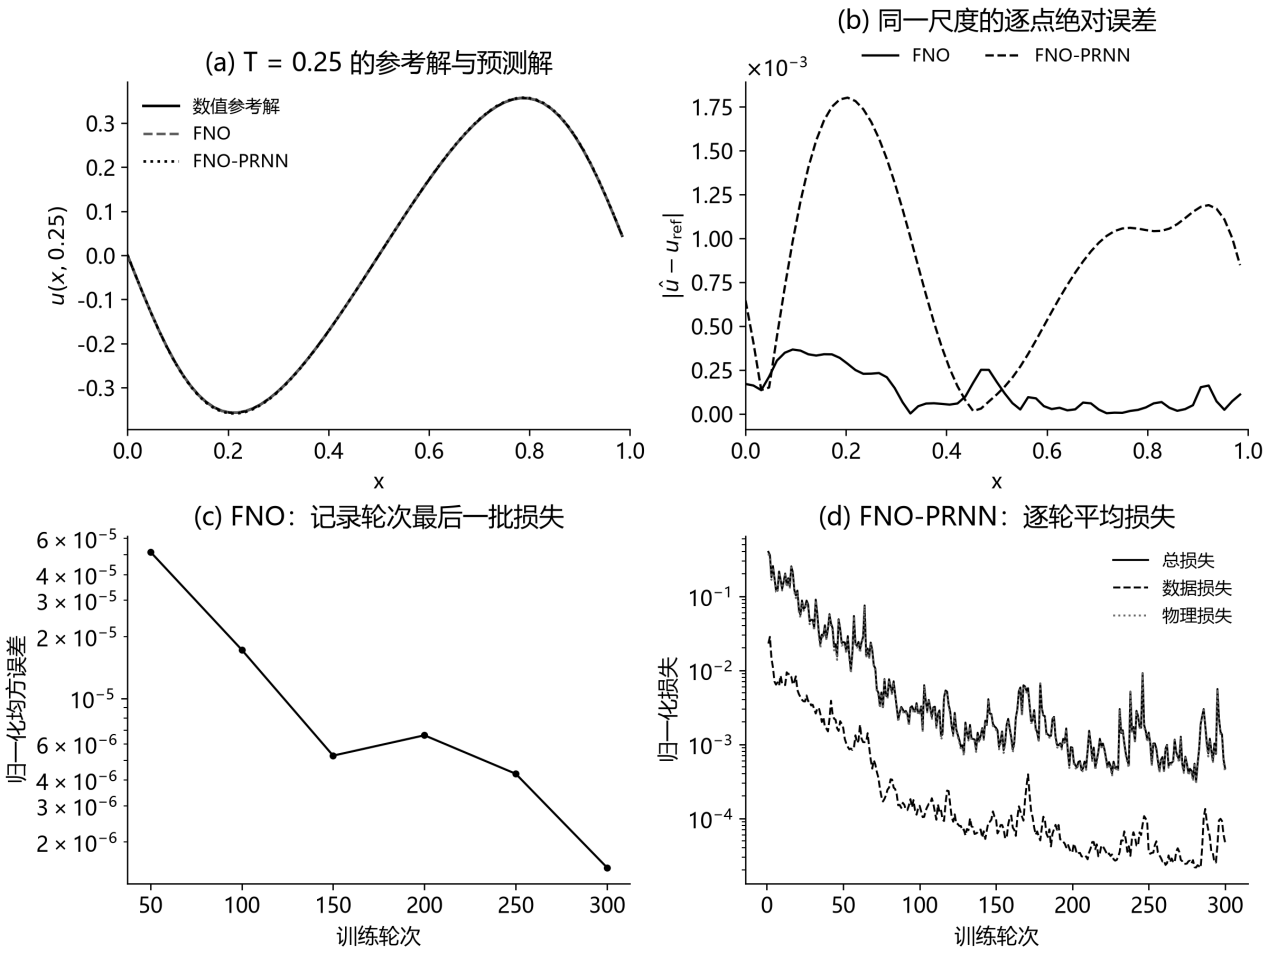



图 4 T=0.25 时两种方法的对比。（a）参考解与预测解；（b）同一纵轴尺度下的逐点绝对误差；（c）FNO 每 50 轮记录的最后小批次 MSE；（d）FP 每轮平均的总损失、数据损失和物理损失。后两图采用对数纵轴。

**预测结果。** FNO 与 FP 的相对 $L^2$ 误差分别为 0.06850% 和 0.40415%。两条预测曲线在图 4(a) 中均接近参考场，但直接比较绝对误差可见，FP 的偏差整体更大；其最大绝对误差为 $1.80\times10^{-3}$，FNO 为 $3.67\times10^{-4}$。

该时刻参考场的最大绝对幅值约为 0.35674，明显高于 T=1 时的 0.01790。因此，视觉重合程度和绝对误差都需要结合场值尺度理解；表 14 同时列出相对误差，避免仅凭解曲线作判断。

**训练表现。** FNO 的六个记录点总体下降，局部仍有回升；FP 的逐轮损失也总体下降，但存在波动。FP 第 300 轮的数据损失约为 $4.77\times10^{-5}$，物理损失约为 $4.26\times10^{-4}$。它说明两项训练目标具有不同数值尺度，不能直接据此判断哪一项造成了测试误差。

### 8.3.3 T=0.5：中间终点的预测

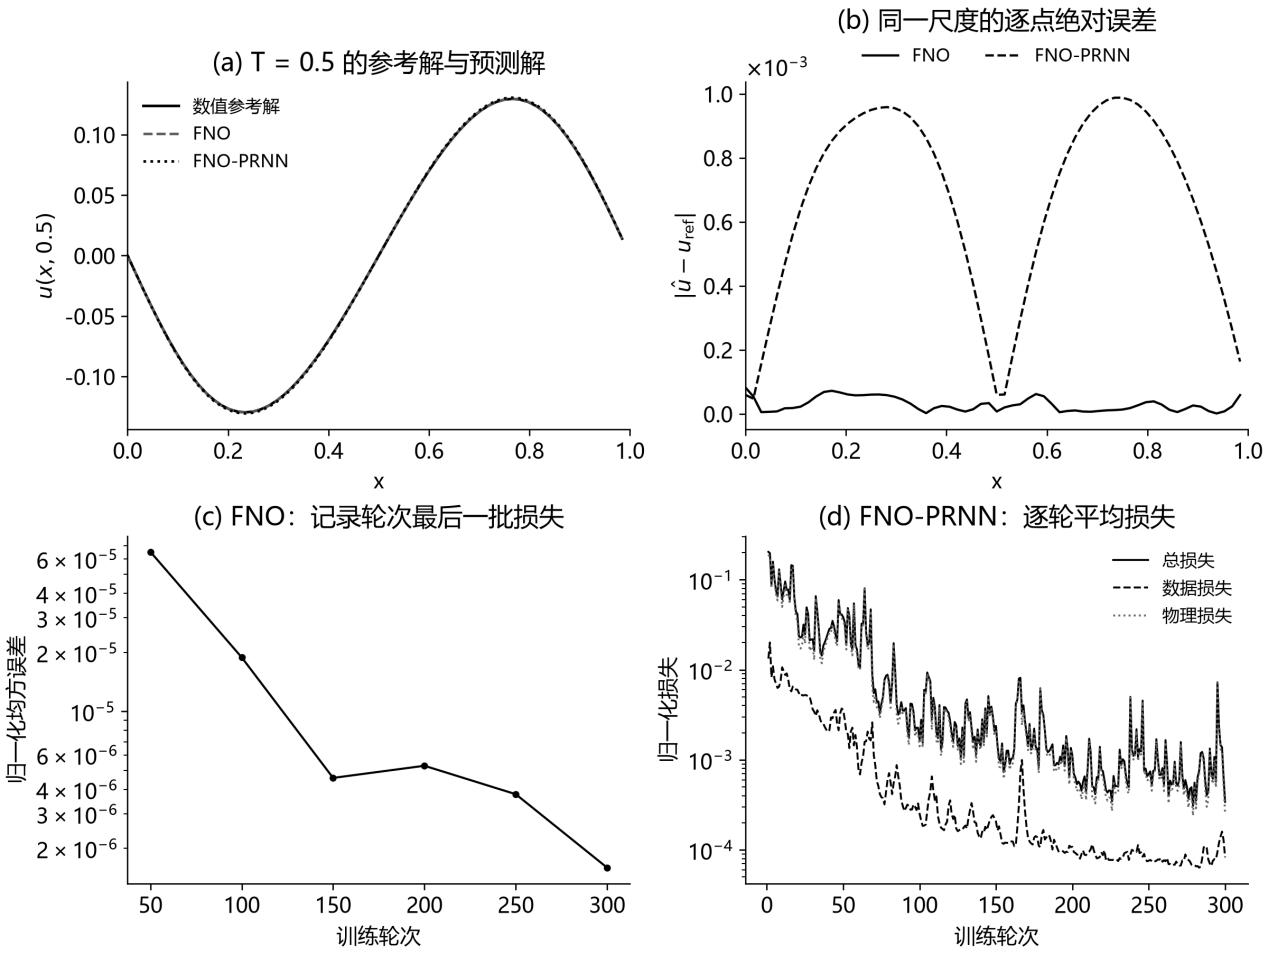



图 5 T=0.5 时两种方法的对比。（a）参考解与预测解；（b）同一纵轴尺度下的逐点绝对误差；（c）FNO 每 50 轮记录的最后小批次 MSE；（d）FP 每轮平均的总损失、数据损失和物理损失。后两图采用对数纵轴。

**预测结果。** FNO 的相对 $L^2$ 误差为 0.04011%，FP 为 0.78750%；后者约为前者的 19.63 倍。FNO 的最大绝对误差约为 $8.27\times10^{-5}$，FP 约为 $9.88\times10^{-4}$。三项指标均支持本次 FNO 的终点拟合更准确。

与 T=0.25 的独立 FP 模型相比，此处最大绝对误差减小，但相对 $L^2$ 误差增大。参考场最大幅值已降至约 0.12958，说明误差的绝对量与其相对于解幅值的大小可以呈现不同变化趋势。

**训练表现。** 两种模型均完成原定的 300 轮训练。FP 第 300 轮总损失约为 $3.41\times10^{-4}$，低于 T=0.25 模型的 $4.74\times10^{-4}$，但其测试相对误差反而更高。不同终点的标签尺度、POD 基和配点区间不同，训练损失值不能直接充当跨实验的预测精度排名。

### 8.3.4 T=0.75：较晚终点的预测

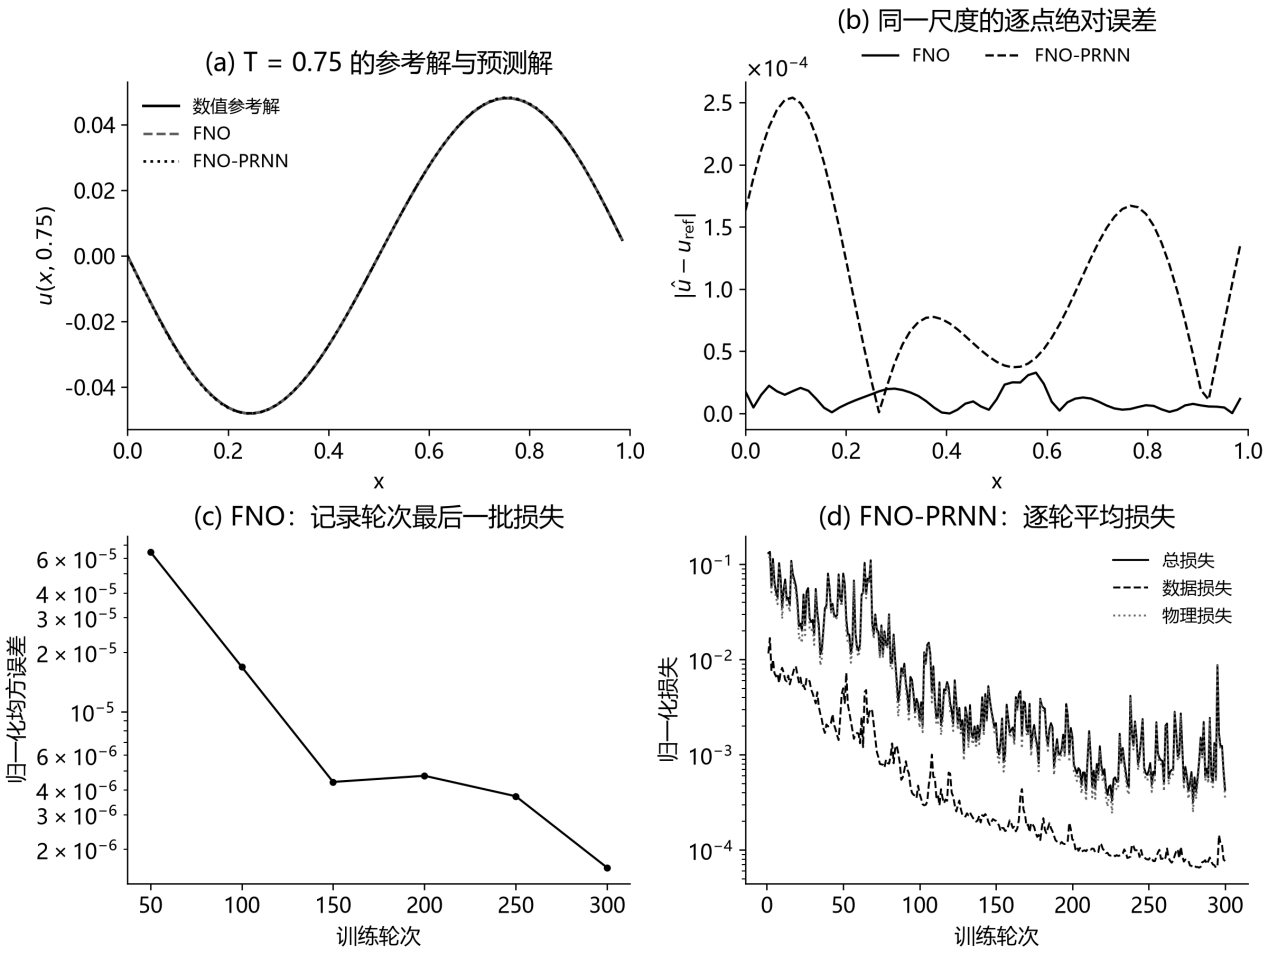



图 6 T=0.75 时两种方法的对比。（a）参考解与预测解；（b）同一纵轴尺度下的逐点绝对误差；（c）FNO 每 50 轮记录的最后小批次 MSE；（d）FP 每轮平均的总损失、数据损失和物理损失。后两图采用对数纵轴。

**预测结果。** FNO 的相对 $L^2$ 误差为 0.03952%，FP 为 0.37502%。FP 比其 T=0.5 模型的相对误差更小，但在这一终点仍未超过 FNO；其最大绝对误差约为 $2.54\times10^{-4}$，FNO 约为 $3.29\times10^{-5}$。

参考场最大幅值约为 0.04804。图 6(a) 中两种预测在整体形状上均与参考场接近，图 6(b) 则显示 FP 的逐点偏差较大。该区别说明解曲线与误差曲线应同时展示，不能用“看起来重合”代替定量评价。

**与原终点的联系。** 表 14 中 T=1 的 FNO 与 FP 相对误差分别为 0.04628% 和 0.83051%，仍保持 FNO 较小的排序。连同前三个正时间终点，本组结果支持当前 FNO 在这些终点任务上的精度优势；各终点的模型独立训练，这些场不能直接拼接为同一模型的时间轨迹。

## 8.4 训练记录与综合比较

表 15 第 300 轮的损失记录

| 终止时刻 T | FNO MSE | FP 总损失 | FP 数据损失 | FP 物理损失 |
|---|---|---|---|---|
| 0 | $2.71641\times10^{-6}$ | $2.13784\times10^{-4}$ | $1.72830\times10^{-15}$ | $2.13784\times10^{-4}$ |
| 0.25 | $1.50087\times10^{-6}$ | $4.74061\times10^{-4}$ | $4.76557\times10^{-5}$ | $4.26405\times10^{-4}$ |
| 0.5 | $1.59519\times10^{-6}$ | $3.41250\times10^{-4}$ | $8.25016\times10^{-5}$ | $2.58748\times10^{-4}$ |
| 0.75 | $1.61572\times10^{-6}$ | $4.27775\times10^{-4}$ | $7.63685\times10^{-5}$ | $3.51407\times10^{-4}$ |
| 1 | $1.63487\times10^{-6}$ | $3.93337\times10^{-4}$ | $8.61689\times10^{-5}$ | $3.07168\times10^{-4}$ |

FNO 列为该轮最后一个小批次的损失，FP 各列为该轮八个小批次的平均；它们均不是验证误差。表 15 用于补充训练记录，预测精度以表 14 为准。FP 的物理损失约束降阶方程，数值较小不等于完整参考场的误差必然更小。

表 16 补充实验对两种方法优缺点的说明

| 比较方面 | FNO | FP |
|---|---|---|
| 初值保持 | T=0 时通过数据监督学习恒等映射，本次仍有约 0.13% 的相对误差。 | 初始投影由输出结构保证，本次误差接近浮点计算尺度；这是初值约束的优势。 |
| 正时间精度 | 在四个正时间终点的三项指标上均更小，当前固定算例的拟合更准确。 | 能够近似重建各终点解，但本次增加降阶与物理约束并未带来更低的终点误差。 |
| 物理信息 | 只监督对应终点的场值，没有显式约束中间动力学。 | 同时约束终点数据和 [0,T] 内的降阶残差，提供了额外的物理训练目标。 |
| 本节评价范围 | 每个终点单独训练；本节没有构造单一时间条件 FNO。 | 虽然模型含时间输入，本节仍逐终点重新训练，未评价这些新模型各自完整的时间轨迹。 |

**结果边界。** 以上仍只针对同一固定测试初值、单次训练设置及同一离散参考求解器。没有权重或结构消融，也没有多随机种子、独立随机测试集和统一速度测量，不能将误差差距单独归因于物理损失，或据此判断一般情况下的效率与泛化能力。

**结论。** 补充实验将初值重建与正时间预测区分开来：FP 在 T=0 的初值保持更准确；在 T=0.25、0.5、0.75、1 的独立终点任务中，当前纯 FNO 的三项预测误差均较小。FP 提供了初值投影和降阶动力学约束，但本组结果没有显示其终点精度优于纯 FNO。